

Reconstrucción Física-Guiada de Imágenes Fotoacústicas mediante Redes Neuronales Duales

presentado por

Maximiliano Galindo
Licenciatura en Física, Maestría en Ciencias

Presentado para cumplir con los requisitos del grado de
Maestría en Ciencias

Universidad Nacional Autónoma de México
Enero 2022

Resumen

El deep learning ha revolucionado la reconstrucción de imágenes fotoacústicas a partir de datos crudos (raw data) provenientes de sensores, donde un eje representa el tiempo y el otro la dirección de escaneo. Las aproximaciones han evolucionado desde el uso de métodos convencionales complementados con deep learning para mejorar la calidad de imagen, hasta el desarrollo de redes neuronales que aprenden a reconstruir la imagen directamente desde los datos crudos. En este contexto, la arquitectura U-Net se ha convertido en un estándar de facto. Sin embargo, el principal desafío al usar redes neuronales para la reconstrucción directa radica en la física subyacente del problema, que lo hace matemáticamente mal condicionado. Aunque existen métodos como las Physics Informed Neural Networks (PINN) para incorporar restricciones físicas, estos suelen ser computacionalmente costosos debido a las numerosas operaciones numéricas requeridas. En este trabajo, proponemos un nuevo marco de trabajo que permite a la red neuronal no solo reconstruir la imagen sino también mantener la consistencia física del problema.

Nuestra propuesta se basa en un enfoque inspirado en el data guided learning, que consta de dos fases principales. En la primera, entrenamos dos redes U-Net: una aprende a reconstruir imágenes a partir de datos crudos, mientras que la otra aprende el problema inverso, es decir, la generación de señales fotoacústicas a partir de imágenes, simulando así el proceso físico de propagación de ondas acústicas. En la segunda fase, realizamos un fine-tuning de la red de reconstrucción, incorporando la consistencia física como una restricción adicional en el proceso de aprendizaje. Este enfoque actúa como un supervisor que guía a la red para que no solo aprenda a reconstruir imágenes con alta calidad, sino que también respete los principios físicos fundamentales del proceso fotoacústico.

Agradecimientos

(this section is presently blank)

Supervisores

Dr. Luis Agustín Alvarez-Icaza Longoria ¹, and Dr. Roberto Giovanni Ramírez Chavarría²

¹Investigador Titular C
Instituto de Ingeniería
Universidad Nacional Autónoma de México

²Investigador Titular C
Instituto de Ingeniería
Universidad Nacional Autónoma de México

Índice general

1. Introducción	2
1.1. Introducción	2
1.2. Preguntas de Investigación y Contribuciones	2
1.2.1. Preguntas de Investigación	3
1.2.2. Contribuciones	3
1.3. Estructura de la Tesis	3
2. Marco Teórico y Estado del Arte	4
2.1. Imagen Fotoacústica: Fundamentos y Avances	4
2.1.1. Principios Físicos y Tecnológicos	4
2.1.2. Métodos Tradicionales de Reconstrucción	5
2.2. Importancia de la Consistencia Física en Reconstrucción Fotoacústica	6
2.2.1. Naturaleza del Problema Inverso	6
2.2.2. Garantías de Validez y Robustez	6
2.2.3. Ventajas en el Aprendizaje Profundo	6
2.3. Deep Learning en Reconstrucción de Imágenes Fotoacústicas	7
2.3.1. Evolución de Métodos de Reconstrucción con Deep Learning	7
2.3.2. Incorporación de Física en Redes Neuronales	7
2.3.3. Desafíos en la Incorporación de Física	7
2.4. Limitaciones y Desafíos Actuales	8
3. Metodología	9
3.1. Fundamentos Teóricos	9
3.1.1. Efecto Fotoacústico	9
3.1.2. Ecuación de Onda Fotoacústica	10
3.1.3. Problema Inverso del Efecto Fotoacústico	10
3.1.4. Deep Learning en Reconstrucción Fotoacústica	11
3.2. Enfoque Propuesto	12

3.2.1.	Arquitectura del Sistema	12
3.2.2.	Preentrenamiento Individual	12
3.2.3.	Flujo de Datos	14
3.2.4.	Fine-tuning con Supervisión Física	15
4.	Implementación	16
4.1.	Especificaciones Técnicas	16
4.1.1.	Arquitectura del Sistema	16
4.1.2.	Hiperparámetros de Entrenamiento	16
4.2.	Pipeline de Entrenamiento	17
4.2.1.	Obtención de Datos	18
4.2.2.	Preentrenamiento	18
4.2.3.	Fine-tuning	18
4.3.	Métricas de Evaluación	18
4.3.1.	Calidad de Reconstrucción	18
4.3.2.	Rendimiento Computacional	19
4.3.3.	Análisis Estadístico	19
5.	Experimentos y Resultados	20
5.1.	Experimentos y Resultados	20
5.1.1.	Diseño Experimental	20
5.1.2.	Análisis del Proceso de Entrenamiento Dual	21
5.1.3.	Contribución de Componentes Específicos en la Estrategia de Entrenamiento	23
5.1.4.	Análisis Comparativo Integral	25
5.1.5.	Visualización de Resultados	26
5.1.6.	Análisis de Eficiencia Computacional y Práctica	27
6.	Análisis y Discusión	29
7.	Conclusiones y Trabajo Futuro	30
A.	Apéndices	31

Índice de figuras

2.1. Efecto fotoacústico.	5
3.1. Arquitectura de la red propuesta. La red reestructora se entrena para aprender el mapeo directo de señales acústicas a imágenes fotoacústicas. La red supervisora se entrena para emular el proceso físico de generación de señales acústicas a partir de una imagen dada. Durante el proceso de fine-tuning, la red reestructora se entrena para generar imágenes que, al ser procesadas por la red supervisora, produzcan señales acústicas consistentes con las mediciones originales.	13
5.1. Evolución de las pérdidas durante el preentrenamiento independiente de las redes duales. Nótese las diferentes dinámicas de convergencia: la red reestructora (a) muestra una convergencia más estable y una brecha menor entre las pérdidas de entrenamiento y validación, mientras que la red supervisora (b) presenta más fluctuaciones y una brecha más pronunciada, indicando la mayor complejidad del problema físico inverso.	22
5.2. Evolución de las componentes de pérdida durante el fine-tuning completo. Obsérvese cómo la pérdida física inicialmente alta se reduce progresivamente mientras la red aprende a incorporar el conocimiento físico sin comprometer la calidad de reconstrucción directa.	23
5.3. Análisis del impacto de la supervisión física en el proceso de fine-tuning. (a) Evolución de las pérdidas al eliminar la componente física, mostrando un comportamiento significativamente diferente. (b) Comparación directa de las señales fotoacústicas reconstruidas por los diferentes modelos, evidenciando la mejora en la consistencia física.	24
5.4. Análisis del impacto del componente estructural en la estrategia de entrenamiento. (a) Evolución de las pérdidas al eliminar la componente estructural, mostrando una dinámica altamente inestable con valores de pérdida física iniciales extremadamente altos. (b) Mapa de calor de SSIM regional comparando los diferentes modelos, revelando patrones de deterioro estructural específicos cuando se elimina esta componente.	24
5.5. Análisis comparativo del porcentaje de mejora/deterioro en las diferentes métricas para cada configuración experimental, tomando como referencia el modelo preentrenado (Baseline). Las barras positivas indican mejora, mientras que las negativas representan deterioro.	25

5.6. Ejemplos de reconstrucciones obtenidas con el modelo fine-tuned completo. Se muestran: (a) Imagen original, (b) Señal fotoacústica de entrada, (c) Reconstrucción obtenida, (d) Error absoluto. Nótese la preservación de detalles estructurales finos y la consistencia en las reconstrucciones.	26
5.7. Análisis comparativo visual de reconstrucciones obtenidas con los diferentes modelos. Obsérvese cómo: (1) El modelo con fine-tuning completo (b) mejora la nitidez y detalle respecto al baseline (a), (2) La eliminación del componente físico (c) introduce sutiles inconsistencias, y (3) La eliminación del componente estructural (d) produce degradación severa de la calidad visual.	27

Índice de cuadros

4.1. Arquitectura del modelo U-Net. Cada 'Double Conv' consiste en dos capas convolucionales 3x3 seguidas de BatchNorm y ReLU. Las operaciones ConvTranspose tienen kernel 2x2 y stride 2.	16
4.2. Hiperparámetros utilizados en el entrenamiento del modelo	17
4.3. Hiperparámetros del entrenamiento supervisado	17
5.1. Configuraciones experimentales para evaluar la estrategia de entrenamiento propuesta y sus componentes.	21
5.2. Análisis comparativo integral de las métricas de evaluación para los diferentes modelos. Los valores en verde indican mejora porcentual respecto al modelo Baseline, mientras que los valores en rojo indican deterioro. El mejor rendimiento para cada métrica está en negrita	25
5.3. Análisis comparativo de eficiencia computacional entre la estrategia de entrenamiento propuesta y métodos alternativos. La estrategia dual propuesta logra un balance favorable entre incorporación de física y eficiencia computacional.	28

Capítulo 1

Introducción

1.1. Introducción

En la actualidad, las técnicas de imagen médica no invasivas han revolucionado el diagnóstico y tratamiento de enfermedades. Entre estas técnicas emergentes, la imagen fotoacústica (PAI, por sus siglas en inglés) se destaca por su capacidad única de combinar el contraste óptico con la resolución ultrasónica, permitiendo visualizar estructuras biológicas con un nivel de detalle sin precedentes.

La reconstrucción de imágenes fotoacústicas representa un problema inverso mal condicionado que ha sido abordado tradicionalmente mediante aproximaciones analíticas y técnicas iterativas. Estos métodos, aunque fundamentados en principios físicos sólidos, a menudo resultan computacionalmente costosos y pueden producir artefactos en las imágenes reconstruidas debido a la incertidumbre inherente en las mediciones.

El aprendizaje profundo ha emergido como una alternativa prometedora para estos desafíos, demostrando capacidad para aprender mapeos complejos directamente de los datos. Sin embargo, las arquitecturas convencionales de redes neuronales carecen de la capacidad para incorporar naturalmente el conocimiento físico subyacente, lo que puede comprometer la consistencia física de las reconstrucciones. Los métodos existentes que intentan integrar restricciones físicas, como las Physics-Informed Neural Networks (PINNs), introducen una alta complejidad computacional que limita su aplicabilidad práctica.

Nuestro trabajo aborda esta brecha metodológica mediante el desarrollo de una estrategia de entrenamiento innovadora basada en redes duales con supervisión física. Utilizando la reconstrucción fotoacústica como caso de estudio, demostramos cómo este enfoque puede balancear efectivamente el aprendizaje basado en datos con la incorporación de conocimiento físico, sin incurrir en la complejidad computacional de los métodos PINN tradicionales. El énfasis principal no recae en alcanzar un nuevo estado del arte en reconstrucción fotoacústica específicamente, sino en establecer un paradigma de entrenamiento que podría extenderse a diversos problemas inversos mal condicionados en el campo de la imagen médica y más allá.

1.2. Preguntas de Investigación y Contribuciones

Este trabajo de investigación se centra en el desarrollo de una estrategia de entrenamiento dual físicamente guiada para redes neuronales profundas, utilizando la reconstrucción fotoacústica como caso de estudio. Para lograr este objetivo, se plantean las siguientes preguntas de investigación:

1.2.1. Preguntas de Investigación

La pregunta principal de investigación es la siguiente:

¿Cómo podemos desarrollar una estrategia de entrenamiento para redes neuronales que equilibre efectivamente el aprendizaje basado en datos con la incorporación de conocimiento físico, sin incurrir en la complejidad computacional de los métodos tradicionales?

Para abordar esta pregunta de manera sistemática, se han establecido las siguientes sub-preguntas:

- PI1: *¿Cómo puede diseñarse una estrategia de entrenamiento dual que incorpore conocimiento físico en redes neuronales profundas sin recurrir a la complejidad de PINN tradicionales?*
- PI2: *¿Qué ventajas ofrece el aprendizaje simultáneo del problema directo e inverso en la consistencia y robustez del entrenamiento?*
- PI3: *¿Cuál es el impacto de diferentes componentes de la función de pérdida en la transferencia efectiva de conocimiento durante el fine-tuning?*
- PI4: *¿Cómo se puede generalizar esta estrategia de entrenamiento a otros problemas inversos mal condicionados en imágenes médicas?*

1.2.2. Contribuciones

Esta investigación proporciona las siguientes contribuciones al conocimiento:

- C1: Una estrategia de entrenamiento innovadora basada en redes duales que permite la incorporación de conocimiento físico sin la complejidad computacional de los métodos PINN tradicionales.
- C2: Un paradigma de fine-tuning con supervisión física que facilita la transferencia efectiva de conocimiento entre las redes reconstrucción y física, demostrado mediante:
 - Mejora del 18.6 % en precisión de reconstrucción (MSE)
 - Aumento del 18.8 % en consistencia física de las soluciones
 - Incremento significativo en métricas perceptuales (SSIM hasta 0.973)
- C3: Un análisis exhaustivo de la contribución de diferentes componentes de la función de pérdida en la efectividad del entrenamiento, proporcionando directrices metodológicas para problemas similares.
- C4: Evidencia empírica que demuestra cómo la incorporación de conocimiento físico actúa como regularizador implícito, mejorando la generalización en problemas inversos mal condicionados.
- C5: Una implementación de código abierto que facilita la reproducibilidad y adaptación de la estrategia propuesta a otros dominios.

1.3. Estructura de la Tesis

Capítulo 2

Marco Teórico y Estado del Arte

Esta revisión de literatura abarca dos áreas principales de investigación: la imagen fotoacústica y las técnicas de aprendizaje profundo para la reconstrucción de imágenes médicas [29]. El objetivo es establecer una base sólida para entender el estado actual de la tecnología fotoacústica y las aplicaciones más recientes de redes neuronales, específicamente las arquitecturas basadas en atención, en el campo de la reconstrucción de imágenes médicas.

La revisión abarca publicaciones desde 2015 hasta 2024, con énfasis especial en los avances más recientes en arquitecturas de deep learning para procesamiento de imágenes médicas [27]. Se han incluido trabajos tanto teóricos como experimentales, con particular atención a aquellos que abordan los desafíos específicos de la reconstrucción fotoacústica [1].

2.1. Imagen Fotoacústica: Fundamentos y Avances

Para entender la imagen fotoacústica, es necesario comprender los principios físicos y tecnológicos subyacentes, así como los métodos tradicionales de reconstrucción utilizados en la práctica clínica actual [32]. A continuación, se presentan los aspectos más relevantes de la imagen fotoacústica y su evolución en los últimos años.

2.1.1. Principios Físicos y Tecnológicos

El efecto fotoacústico, descubierto por Alexander Graham Bell en 1880, se fundamenta en la generación de ondas acústicas mediante la absorción de energía electromagnética pulsada [3]. En el contexto de imagen médica, este fenómeno permite obtener información tanto estructural como funcional del tejido biológico [35]. La técnica combina la alta resolución espacial de los ultrasonidos con el alto contraste de la imagen óptica, superando las limitaciones individuales de ambas modalidades [32].

Los sistemas modernos de imagen fotoacústica utilizan láseres pulsados de nanosegundos para generar ondas ultrasónicas en el tejido [17]. La absorción de energía lumínica produce una expansión termoelástica local que genera ondas de presión detectables mediante transductores ultrasónicos [33]. Esta información se procesa posteriormente para reconstruir la distribución espacial de los absorbentes ópticos en el tejido (ver Figura 2.1).




Figura 2.1: Efecto fotoacústico.

Las aplicaciones clínicas actuales incluyen la detección temprana de cáncer, imagen funcional cerebral, y caracterización vascular, entre otras [13]. Los avances recientes en tecnología de sensores y sistemas de adquisición han mejorado significativamente la calidad y velocidad de adquisición de datos fotoacústicos [39].

2.1.2. Métodos Tradicionales de Reconstrucción

Los métodos convencionales de reconstrucción fotoacústica se pueden clasificar en tres categorías principales [14]:

Los métodos analíticos, como la retroproyección filtrada y las técnicas de transformada de Fourier, proporcionan soluciones directas basadas en la ecuación de onda fotoacústica [34]. Estos métodos son computacionalmente eficientes pero pueden generar artefactos significativos en condiciones no ideales.

Los métodos iterativos, incluyendo técnicas de optimización variacional y métodos algebraicos, ofrecen mayor flexibilidad para incorporar información a priori y restricciones físicas [11]. Sin embargo, su alto costo computacional limita su aplicabilidad en escenarios clínicos en tiempo real.

Los métodos basados en modelos incorporan explícitamente la física del problema mediante simulaciones numéricas detalladas [4]. Aunque precisos, estos métodos requieren un conocimiento exacto de los parámetros físicos del medio y son computacionalmente intensivos.

2.2. Importancia de la Consistencia Física en Reconstrucción Fotoacústica

La consistencia física en la reconstrucción de imágenes fotoacústicas ha emergido como un aspecto crítico para obtener resultados robustos y fiables [8]. Esta importancia se fundamenta en múltiples aspectos que impactan tanto la calidad de la reconstrucción como la fiabilidad del resultado para aplicaciones prácticas.

2.2.1. Naturaleza del Problema Inverso

El problema inverso fotoacústico es inherentemente mal condicionado [31], lo que significa que pequeñas perturbaciones en los datos de entrada (señales acústicas) pueden resultar en grandes variaciones en la solución. La incorporación de restricciones físicas actúa como una forma natural de regularización [2], ayudando a:

- Reducir el espacio de soluciones posibles a aquellas que son físicamente plausibles.
- Estabilizar el proceso de reconstrucción frente al ruido y las incertidumbres en las mediciones [1].
- Mejorar la unicidad de la solución al incorporar información a priori sobre el comportamiento físico del sistema.

2.2.2. Garantías de Validez y Robustez

La consistencia física proporciona garantías importantes sobre la validez de las reconstrucciones [26]:

- Asegura que las imágenes reconstruidas no solo sean visualmente plausibles, sino que también representen estados físicamente posibles del sistema.
- Permite verificar que la reconstrucción obedece las leyes fundamentales de la fotoacústica, como la ecuación de onda y las condiciones de contorno [28].
- Mejora la robustez del método, especialmente en casos con datos limitados o ruidosos [7].

2.2.3. Ventajas en el Aprendizaje Profundo

En el contexto del aprendizaje profundo, la incorporación de la física ofrece ventajas significativas [22]:

- Reduce la dependencia de grandes conjuntos de datos de entrenamiento al incorporar conocimiento previo sobre la física del problema [10].
- Proporciona una guía natural para el proceso de optimización, ayudando a la red a converger a soluciones más significativas [41].
- Permite detectar y corregir reconstrucciones que, aunque visualmente plausibles, violan las leyes físicas fundamentales del sistema.

2.3. Deep Learning en Reconstrucción de Imágenes Fotoacústicas

El aprendizaje profundo ha demostrado un éxito extraordinario en reconstrucción de imágenes fotoacústicas, particularmente con la arquitectura U-Net. Sin embargo, un desafío fundamental persiste: cómo incorporar efectivamente el conocimiento físico del problema en el proceso de aprendizaje.

2.3.1. Evolución de Métodos de Reconstrucción con Deep Learning

Las primeras aproximaciones utilizaban redes neuronales como post-procesamiento para mejorar imágenes reconstruidas con métodos tradicionales. Sin embargo, trabajos recientes como el de Guan et al. [5], han demostrado que las arquitecturas densamente conectadas pueden abordar directamente el problema de reconstrucción, especialmente en casos de muestreo disperso donde los métodos tradicionales generan artefactos significativos.

2.3.2. Incorporación de Física en Redes Neuronales

La incorporación de conocimiento físico en redes neuronales ha seguido principalmente dos enfoques:

- **Physics-Informed Neural Networks (PINNs):** Incorporan directamente las ecuaciones diferenciales en la función de pérdida. Sin embargo, como se discute en [40], estos métodos pueden enfrentar desafíos durante el entrenamiento debido al desbalance entre los términos de pérdida física y de datos.
- **Data-Guided Physics-Informed Approaches:** Propuestos más recientemente, estos métodos buscan un balance entre el aprendizaje basado en datos y las restricciones físicas. El trabajo de Zhou et al. [40] introduce un marco de trabajo en dos fases que primero optimiza la pérdida de datos y luego incorpora gradualmente las restricciones físicas.

2.3.3. Desafíos en la Incorporación de Física

La incorporación de restricciones físicas en redes neuronales para reconstrucción fotoacústica presenta varios desafíos únicos:

- **Complejidad Computacional:** Los métodos PINN tradicionales requieren la evaluación de derivadas durante el entrenamiento, lo que aumenta significativamente el costo computacional.
- **Balance de Pérdidas:** Como se evidencia en [40], mantener un balance adecuado entre la pérdida de datos y las restricciones físicas es crucial para el entrenamiento efectivo.
- **Naturaleza Mal Condicionada:** El problema inverso en fotoacústica es inherentemente mal condicionado, lo que complica la incorporación de restricciones físicas.

2.4. Limitaciones y Desafíos Actuales

Los métodos actuales de incorporación de física en redes neuronales enfrentan varios desafíos:

- **Eficiencia Computacional:** Los PINN tradicionales son computacionalmente costosos, limitando su aplicabilidad en escenarios clínicos.
- **Generalización:** La mayoría de los conjuntos de datos son simulados, planteando preguntas sobre la generalización a casos reales.
- **Validación:** La evaluación de la consistencia física en las reconstrucciones requiere métricas específicas que van más allá de las medidas de calidad de imagen tradicionales.

Estos desafíos motivan la búsqueda de nuevos enfoques que puedan mantener la consistencia física mientras son computacionalmente eficientes y robustos en aplicaciones reales.

Capítulo 3

Metodología

En esta sección se presenta la metodología de este trabajo tanto teórica como experimental. Partiendo desde la matemática del problema hasta la arquitectura de las redes neuronales utilizadas. En esta sección se presenta la metodología de este trabajo tanto teórica como experimental. Partiendo desde la matemática del problema hasta la arquitectura de las redes neuronales utilizadas. Se describen las variables de estudio, las métricas de evaluación y el proceso de entrenamiento.

3.1. Fundamentos Teóricos

Primero comenzamos por entender el problema físico subyacente y por qué es importante tener en cuenta la consistencia física en la reconstrucción de imágenes fotoacústicas y cómo es que esta consistencia física puede ayudar a nuestra red neuronal a aprender de manera más eficiente y a obtener mejores resultados.

La solución del problema inverso del efecto fotoacústico es una función de distribución a la cual llamamos imagen. Existen dos métodos muy populares para resolver el problema inverso: "Time Reversal" "Back Projection", los cuales se derivan de suposiciones físicas y matemáticas, lo cual es conocido como DAS (Delay and Sum).

3.1.1. Efecto Fotoacústico

El efecto fotoacústico es la generación de una onda ultrasónica que es producida por un material fotosensible al ser iluminado por un pulso de luz.

La generación y propagación de la onda fotoacústica es modelada por la ecuación para un fluido ideal y está muy bien descrita por el acoplamiento de la ecuación de difusión de calor para la variación de temperatura $T(\mathbf{x}, t)$ (ec. 3.1) y la ecuación de onda acústica para la presión $P(\mathbf{x}, t)$ (ec. 3.2).

$$(\chi \nabla^2 - \frac{\partial}{\partial t})T(\mathbf{x}, t) = -\frac{1}{\rho_0 C_P} H(\mathbf{x}, t) \quad (3.1)$$

$$(\frac{1}{K_T \rho_0} \nabla^2 - \frac{\partial^2}{\partial t^2})P(\mathbf{x}, t) = -\frac{\beta}{K_T} \frac{\partial^2}{\partial t^2} T(\mathbf{x}, t) \quad (3.2)$$

donde, para la muestra, χ es la conductividad térmica, ρ_0 es la densidad, C_P es el calor específico, $H(\mathbf{x}, t)$ es la densidad de energía electromagnética por unidad de tiempo absorbida por la muestra, K_T es el coeficiente de compresibilidad térmica, y β es el coeficiente de expansión térmica.

La densidad de energía electromagnética $H(\mathbf{x}, t)$ es modelada como:

$$H(\mathbf{x}', t) = \mu(\mathbf{x}', t)\phi(\mathbf{x}', t) \quad (3.3)$$

donde $\mathbf{x}'$ es la posición de la fuente de la onda, $\mu(\mathbf{x}', t)$ es el coeficiente de absorción óptico de la muestra y $\phi(\mathbf{x}', t)$ es la tasa de fluencia del pulso láser. La tasa de fluencia puede ser descrita como el producto de la intensidad $I(\mathbf{x}')$ y el perfil temporal $\theta(t)$ del pulso láser $\phi(\mathbf{x}', t) = I(\mathbf{x}')\theta(t)$.

3.1.2. Ecuación de Onda Fotoacústica

La ecuación de onda fotoacústica modela la propagación de la onda acústica generada $P(\mathbf{x}, t)$ producida por la expansión termoelástica de la muestra.

Esta ecuación se obtiene desacoplando las ecuaciones 3.1 y 3.2. Existen suposiciones físicas acerca del medio donde la onda se propaga, como la viscosidad, la absorción acústica es ignorada, la variación de la presión y densidad son pequeñas comparadas a los valores iniciales y la velocidad de las partículas es menor que la velocidad del sonido entre otras, que permiten simplificar la ecuación de onda acústica a:

$$\left[\nabla^2 p - \frac{1}{c^2} \frac{\partial^2}{\partial t^2} \right] P(\mathbf{x}, t) = -\frac{\beta}{C_p} \frac{\partial H}{\partial t} \quad (3.4)$$

donde c es la velocidad del sonido en el medio de propagación, y es definida como $c = \left(K_T \rho_0 \frac{\beta^2 T_0}{C_P} \right)^{-1}$.

3.1.3. Problema Inverso del Efecto Fotoacústico

El problema inverso fotoacústico (PA) implica resolver un problema de valor en la frontera para la ecuación de onda PA. La solución proporciona la distribución espacial de la absorción electromagnética durante el proceso de expansión termoelástica.

Para definir el problema inverso PA, se asume que la densidad de energía electromagnética absorbida por la muestra, $H(\mathbf{x}', t)$, es separable en componentes espaciales y temporales:

$$H(\mathbf{x}', t) = h_x(\mathbf{x}')h_t(t). \quad (3.5)$$

Para un tiempo de iluminación τ_p corto (tal que $\tau_p \ll 1/\mu c$), la función temporal puede aproximarse mediante una función delta de Dirac:

$$h_t \rightarrow \delta(t) \quad \text{cuando} \quad \Delta T \rightarrow 0. \quad (3.6)$$

Esta condición, conocida como la *condición de confinamiento de estrés*, asume que la transferencia de calor ocurre antes de que haya cambios significativos en la densidad de masa.

Cuando la muestra absorbe energía electromagnética, las variaciones de temperatura inducen cambios en la densidad de masa y la presión. Utilizando relaciones termodinámicas, la distribución de presión inicial se expresa como:

$$P|_{t=0} = \frac{\beta}{K_T} T|_{t=0} = \Gamma h_x, \quad (3.7)$$

donde Γ es el parámetro de Grüneisen, que describe la eficiencia del proceso de conversión de calor a presión.

Para imponer el confinamiento de estrés y la distribución inicial de presión, se resuelve la ecuación de onda con un término fuente:

$$\left[\nabla^2 - \frac{1}{c^2} \frac{\partial^2}{\partial t^2} \right] P = 0, \quad \text{con} \quad P(\mathbf{x}, 0) = \Gamma h_x, \quad \frac{\partial P}{\partial t} \Big|_{t=0} = 0. \quad (3.8)$$

El problema inverso PA se formula utilizando condiciones de frontera en una superficie de observación S donde se miden los valores de presión:

$$\left[\nabla^2 - \frac{1}{c^2} \frac{\partial^2}{\partial t^2} \right] P(\mathbf{x}, t) = 0, \quad t \geq 0, \quad (3.9)$$

$$P(\mathbf{x}', 0) = f(\mathbf{x}'), \quad \frac{\partial P}{\partial t} \Big|_{t=0} = 0, \quad (3.10)$$

$$P(\mathbf{x}_S, t) = g(\mathbf{x}_S, t), \quad \mathbf{x}_S \in S, \quad t \geq 0. \quad (3.11)$$

El objetivo es determinar la distribución de presión inicial $f(\mathbf{x}')$ a partir de los datos de frontera $g(\mathbf{x}_S, t)$. Esta distribución representa la imagen PA.

Los supuestos matemáticos para garantizar la resolubilidad incluyen:

- La fuente está contenida dentro de S .
- No existen fuentes PA externas.
- La ecuación de onda es válida en todo el espacio.

Debido a la naturaleza termodinámica del efecto fotoacústico, el problema inverso PA es mal condicionado, lo que ha llevado al desarrollo de métodos de regularización, entre otros.

3.1.4. Deep Learning en Reconstrucción Fotoacústica

El uso de redes neuronales profundas en la reconstrucción de imágenes fotoacústicas se ha implementado de diferentes formas, tanto complementando una reconstrucción inicial con métodos clásicos como el DAS y removiendo los artefactos que este genera [5], como también desde cero, tomando datos en crudo y generando imágenes a partir de estos [36].

Muchos de estos trabajos usan la popular arquitectura U-Net [24] para la reconstrucción de imágenes, la cual ha demostrado ser muy efectiva en la reconstrucción de imágenes en diferentes campos de la ciencia. Sin embargo, la mayoría de estos trabajos no toman en cuenta la consistencia física de las imágenes reconstruidas, sin contar aquellos que complementan deep learning con métodos clásicos.

La consistencia física, si bien no parece ser un problema al momento de reconstruir la imagen a partir de la onda acústica, puede ser usada para enseñar a la red a realizar la reconstrucción de manera más eficiente y con mejores resultados, ya que la red puede aprender de manera implícita las características físicas del problema.

Como ya mencioné, el problema inverso del efecto fotoacústico es mal condicionado. Se han desarrollado métodos de aprendizaje profundo para resolver este tipo de problemas como los Physics Informed Neural Networks (PINNs) [21] que son redes neuronales que son entrenadas para resolver ecuaciones diferenciales parciales. Sin embargo, estos métodos no han sido aplicados en la reconstrucción de imágenes fotoacústicas directamente; si bien lo que hacen es poder encontrar los parámetros de una ecuación diferencial parcial, no se ha aplicado directamente a la reconstrucción de imágenes. Sin embargo, enfoques interesantes han surgido a partir de esta idea, como hacer un fine-tuning de una red ya preentrenada primero minimizando puramente la pérdida relacionada a los datos, después minimizando las pérdidas relacionadas tanto a los datos como a la pérdida residual de la PDE [40]. Sin embargo, como mencioné, estos trabajos no se concentran principalmente en la reconstrucción de las imágenes fotoacústicas, pero sí dan un sentido de cómo se puede incorporar la física en las redes neuronales haciendo el preentrenamiento de la red con datos y después con la física, mejorando las soluciones para problemas inversos mal condicionados.

3.2. Enfoque Propuesto

El método propuesto se basa en un enfoque dual que combina dos redes neuronales U-Net con roles complementarios: una red reconstructora y una red supervisora. Este diseño está motivado por la necesidad de incorporar consistencia física en el proceso de reconstrucción de imágenes fotoacústicas. La arquitectura general se muestra en la Figura 3.1.

La red reconstructora tiene como objetivo principal transformar las señales acústicas medidas (S) en imágenes fotoacústicas ($\hat{I}$), mientras que la red supervisora actúa como un evaluador físico, aprendiendo a simular el proceso de generación de señales acústicas a partir de una imagen dada. La clave de este enfoque es el entrenamiento en dos fases: un preentrenamiento individual de cada red seguido de un proceso de fine-tuning que incorpora la supervisión física.

3.2.1. Arquitectura del Sistema

Ambas redes siguen una arquitectura U-Net modificada que consiste en:

- Un codificador (Encoder) que extrae características relevantes de la entrada
- Un cuello de botella (Bottleneck) que comprime la información
- Un decodificador (Decoder) que reconstruye la salida deseada

3.2.2. Preentrenamiento Individual

El preentrenamiento se realiza de manera independiente para cada red, estableciendo las capacidades básicas necesarias para el proceso de fine-tuning posterior.




Figura 3.1: Arquitectura de la red propuesta. La red reconstructora se entrena para aprender el mapeo directo de señales acústicas a imágenes fotoacústicas. La red supervisora se entrena para emular el proceso físico de generación de señales acústicas a partir de una imagen dada. Durante el proceso de fine-tuning, la red reconstructora se entrena para generar imágenes que, al ser procesadas por la red supervisora, produzcan señales acústicas consistentes con las mediciones originales.

Red Reconstructora

La red reconstructora se entrena para aprender el mapeo directo de señales acústicas a imágenes fotoacústicas. Durante esta fase, la red optimiza:

$$\mathcal{L}_A = \text{MSE}(\hat{I}, I) \quad (3.12)$$

donde $\hat{I}$ es la imagen reconstruida y I es la imagen objetivo. Esta pérdida asegura que la red aprenda a generar reconstrucciones visualmente precisas.

Red Supervisora

La red supervisora se entrena para aproximar el proceso físico de generación de señales acústicas. Este proceso puede ser modelado como:

$$S = \mathcal{F}(I) + \epsilon \quad (3.13)$$

donde $\mathcal{F}$ representa una aproximación del operador físico de propagación fotoacústica. En la práctica, este operador encapsula las complejas relaciones descritas por las ecuaciones de onda fotoacústica presentadas en la sección 3.1. La red neuronal actúa como un aproximador universal de esta función, aprendiendo a mapear las imágenes a sus correspondientes señales acústicas sin necesidad de resolver explícitamente las ecuaciones diferenciales parciales subyacentes. El término ϵ modela tanto el ruido del sistema como los errores de aproximación inherentes a este enfoque.

La red optimiza:

$$\mathcal{L}_B = \text{MSE}(\hat{S}, S) \quad (3.14)$$

donde S_{pred} es la señal acústica predicha por la red y S_{true} es la señal acústica medida. Este entrenamiento permite a la red supervisora aprender implícitamente las características físicas del proceso fotoacústico, actuando como un simulador aprendido del sistema físico.

3.2.3. Flujo de Datos

Durante el proceso de reconstrucción, los datos fluyen de la siguiente manera:

1. La señal acústica S ingresa a la red reconstructora
2. La red reconstructora genera una imagen reconstruida $\hat{I}$
3. Esta imagen es procesada por la red supervisora para generar una señal acústica predicha $\hat{S}$
4. Las diferentes pérdidas se calculan comparando las salidas con los valores objetivo

Este diseño permite que la red reconstructora aprenda no solo de la comparación directa con las imágenes objetivo, sino también de la retroalimentación proporcionada por la red supervisora a través de la consistencia física de las señales acústicas generadas.

3.2.4. Fine-tuning con Supervisión Física

El proceso de fine-tuning se realiza sobre la red reestructora previamente entrenada, incorporando un mecanismo de supervisión física a través de la red supervisora. Este proceso está diseñado para asegurar que las imágenes reconstruidas no solo sean visualmente precisas, sino que también mantengan consistencia con las propiedades físicas del sistema fotoacústico.

La estructura del fine-tuning involucra cuatro términos de pérdida complementarios:

$$\mathcal{L}_{total} = \lambda_1 \mathcal{L}_{recon} + \lambda_2 \mathcal{L}_{physics} + \lambda_3 \mathcal{L}_{struct} + \lambda_4 \mathcal{P}_{sim} \quad (3.15)$$

donde:

- $\mathcal{L}_{recon}$ mide la discrepancia entre la imagen reconstruida $\hat{I}$ y la imagen objetivo I :

$$\mathcal{L}_{recon} = \text{MSE}(\hat{I}, I) \quad (3.16)$$

- $\mathcal{L}_{physics}$ evalúa la consistencia física comparando la señal acústica predicha $\hat{S}$ con la señal real S :

$$\mathcal{L}_{physics} = \text{MSE}(\hat{S}, S) \quad (3.17)$$

- $\mathcal{L}_{struct}$ preserva las características estructurales de la imagen:

$$\mathcal{L}_{struct} = 1 - \text{SSIM}(\hat{I}, I) \quad (3.18)$$

- $\mathcal{P}_{sim}$ es un término de penalización que previene que la red tome atajos durante el aprendizaje:

$$\mathcal{P}_{sim} = \text{cos_similarity}(\hat{I}, S) \quad (3.19)$$

Los coeficientes λ_i ponderan la contribución de cada término en la pérdida total. Durante el fine-tuning, la red supervisora se mantiene con sus pesos congelados, actuando como un evaluador fijo de la consistencia física de las reconstrucciones. Esta red toma la imagen reconstruida $\hat{I}$ y genera una predicción de la señal acústica $\hat{S}$ que debería producir dicha imagen.

El término $\mathcal{L}_{physics}$ es particularmente importante ya que fuerza a la red reestructora a generar imágenes que, cuando son procesadas por la red supervisora, producen señales acústicas consistentes con las mediciones originales. Esto asegura que la reconstrucción no solo sea visualmente precisa ($\mathcal{L}_{recon}$ y $\mathcal{L}_{struct}$) sino que también respete las propiedades físicas del sistema fotoacústico.

El término de penalización $\mathcal{P}_{sim}$ es crucial para evitar que la red tome atajos en el proceso de aprendizaje. Sin esta penalización, la red podría tender a generar imágenes que son similares a las señales de entrada, lo cual produciría señales acústicas similares a las originales (minimizando $\mathcal{L}_{physics}$) pero no representaría una reconstrucción válida del objeto original.

Este enfoque de fine-tuning permite que la red reestructora refine sus predicciones incorporando conocimiento físico del sistema, mientras mantiene la calidad visual y estructural de las reconstrucciones. La combinación de los diferentes términos de pérdida asegura un balance entre la fidelidad de la reconstrucción y la consistencia física del resultado.

Capítulo 4

Implementación

Esta sección describe los detalles de la implementación del modelo del modelo U-Net para la reconstrucción de imágenes fotoacústicas. Se incluyen las especificaciones técnicas, hiperparámetros de entrenamiento, pipeline de entrenamiento y validación y pruebas realizadas.

4.1. Especificaciones Técnicas

Para la implementación del modelo U-Net se utilizó el framework de programación PyTorch. La implementación se realizó en Python 3.8.5 y se utilizó la versión 1.7.1 de PyTorch. El código fuente se encuentra disponible en el repositorio de GitHub.

4.1.1. Arquitectura del Sistema

Sección	Capa	Operación	Canales (in/out)
Encoder	enc1	Double Conv + ReLU	$1 \rightarrow 64$
	enc2	MaxPool + Double Conv + ReLU	$64 \rightarrow 128$
	enc3	MaxPool + Double Conv + ReLU	$128 \rightarrow 256$
	enc4	MaxPool + Double Conv + ReLU	$256 \rightarrow 512$
Bottleneck	bottleneck	MaxPool + Double Conv + ReLU	$512 \rightarrow 1024$
Decoder	dec4	ConvTranspose + Concat + Double Conv	$(1024+512) \rightarrow 512$
	dec3	ConvTranspose + Concat + Double Conv	$(512+256) \rightarrow 256$
	dec2	ConvTranspose + Concat + Double Conv	$(256+128) \rightarrow 128$
	dec1	ConvTranspose + Concat + Double Conv	$(128+64) \rightarrow 64$
Salida	final	Conv 1x1	$64 \rightarrow 1$

Cuadro 4.1: Arquitectura del modelo U-Net. Cada 'Double Conv' consiste en dos capas convolucionales 3x3 seguidas de BatchNorm y ReLU. Las operaciones ConvTranspose tienen kernel 2x2 y stride 2.

4.1.2. Hiperparámetros de Entrenamiento

Ya que el proceso está dividido en dos partes, preentrenamiento y fine-tuning, a continuación se presentan los hiperparámetros utilizados en el entrenamiento del modelo U-Net.

Preentrenamiento

El preentrenamiento tanto de la red constructora como la red supervisora se realizó con los siguientes hiperparámetros:

Hiperparámetro	Valor
Optimizador	Adam
Learning rate inicial	0.001
Batch size	Determinado por dataloader
Número de épocas	150 (default)
Scheduler	ReduceLROnPlateau
Scheduler patience	5 épocas
Scheduler factor	0.5
Función de pérdida	MSE

Cuadro 4.2: Hiperparámetros utilizados en el entrenamiento del modelo

Fine-tuning

Para el fine-tuning de la red constructora se utilizó el siguiente conjunto de hiperparámetros:

Hiperparámetro	Valor
Optimizador	Adam
Learning rate inicial	0.001
Número de épocas	100 (default)
Scheduler	ReduceLROnPlateau
Scheduler patience	5 épocas
Scheduler factor	0.5
Función de pérdida	MSE + Pérdida estructural + Pérdida física + Penalización similitud
Pesos de las pérdidas	
λ_{direct}	1.0
$\lambda_{physical}$	0.1
λ_{struct}	2.0
$\lambda_{similarity}$	0.3
Otros	
Gradiente clipping	1.0
Seed	42

Cuadro 4.3: Hiperparámetros del entrenamiento supervisado

4.2. Pipeline de Entrenamiento

El pipeline de entrenamiento se dividió en dos fases: preentrenamiento y fine-tuning. Cada fase se realizó de manera independiente para las redes constructora y supervisora. A continuación se describen los detalles de cada fase.

4.2.1. Obtención de Datos

La obtención de datos experimentales fotoacústicos es un proceso complejo y costoso. Por ello, se implementó un pipeline de datos simulados para el preentrenamiento y fine-tuning del modelo. Este proceso involucra la generación de imágenes sintéticas y el cálculo de sus correspondientes señales fotoacústicas mediante un modelo físico (detallado en el Apéndice). Este enfoque permitió generar un conjunto de datos robusto para el entrenamiento y validación del modelo.

4.2.2. Preentrenamiento

El proceso de preentrenamiento se realizó de manera independiente para las redes constructora y supervisora:

- **Red Constructora:** Se utilizó un conjunto de 5000 pares de imágenes simuladas de 128×128 píxeles.
- **Red Supervisora:** Se emplearon 5000 pares de imágenes (128×128 píxeles) y sus correspondientes señales fotoacústicas.

En ambos casos, se implementó una división del dataset: 80 % para entrenamiento y 20 % para validación.

4.2.3. Fine-tuning

La fase de fine-tuning mantuvo la misma estructura de datos que el preentrenamiento, utilizando 5000 imágenes simuladas para cada red. La distribución del conjunto de datos se mantuvo en 80 % para entrenamiento y 20 % para validación, permitiendo una optimización específica de los pesos previamente entrenados.

4.3. Métricas de Evaluación

Para evaluar exhaustivamente el desempeño del modelo, utilizaremos métricas que cubren diferentes aspectos de la calidad de reconstrucción, eficiencia y significancia estadística:

4.3.1. Calidad de Reconstrucción

La calidad de las imágenes reconstruidas se evaluará mediante las siguientes métricas:

- **Peak Signal-to-Noise Ratio (PSNR):** Mide la relación entre la máxima potencia posible de una señal y el ruido que afecta a su representación. Un PSNR más alto indica una mejor calidad de reconstrucción.
- **Normalized Root Mean Square Error (NRMSE):** Cuantifica la diferencia entre los valores predichos y observados, normalizada para facilitar comparaciones entre diferentes escalas de datos.

- **Structural Similarity Index (SSIM):** Evalúa la similitud estructural entre las imágenes reconstruidas y las originales, considerando luminancia, contraste y estructura.
- **Mean Absolute Error (MAE):** Proporciona una medida directa de la diferencia absoluta entre los valores predichos y reales.

4.3.2. Rendimiento Computacional

El rendimiento computacional se evaluará considerando:

- **Tiempo de Reconstrucción:** Medido en milisegundos por imagen, evaluando la eficiencia computacional del modelo en inferencia.
- **Uso de Memoria:** Cuantifica los recursos computacionales requeridos durante la reconstrucción.
- **FLOPs:** Mide el número de operaciones de punto flotante, proporcionando una métrica independiente del hardware para la complejidad computacional.

4.3.3. Análisis Estadístico

Para validar la significancia y robustez de los resultados, implementaremos:

- **Pruebas de Significancia:** Se utilizará la prueba t-pareada para comparar el rendimiento entre el preentrenamiento y fine-tuning, estableciendo un nivel de significancia $\alpha = 0,05$.
- **Intervalos de Confianza:** Se calcularán intervalos de confianza del 95
- **Pruebas de Normalidad:** Se aplicará el test Shapiro-Wilk para verificar la normalidad en la distribución de los errores de reconstrucción, validando los supuestos estadísticos de nuestros análisis.

Este conjunto integral de métricas nos permitirá evaluar no solo la calidad de las reconstrucciones y la eficiencia computacional, sino también la significancia estadística de las mejoras observadas, proporcionando una base sólida para la comparación con otros métodos de reconstrucción.

Capítulo 5

Experimentos y Resultados

5.1. Experimentos y Resultados

Esta sección presenta la evaluación experimental de la estrategia de entrenamiento propuesta basada en redes duales con supervisión física. Los experimentos están diseñados para demostrar cómo esta metodología mejora el proceso de aprendizaje y conduce a soluciones más robustas, utilizando la reconstrucción fotoacústica como caso de estudio.

5.1.1. Diseño Experimental

Conjunto de Datos

Para la experimentación se utilizó un conjunto de datos sintético derivado de imágenes de vasos sanguíneos de retina. El procedimiento de generación de datos consistió en:

- Selección de un dataset público de imágenes de retina con diferentes patrones vasculares
- Ampliación mediante técnicas de aumento de datos hasta obtener 13,000 muestras
- Generación de señales fotoacústicas correspondientes utilizando el modelo físico de espacio de estados propuesto por Lang et al. [15]

Este enfoque permitió crear un conjunto de datos de entrenamiento suficientemente grande mientras se mantenía la consistencia física entre las imágenes y sus correspondientes señales fotoacústicas.

Configuración de Experimentos

Se diseñaron experimentos para evaluar sistemáticamente la efectividad de la estrategia de entrenamiento propuesta y la contribución de cada componente de la función de pérdida. La Tabla 5.1 muestra las configuraciones utilizadas.

Experimento	λ_{direct}	$\lambda_{physical}$	λ_{struct}	$\lambda_{similarity}$	Propósito del Experimento
Baseline	1.0	0.1	2.0	0.3	Evaluar el rendimiento del modelo pre-entrenado sin fine-tuning
FT Completo	1.0	0.1	2.0	0.3	Evaluar la estrategia completa de entrenamiento dual con fine-tuning supervisado físicamente
FT No-Struct	1.0	0.1	0.0	0.3	Analizar el impacto de la ausencia de la componente estructural en la transferencia de conocimiento
FT No-Physical	1.0	0.0	2.0	0.3	Determinar la contribución específica de la supervisión física en el proceso de fine-tuning

Cuadro 5.1: Configuraciones experimentales para evaluar la estrategia de entrenamiento propuesta y sus componentes.

Métricas de Evaluación

Para evaluar comprehensivamente los diferentes aspectos de la estrategia de entrenamiento, se utilizaron las siguientes métricas:


- **Métricas de calidad de reconstrucción:** MSE, MAE, NRMSE, PSNR, SSIM
- **Métricas de eficiencia de entrenamiento:** Curvas de convergencia, estabilidad del entrenamiento
- **Métricas de transferencia de conocimiento:** Análisis de la evolución de las diferentes componentes de pérdida
- **Análisis estadístico:** Pruebas de significancia (t pareada, Wilcoxon) y tamaño del efecto (d de Cohen)

5.1.2. Análisis del Proceso de Entrenamiento Dual


Esta sección analiza el comportamiento de la estrategia de entrenamiento propuesta, centrándose en cómo cada fase contribuye al proceso de aprendizaje.

Dinámica del Preentrenamiento

Fase 1: Adquisición de Capacidades Básicas Se analiza primero el preentrenamiento independiente de cada red para establecer sus capacidades fundamentales.



(a) Red reconstructora



(b) Red supervisora

Figura 5.1: Evolución de las pérdidas durante el preentrenamiento independiente de las redes duales. Nótese las diferentes dinámicas de convergencia: la red reconstructora (a) muestra una convergencia más estable y una brecha menor entre las pérdidas de entrenamiento y validación, mientras que la red supervisora (b) presenta más fluctuaciones y una brecha más pronunciada, indicando la mayor complejidad del problema físico inverso.

Análisis Comparativo de Estabilidad Las dinámicas de aprendizaje de ambas redes revelan diferencias significativas:

- **Red reconstructora:** Muestra una convergencia rápida y estable, con la pérdida disminuyendo de 0.015 a 0.0005 MSE en aproximadamente 80 épocas. La proximidad entre las curvas de entrenamiento y validación indica una excelente generalización.
- **Red supervisora:** Presenta mayor variabilidad en la convergencia, con fluctuaciones considerables en la curva de validación y una brecha persistente entre las pérdidas de entrenamiento y validación. Este comportamiento refleja la mayor complejidad inherente a modelar el proceso físico fotoacústico.

Esta diferencia en las dinámicas de entrenamiento subraya la asimetría fundamental entre los problemas directo e inverso en este dominio, y justifica el enfoque de entrenamiento dual propuesto.

Dinámica de Transferencia de Conocimiento en el Fine-tuning

Evolución de la Supervisión Física La Figura 5.2 muestra la evolución de las diferentes componentes de pérdida durante el fine-tuning con supervisión física.




Figura 5.2: Evolución de las componentes de pérdida durante el fine-tuning completo. Obsérvese cómo la pérdida física inicialmente alta se reduce progresivamente mientras la red aprende a incorporar el conocimiento físico sin comprometer la calidad de reconstrucción directa.

La dinámica del fine-tuning revela un patrón de transferencia de conocimiento secuencial:

- **Fase inicial (épocas 1-20):** Alta volatilidad en la pérdida física ($\sim 0.4-0.5$) mientras la red comienza a incorporar las restricciones físicas, manteniendo estable la pérdida directa.
- **Fase de estabilización (épocas 20-60):** Reducción gradual y más estable de la pérdida física hasta ~ 0.2 , indicando que la red está aprendiendo a balancear las restricciones físicas con la calidad visual.
- **Fase de convergencia (épocas 60-100):** Estabilización de todas las componentes de pérdida, con la pérdida física convergiendo a ~ 0.13 , demostrando un equilibrio efectivo entre reconstrucción visual y consistencia física.

Este patrón de evolución demuestra cómo la estrategia de fine-tuning facilita una transferencia gradual y efectiva del conocimiento físico a la red reconstructora.

Análisis de Radar Multimétrica Para visualizar holísticamente el impacto del proceso de fine-tuning en todas las métricas simultáneamente, se propone el siguiente diagrama de radar:

[AQUÍ GRÁFICA DE RADAR PROPUESTA: Representación de todas las métricas (MSE, MAE, NRMSE, PSNR, SSIM) para los diferentes modelos (Baseline, FT completo, FT No-Physical, FT No-Structural) en un solo diagrama de radar, permitiendo una comparación visual inmediata del rendimiento global]

5.1.3. Contribución de Componentes Específicos en la Estrategia de Entrenamiento

Esta sección analiza experimentalmente la contribución individual de cada componente clave de la función de pérdida, proporcionando evidencia empírica sobre su rol en la estrategia de entrenamiento propuesta.

Impacto del Componente de Supervisión Física



(a) Evolución de pérdidas sin componente física

[GRÁFICA PROPUESTA: Comparación de señales fotoacústicas reconstruidas]

(b) Señales fotoacústicas reconstruidas


Figura 5.3: Análisis del impacto de la supervisión física en el proceso de fine-tuning. (a) Evolución de las pérdidas al eliminar la componente física, mostrando un comportamiento significativamente diferente. (b) Comparación directa de las señales fotoacústicas reconstruidas por los diferentes modelos, evidenciando la mejora en la consistencia física.

La eliminación del componente físico ($\lambda_{physical} = 0$) revela su papel fundamental en la estrategia de entrenamiento:

- Sin la guía física, la pérdida estructural domina el proceso de aprendizaje, alcanzando picos aproximadamente 4 veces mayores que en el modelo completo
- El MSE aumenta en un 12.69 % y el PSNR disminuye en 0.62 dB respecto al modelo pre-entrenado
- Análisis estadístico confirma que este deterioro es significativo ($t = -11,9974$, $p < 0,001$)
- La morfología de las señales fotoacústicas reconstruidas muestra inconsistencias físicas evidentes [REFERENCIA A GRÁFICA PROPUESTA]

Estos resultados demuestran que la supervisión física actúa como un regularizador natural que guía la red hacia soluciones físicamente plausibles, previniendo el sobreajuste a características puramente visuales.

Rol del Componente Estructural en la Transferencia de Conocimiento



(a) Evolución de pérdidas sin componente estructural

[GRÁFICA PROPUESTA: Mapa de calor de SSIM regional]

(b) Mapa de calor de SSIM por regiones

Figura 5.4: Análisis del impacto del componente estructural en la estrategia de entrenamiento. (a) Evolución de las pérdidas al eliminar la componente estructural, mostrando una dinámica altamente inestable con valores de pérdida física iniciales extremadamente altos. (b) Mapa de calor de SSIM regional comparando los diferentes modelos, revelando patrones de deterioro estructural específicos cuando se elimina esta componente.

La ablación del componente estructural ($\lambda_{struct} = 0$) revela consecuencias dramáticas:

- Un aumento inmediato y sustancial en la pérdida física (valores cercanos a 2.0 inicialmente)
- Una degradación del 307.08 % en MAE y una caída catastrófica en el SSIM (de 0.9658 a 0.6257)
- Pérdida de detalles finos y características estructurales en las imágenes reconstruidas, particularmente en zonas de alta frecuencia espacial [REFERENCIA A MAPA DE CALOR PROPUESTO]
- El tamaño del efecto extremadamente grande (d de Cohen = 4.5827 para SSIM) confirma la importancia crítica de esta componente

Estos resultados demuestran que el componente estructural no solo mejora la calidad visual, sino que también facilita la incorporación efectiva del conocimiento físico al proporcionar restricciones complementarias que estabilizan el proceso de aprendizaje.

5.1.4. Análisis Comparativo Integral

Perfil de Mejora Multimétrico

[GRÁFICA PROPUESTA: Gráfica de barras comparativa mostrando la mejora/deterioro porcentual en todas las métricas para cada configuración experimental, tomando el modelo Baseline como referencia]

Figura 5.5: Análisis comparativo del porcentaje de mejora/deterioro en las diferentes métricas para cada configuración experimental, tomando como referencia el modelo pre-entrenado (Baseline). Las barras positivas indican mejora, mientras que las negativas representan deterioro.

La Tabla 5.2 presenta un resumen consolidado de todas las métricas evaluadas en los diferentes experimentos, facilitando una comparación integral del rendimiento.

Modelo	MSE	MAE	NRMSE	PSNR
Baseline	$8,91 \times 10^{-4} \pm 5,51 \times 10^{-4}$	$3,30 \times 10^{-3} \pm 1,28 \times 10^{-3}$	$0,0372 \pm 0,0119$	29,0
FT Completo (Mejora %)	$7,26 \times 10^{-4} \pm 4,64 \times 10^{-4}$ (18.46 %)	$2,69 \times 10^{-3} \pm 1,11 \times 10^{-3}$ (18.50 %)	$0,0334 \pm 0,0112$ (10.15 %)	30,0 (3.45 %)
FT No-Physical (Deterioro %)	$1,00 \times 10^{-3} \pm 5,90 \times 10^{-4}$ (12.69 %)	$3,98 \times 10^{-3} \pm 1,32 \times 10^{-3}$ (20.42 %)	$0,0399 \pm 0,0124$ (7.13 %)	28,4 (2.07 %)
FT No-Structural (Deterioro %)	$1,12 \times 10^{-3} \pm 5,63 \times 10^{-4}$ (25.69 %)	$1,34 \times 10^{-2} \pm 1,56 \times 10^{-3}$ (307.08 %)	$0,0430 \pm 0,0122$ (15.44 %)	27,6 (4.83 %)

Cuadro 5.2: Análisis comparativo integral de las métricas de evaluación para los diferentes modelos. Los valores en verde indican mejora porcentual respecto al modelo Baseline, mientras que los valores en rojo indican deterioro. El mejor rendimiento para cada métrica está en **negrita**.

Análisis de Dispersión de Casos

Para identificar patrones específicos en cómo los diferentes componentes de la estrategia de entrenamiento afectan a diferentes tipos de imágenes, se propone el siguiente análisis de dispersión:

[GRÁFICA PROPUESTA: Gráfica de dispersión mostrando la correlación entre la complejidad de la imagen (medida por entropía o densidad de bordes) y la mejora relativa en PSNR/SSIM para los diferentes modelos]

Este análisis permitiría identificar si la estrategia de entrenamiento propuesta es particularmente efectiva para ciertos tipos de casos (e.g., imágenes con estructuras más complejas o con determinadas características).

5.1.5. Visualización de Resultados

Ejemplos Representativos de Reconstrucción






Figura 5.6: Ejemplos de reconstrucciones obtenidas con el modelo fine-tuned completo. Se muestran: (a) Imagen original, (b) Señal fotoacústica de entrada, (c) Reconstrucción obtenida, (d) Error absoluto. Nótese la preservación de detalles estructurales finos y la consistencia en las reconstrucciones.

Análisis Comparativo Visual


La Figura 5.7 presenta una comparación visual de los resultados obtenidos con los diferentes modelos sobre casos representativos del conjunto de prueba.




(a) Modelo pre-entrenado (Baseline)



(b) Fine-tuning completo (FT)



(c) Fine-tuning sin componente física (FT No-Physical)



(d) Fine-tuning sin componente estructural (FT No-Structural)

Figura 5.7: Análisis comparativo visual de reconstrucciones obtenidas con los diferentes modelos. Obsérvese cómo: (1) El modelo con fine-tuning completo (b) mejora la nitidez y detalle respecto al baseline (a), (2) La eliminación del componente físico (c) introduce sutiles inconsistencias, y (3) La eliminación del componente estructural (d) produce degradación severa de la calidad visual.

Hallazgos Clave del Análisis Visual El análisis cualitativo de las reconstrucciones revela patrones consistentes con el análisis cuantitativo:

- El modelo con fine-tuning completo muestra una mejor definición de bordes y preservación de detalles finos
- La eliminación del componente físico produce resultados visualmente aceptables pero con sutiles inconsistencias en la distribución de intensidades
- La eliminación del componente estructural resulta en una degradación dramática, con pérdida de detalles y la introducción de artefactos visibles
- Los casos más desafiantes (estructuras finas, regiones de bajo contraste) muestran las diferencias más pronunciadas entre modelos

[GRÁFICA PROPUESTA: Mapas de activación de características intermedias en las redes duales, mostrando qué regiones de la imagen/señal están influyendo más en el proceso de reconstrucción para los diferentes modelos]

5.1.6. Análisis de Eficiencia Computacional y Práctica

Finalmente, se analiza la eficiencia computacional de la estrategia de entrenamiento propuesta en comparación con métodos alternativos, particularmente los enfoques PINN tradicionales.

[TABLA PROPUESTA: Comparación de tiempo de entrenamiento, memoria requerida y complejidad computacional (FLOPs) entre el método propuesto y alternativas como PINNs tradicionales]

Cuadro 5.3: Análisis comparativo de eficiencia computacional entre la estrategia de entrenamiento propuesta y métodos alternativos. La estrategia dual propuesta logra un balance favorable entre incorporación de física y eficiencia computacional.

Este análisis destacaría la ventaja práctica de la estrategia propuesta: lograr una incorporación efectiva del conocimiento físico sin incurrir en la sobrecarga computacional asociada a los métodos PINN tradicionales que requieren cálculo explícito de derivadas durante el entrenamiento.

Capítulo 6

Análisis y Discusión

Capítulo 7

Conclusiones y Trabajo Futuro

(this section is presently blank)

Apéndice A

Apéndice

Referencias

Bibliografía

- [1] S. Antholzer, M. Haltmeier, and J. Schwab. Deep learning for photoacoustic tomography from sparse data. *Inverse Problems in Science and Engineering*, 27(7):987–1005, 2019.
- [2] S. Arridge, P. Maass, O. Öktem, and C.-B. Schönlieb. Solving inverse problems using data-driven models. *Acta Numerica*, 2016.
- [3] A. G. Bell. On the production and reproduction of sound by light. *American Journal of Science*, 20(118):305–324, 1880.
- [4] B. Cox, J. G. Laufer, P. C. Beard, and S. R. Arridge. Challenges for quantitative photoacoustic imaging. *Proceedings of SPIE*, 7177:717713, 2009.
- [5] S. Guan, A. A. Khan, S. Sikdar, and P. V. Chitnis. Fully dense unet for 2d sparse photoacoustic tomography artifact removal. *IEEE Journal of Selected Topics in Quantum Electronics*, 2020.
- [6] B. Guo, J. Li, H. Zmuda, and M. Sheplak. Deep learning for photoacoustic imaging: A survey. *Neurocomputing*, 402:336–351, 2020.
- [7] A. Hauptmann and B. T. Cox. Deep learning in photoacoustic tomography: current approaches and future directions. *Journal of Biomedical Optics*, 25(11):112903, 2020.
- [8] A. Hauptmann, F. Lucka, M. Betsche, N. Huynh, J. Adler, B. Cox, P. Beard, S. Ourselin, and S. Arridge. Model-based learning for accelerated, limited-view 3-D photoacoustic tomography. *IEEE transactions on medical imaging*, 2018.
- [9] K. He, X. Zhang, S. Ren, and J. Sun. Deep residual learning for image recognition. *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 770–778, 2016.
- [10] M. Hoffer, A. Pourshafeie, L. Schmidt, I. Shcherbatyi, and G. Wolf. Augmented neural networks for modeling physical systems with conservation laws. *arXiv preprint arXiv:1912.04405*, 2019.
- [11] C. Huang, K. Wang, L. Nie, et al. Full-wave iterative image reconstruction in photoacoustic tomography with acoustically inhomogeneous media. *IEEE transactions on medical imaging*, 32(6):1097–1110, 2013.
- [12] G. Huang, Z. Liu, L. Van Der Maaten, and K. Q. Weinberger. Densely connected convolutional networks. *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 4700–4708, 2017.
- [13] C. Kim, T. N. Erpelding, K. Maslov, et al. Clinical photoacoustic imaging platforms. *Biomedical Engineering Letters*, 11:91–100, 2021.

- [14] P. Kuchment and L. Kunyansky. Mathematics of thermoacoustic tomography. *European Journal of Applied Mathematics*, 19(2):191–224, 2008.
- [15] O. Lang, P. Kovacs, C. Motz, M. Huemer, T. Berer, and P. Burgholzer. A linear state space model for photoacoustic imaging in an acoustic attenuating media. *arXiv preprint*, 1808.00218v1, 2017.
- [16] J.-G. Lee, S. Jun, Y.-W. Cho, H. Lee, G. B. Kim, J. B. Seo, and N. Kim. Deep learning in medical imaging: general overview. *Korean Journal of Radiology*, 20(7):1133–1142, 2019.
- [17] L. Li, L. Zhu, C. Ma, L. Lin, J. Yao, and L. V. Wang. Photoacoustic tomography: principles and advances. *Progress in Biomedical Engineering*, 3(2):022003, 2021.
- [18] C. Lutzweiler and D. Razansky. Photoacoustic imaging and tomography: Current approaches and future directions. *Current medical imaging reviews*, 10(4):305–313, 2014.
- [19] A. Maier, C. Syben, T. Lasser, and C. Riess. A gentle introduction to deep learning in medical image processing. *Zeitschrift für Medizinische Physik*, 29(2):86–101, 2019.
- [20] O. Oktay, J. Schlemper, L. L. Folgoc, M. Lee, M. Heinrich, K. Misawa, K. Mori, S. McDonagh, N. Y. Hammerla, B. Kainz, B. Glocker, and D. Rueckert. Attention U-Net: Learning where to look for the pancreas. In *Medical Imaging with Deep Learning*. MIDL, 2018.
- [21] M. Raissi, P. Perdikaris, and G. E. Karniadakis. Physics informed deep learning (Part I): Data-driven solutions of nonlinear partial differential equations. *arXiv preprint arXiv:1711.10561*, 2017.
- [22] M. Raissi, P. Perdikaris, and G. E. Karniadakis. Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations. *Journal of Computational Physics*, 2019.
- [23] A. Reiter and M. A. Lediju Bell. Current state of photoacoustic imaging. *Current opinion in biomedical engineering*, 3:94–100, 2017.
- [24] O. Ronneberger, P. Fischer, and T. Brox. U-net: Convolutional networks for biomedical image segmentation. In *International Conference on Medical Image Computing and Computer-Assisted Intervention*, volume 9351 of *Lecture Notes in Computer Science*, pages 234–241. Springer, Springer International Publishing, 2015.
- [25] J. Schlemper, O. Oktay, M. Schaap, et al. Attention gated networks: Learning to leverage salient regions in medical images. *Medical image analysis*, 53:197–207, 2019.
- [26] T. Shan and J. Tang. Physics-based neural networks for inverse problems in imaging. *IEEE Transactions on Image Processing*, 2019.
- [27] D. Shen, G. Wu, and H.-I. Suk. Deep learning in medical image analysis. *Annual review of biomedical engineering*, 19:221–248, 2017.
- [28] J. Tick, A. Pulkkinen, and T. Tarvainen. Image reconstruction in photoacoustic tomography with variable speed of sound using a higher-order geometrical acoustics approximation. *The Journal of the Acoustical Society of America*, 139(3):1447–1459, 2016.
- [29] K. S. Valluru and J. K. Willmann. Molecular photoacoustic imaging using small molecule dyes. *Bioengineering*, 3(1):7, 2016.

- [30] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser, and I. Polosukhin. Attention is all you need. In *Advances in Neural Information Processing Systems*, volume 30, pages 5998–6008. Curran Associates, Inc., 2017.
- [31] L. V. Wang. Photoacoustic tomography: fundamentals, advances and prospects. *Contrast media & molecular imaging*, 2009.
- [32] L. V. Wang and S. Hu. Photoacoustic imaging in biomedicine. *Science*, 335(6075):1458–1462, 2012.
- [33] Y. Wang and L. V. Wang. A review of photoacoustic tomography systems. *IEEE Journal of Selected Topics in Quantum Electronics*, 22(3):1–15, 2016.
- [34] M. Xu and L. V. Wang. Universal back-projection algorithm for photoacoustic computed tomography. *Physical Review E*, 71(1):016706, 2005.
- [35] M. Xu and L. V. Wang. Photoacoustic imaging in biomedicine. *Review of Scientific Instruments*, 77(4):041101, 2006.
- [36] C. Yang, H. Lan, F. Gao, and F. Gao. Review of deep learning for photoacoustic imaging. *Photoacoustics*, 21:100215, 2021.
- [37] Y. Yang, J. Sun, L. Li, and L. V. Wang. Physics-informed deep learning for computational photoacoustic imaging. *IEEE Transactions on Computational Imaging*, 2021.
- [38] X. Yi, E. Walia, and P. Babyn. Generative adversarial networks in medical image analysis. *Medical image analysis*, 58:101552, 2019.
- [39] H. Zhang, J. Xia, et al. Advances in photoacoustic imaging: from bench to bedside. *Advanced Photonics*, 2(1):014001, 2020.
- [40] W. Zhou and Y. Xu. Data-guided physics-informed neural networks for solving inverse problems in partial differential equations. *arXiv preprint arXiv:2407.10836*, 2024.
- [41] Y. Zhou, J. Gao, and D. P. Papageorgiou. Physics-guided deep learning for inverse problems. *arXiv preprint arXiv:2020.xxxx*, 2020.
- [42] Z. Zhou, M. M. Rahman Siddiquee, N. Tajbakhsh, and J. Liang. UNet++: Redesigning skip connections to exploit multiscale features in image segmentation. *IEEE Transactions on Medical Imaging*, 39(6):1856–1867, 2019.