

Reconstrucción Física-Guiada de Imágenes Fotoacústicas mediante Redes Neuronales Duales

presentado por

Maximiliano Galindo
Licenciatura en Física, Maestría en Ciencias

Presentado para cumplir con los requisitos del grado de
Maestría en Ciencias



Universidad Nacional Autónoma de México
Enero 2022

Resumen

El aprendizaje profundo ha revolucionado la reconstrucción de imágenes fotoacústicas a partir de datos crudos (raw data) provenientes de sensores, donde un eje representa el tiempo y el otro la dirección de escaneo. Las aproximaciones han evolucionado desde el uso de métodos convencionales complementados con aprendizaje profundo para mejorar la calidad de imagen, hasta el desarrollo de redes neuronales que aprenden a reconstruir la imagen directamente desde los datos crudos. En este contexto, la arquitectura U-Net se ha convertido en un estándar de facto.

Sin embargo, el principal desafío al usar redes neuronales para la reconstrucción directa radica en la física subyacente del problema, que lo hace matemáticamente mal condicionado. Aunque existen métodos como las Physics Informed Neural Networks (PINN) para incorporar restricciones físicas, estos suelen ser computacionalmente costosos debido a las numerosas operaciones numéricas requeridas. En este trabajo, proponemos un nuevo marco de trabajo que permite a la red neuronal no solo reconstruir la imagen sino también mantener la consistencia física del problema.

Nuestra propuesta se basa en un enfoque inspirado en el aprendizaje guiado por datos, que consta de dos fases principales. En la primera, entrenamos dos redes U-Net: una aprende a reconstruir imágenes a partir de datos crudos, mientras que la otra aprende el problema inverso, es decir, la generación de señales fotoacústicas a partir de imágenes, simulando así el proceso físico de propagación de ondas acústicas. En la segunda fase, realizamos un fine-tuning de la red de reconstrucción, incorporando la consistencia física como una restricción adicional en el proceso de aprendizaje. Este enfoque actúa como un supervisor que guía a la red para que no solo aprenda a reconstruir imágenes con alta calidad, sino que también respete los principios físicos fundamentales del proceso fotoacústico.

Palabras clave: Aprendizaje profundo, reconstrucción de imágenes fotoacústicas, U-Net, Physics Informed Neural Networks, aprendizaje guiado por datos, consistencia física.

Abstract

Deep learning has revolutionized photoacoustic image reconstruction from raw data obtained from sensors, where one axis represents time and the other the scanning direction. Approaches have evolved from using conventional methods complemented with deep learning to improve image quality, to developing neural networks that learn to reconstruct images directly from raw data. In this context, the U-Net architecture has become a de facto standard.

However, the main challenge when using neural networks for direct reconstruction lies in the underlying physics of the problem, which makes it mathematically ill-conditioned. Although methods such as Physics Informed Neural Networks (PINN) exist to incorporate physical constraints, these are usually computationally expensive due to the numerous numerical operations required. In this work, we propose a new framework that allows the neural network to not only reconstruct the image but also maintain the physical consistency of the problem.

Our proposal is based on an approach inspired by data guided learning, consisting of two main phases. In the first, we train two U-Net networks: one learns to reconstruct images from raw data, while the other learns the inverse problem, i.e., the generation of photoacoustic signals from images, thus simulating the physical process of acoustic wave propagation. In the second phase, we perform fine-tuning of the reconstruction network, incorporating physical consistency as an additional constraint in the learning process. This approach acts as a supervisor that guides the network to not only learn to reconstruct high-quality images, but also respect the fundamental physical principles of the photoacoustic process.

Keywords: Deep learning, photoacoustic image reconstruction, U-Net, Physics Informed Neural Networks, data guided learning, physical consistency.

Agradecimientos

Esta tesis fue realizada gracias al Programa de Apoyo a Proyectos de Investigación e Innovación Tecnológica (PAPIIT) a través del proyecto UNAM-DGAPA-PAPIIT IT10155.

Supervisores

Dr. Luis Agustín Álvarez-Icaza Longoria ¹, y Dr. Roberto Giovanni Ramírez Chavarría¹

¹Investigador Titular C
Instituto de Ingeniería
Universidad Nacional Autónoma de México

Índice general

1. Introducción	2
1.1. Preguntas de Investigación y Contribuciones	3
1.1.1. Preguntas de Investigación	3
1.1.2. Contribuciones	4
1.2. Estructura de la Tesis	4
2. Marco Teórico y Estado del Arte	6
2.1. Fundamentos y Avances Recientes en Imagen Fotoacústica	6
2.2. Métodos Tradicionales de Reconstrucción en Imagen Fotoacústica	7
2.3. La Importancia de la Consistencia Física en la Reconstrucción Fotoacústica	9
2.4. Aprendizaje Profundo para la Reconstrucción de Imágenes Fotoacústicas: Tendencias Emergentes	10
2.4.1. Integración del Conocimiento Físico en Redes Neuronales para Imagen Médica	11
2.4.2. Limitaciones y Desafíos en la Aplicación a Datos Reales de Imagen Fotoacústica	12
2.5. Aplicaciones Clínicas y Potencial de la Incorporación de la Física	12
2.6. Enfoques Híbridos en la Reconstrucción Fotoacústica	13
2.7. Optimización en Redes Neuronales Profundas: El Algoritmo Adam	13
2.7.1. Fundamentos del Algoritmo Adam	14
2.7.2. Ventajas de Adam en Problemas de Reconstrucción de Imágenes	14
2.7.3. Consideraciones Teóricas y Limitaciones	14
2.7.4. Configuración de Hiperparámetros	15
2.7.5. Adam en el Contexto de Entrenamiento Dual	15
2.7.6. Alternativas y Desarrollos Recientes	15
2.8. Conclusiones del Capítulo	16
3. Metodología	17
3.1. Fundamentos Teóricos	17

3.1.1.	Efecto Fotoacústico	17
3.1.2.	Ecuación de Onda Fotoacústica	18
3.1.3.	Problema Inverso del Efecto Fotoacústico	18
3.1.4.	Deep Learning en Reconstrucción Fotoacústica	19
3.2.	Enfoque Propuesto	20
3.2.1.	Arquitectura del Sistema	20
3.2.2.	Preentrenamiento Individual	20
3.2.3.	Flujo de Datos	22
3.2.4.	Fine-tuning con Supervisión Física	22
3.2.5.	Simulación de Señales Fotoacústicas mediante Modelo de Espacio de Estados	23
4.	Implementación	26
4.1.	Especificaciones Técnicas	26
4.1.1.	Arquitectura del Sistema	26
4.1.2.	Hiperparámetros de Entrenamiento	28
4.2.	Pipeline de Entrenamiento	29
4.2.1.	Obtención de Datos	29
4.2.2.	Preentrenamiento	30
4.2.3.	Fine-tuning	30
4.3.	Métricas de Evaluación	31
4.3.1.	Calidad de Reconstrucción	31
4.3.2.	Análisis Visuales Específicos	32
4.3.3.	Análisis Estadístico y Correlación	32
5.	Experimentos y Resultados	33
5.1.	Diseño Experimental	33
5.1.1.	Conjunto de Datos	33
5.1.2.	Configuración de Experimentos	33
5.1.3.	Métricas de Evaluación	34
5.2.	Análisis del Proceso de Entrenamiento Dual	34
5.2.1.	Dinámica del Preentrenamiento	34
5.2.2.	Dinámica de Transferencia de Conocimiento en el Fine-tuning	35
5.3.	Contribución de Componentes Específicos	37
5.3.1.	Impacto del Componente de Supervisión Física	37
5.3.2.	Rol del Componente Estructural	39
5.3.3.	Sinergia entre Componentes	40

5.4.	Análisis Comparativo Integral	40
5.4.1.	Perfil de Mejora Multimétrico	40
5.4.2.	Análisis por Categorías de Métricas	41
5.4.3.	Implicaciones para la Reconstrucción Fotoacústica	42
5.4.4.	Análisis de Dispersión de Casos	42
5.5.	Visualización de Resultados	44
5.5.1.	Ejemplos Representativos de Reconstrucción	44
5.5.2.	Análisis Espacial Comparativo	46
5.5.3.	Perfiles de Intensidad	47
5.5.4.	Visualización de Características Aprendidas	47
5.5.5.	Hallazgos Clave del Análisis Visual	49
5.6.	Interpretación de los Hallazgos Experimentales	50
5.6.1.	Complementariedad entre Conocimiento Físico y Aprendizaje de Datos	50
5.6.2.	La Física como Mecanismo de Estabilización del Aprendizaje	50
5.6.3.	Distribución No Uniforme de Mejoras	51
5.7.	Comparación con Métodos Alternativos	51
5.7.1.	Ventajas sobre Métodos PINN Tradicionales	51
5.7.2.	Ventajas sobre Métodos Puramente Basados en Datos	52
5.7.3.	Posicionamiento en el Estado del Arte	52
5.8.	Implicaciones para la Reconstrucción Fotoacústica	52
5.8.1.	Avances en Calidad de Reconstrucción	53
5.8.2.	Potencial Aplicación Clínica	53
5.9.	Limitaciones del Estudio Actual	54
5.10.	Reflexiones sobre el Enfoque Metodológico	54
5.10.1.	Balance entre Rigor Físico y Pragmatismo Computacional	54
5.10.2.	Generalización del Enfoque Metodológico	55
6.	Conclusiones y Trabajo Futuro	56
6.1.	Conclusiones	56
6.1.1.	Sobre la Estrategia de Entrenamiento Dual	56
6.1.2.	Sobre el Aprendizaje Simultáneo de Problemas Directo e Inverso	57
6.1.3.	Sobre la Contribución de los Componentes de la Función de Pérdida	57
6.1.4.	Sobre la Generalización del Enfoque Metodológico	58
6.1.5.	Conclusiones Generales	58
6.2.	Trabajo Futuro	59

6.2.1.	Validación con Datos Reales	59
6.2.2.	Avances Arquitectónicos	59
6.2.3.	Extensión a Reconstrucción Tridimensional	60
6.2.4.	Refinamiento de Modelos Físicos	60
6.2.5.	Aplicación a Otros Problemas Inversos	61
6.2.6.	Investigación en Transferencia de Conocimiento Físico	61
6.3.	Consideraciones Finales	61

Índice de figuras

3.1. Arquitectura de la red propuesta. La red reestructora se entrena para aprender el mapeo directo de señales acústicas a imágenes fotoacústicas. La red supervisora se entrena para emular el proceso físico de generación de señales acústicas a partir de una imagen dada. Durante el proceso de fine-tuning, la red reestructora se entrena para generar imágenes que, al ser procesadas por la red supervisora, produzcan señales acústicas consistentes con las mediciones originales.	21
4.1. Arquitectura de la red propuesta.	27
5.1. Evolución de las pérdidas durante el entrenamiento de las redes duales: (a) Re-constructora exhibe una rápida disminución inicial de la pérdida de entrenamien-to, generando una brecha significativa con la validación; (b) Supervisora muestra menor divergencia entre curvas pero alcanza valores de pérdida más altos (MSE validación: 0.0588 vs 0.0070 en (a)), evidenciando la mayor dificultad inherente al problema inverso de supervisión.	35
5.2. Evolución de las componentes de pérdida durante el fine-tuning completo. Obsérve-se cómo la pérdida física inicialmente alta se reduce progresivamente mientras la red aprende a incorporar el conocimiento físico sin comprometer la calidad de re-contrucción directa.	36
5.3. Diagrama de radar mostrando la evolución de las métricas de evaluación a lo largo del proceso de fine-tuning. Cada eje representa una métrica, y el área total cubierta por el polígono indica la mejora global en la calidad de reconstrucción.	37
5.4. Evolución de pérdidas sin componente física. Nótese la convergencia artificialmen-te rápida de la validación y la elevada brecha entre curvas de entrenamiento y vali-dación.	38
5.5. Evolución de pérdidas sin componente estructural. Se observa una inestabilidad pronunciada en todos los componentes de pérdida, especialmente durante las pri-meras épocas.	39
5.6. Análisis comparativo del porcentaje de mejora/deterioro en las diferentes métricas para cada configuración experimental, tomando como referencia el modelo pre-entrenado (Baseline).	41
5.7. Análisis de dispersión que correlaciona características de complejidad de las imáge-nes con la mejora relativa en métricas de calidad. Izquierda: Correlación entre entropía de la imagen y mejora porcentual en PSNR. Derecha: Correlación entre densidad de bordes y mejora porcentual en SSIM. Las líneas punteadas represen-tan las tendencias lineales para cada modelo, con sus respectivos coeficientes de correlación.	43

5.8. Ejemplos representativos de reconstrucción para diferentes niveles de complejidad. Las imágenes muestran la mejora significativa lograda por el modelo con fine-tuning completo, especialmente en estructuras vasculares finas. Los porcentajes indican la reducción del error absoluto medio respecto al modelo baseline.	45
5.9. Análisis espacial comparativo. La fila superior muestra los mapas de error absoluto para las diferentes variantes del modelo. La fila inferior presenta los mapas de SSIM local, donde las regiones más claras indican mayor similitud estructural con la imagen objetivo.	46
5.10. Perfiles de intensidad a lo largo de un corte transversal. Se comparan los perfiles de intensidad normalizada entre la imagen objetivo (Ground Truth) y las reconstrucciones de las diferentes variantes del modelo.	47
5.11. Mapas de activación de características intermedias en las redes duales. La fila superior muestra las activaciones en diferentes etapas de la red reconstructora, mientras que la fila inferior muestra las activaciones en la red supervisora. Se observa la evolución de las representaciones desde patrones generales hasta estructuras específicas.	48
5.12. Mapas de atención en diferentes capas del decodificador de la red reconstructora. Las áreas en colores cálidos representan regiones con mayor influencia en la salida del modelo. En capas profundas (dec3) el modelo atiende a características globales, mientras que en capas superficiales (dec1) se enfoca en detalles locales y bordes.	49

Índice de tablas

2.1. Comparación de modalidades de imagen médica	8
3.1. Parámetros utilizados para el modelo de espacio de estados en la simulación de señales fotoacústicas.	25
4.1. Arquitectura del modelo U-Net. Cada 'Double Conv' consiste en dos capas convolucionales 3x3 seguidas de BatchNorm y ReLU. Las operaciones ConvTranspose tienen kernel 2x2 y stride 2.	27
4.2. Hiperparámetros utilizados en el entrenamiento del modelo	28
4.3. Hiperparámetros del entrenamiento supervisado	29
5.1. Configuraciones experimentales para evaluar la estrategia de entrenamiento propuesta y sus componentes.	34
5.2. Resultados comparativos de rendimiento entre diferentes configuraciones de fine-tuning. Los mejores resultados se muestran en negrita.	41

Capítulo 1

Introducción

En la actualidad, las técnicas de imagen médica no invasivas han revolucionado el diagnóstico y tratamiento de enfermedades. Entre estas técnicas emergentes, la imagen fotoacústica (PAI, por sus siglas en inglés) se destaca por su capacidad única de combinar el contraste óptico con la resolución ultrasónica, permitiendo visualizar estructuras biológicas con un nivel de detalle sin precedentes. Esta modalidad híbrida ofrece ventajas significativas sobre técnicas convencionales, particularmente en la visualización de microvasculatura y estructuras tisulares con alto contenido de hemoglobina, lo que la hace especialmente valiosa para aplicaciones como detección temprana de cáncer, caracterización vascular y monitorización funcional. La reconstrucción de imágenes fotoacústicas representa un problema inverso mal condicionado que ha sido abordado tradicionalmente mediante aproximaciones analíticas (como retroproyección filtrada y técnicas de transformada de Fourier) y métodos iterativos. Estos enfoques, aunque fundamentados en principios físicos sólidos derivados de la ecuación de onda fotoacústica descrita en la sección 3.1.2, a menudo resultan computacionalmente costosos y pueden producir artefactos en las imágenes reconstruidas debido a la incertidumbre inherente en las mediciones. La naturaleza mal condicionada del problema, explicada detalladamente en la sección 3.1.3, implica que pequeñas perturbaciones en los datos de entrada pueden producir grandes variaciones en la solución, complicando la obtención de reconstrucciones estables y fiables.

El aprendizaje profundo ha emergido como una alternativa prometedora para estos desafíos, demostrando capacidad para aprender mapeos complejos directamente de los datos. Como se detalla en la sección 3.1.4, arquitecturas como U-Net se han convertido en estándares de facto para la reconstrucción de imágenes médicas, incluyendo las fotoacústicas. Sin embargo, las arquitecturas convencionales de redes neuronales carecen de la capacidad para incorporar naturalmente el conocimiento físico subyacente, lo que puede comprometer la consistencia física de las reconstrucciones. Los métodos existentes que intentan integrar restricciones físicas, como las Physics-Informed Neural Networks (PINNs) descritas en la sección 2.4.1 introducen una alta complejidad computacional que limita su aplicabilidad práctica. Esto se debe a que requieren la evaluación de derivadas durante el entrenamiento y la resolución simultánea de problemas directos e inversos, lo que resulta en un aumento significativo del tiempo de entrenamiento y la necesidad de grandes cantidades de datos.

Nuestro trabajo aborda esta brecha metodológica mediante el desarrollo de una estrategia de entrenamiento innovadora basada en redes duales con supervisión física, cuya arquitectura detallamos en la sección 3.2. Esta propuesta se inspira en enfoques de data guided learning pero introduce un paradigma novedoso: dos redes complementarias que aprenden simultáneamente la reconstrucción de imágenes y el problema físico inverso. La primera red aprende a transformar señales fotoacústicas en imágenes, mientras que la segunda actúa como un supervisor físico que aprende a simular el proceso de generación de señales a partir de imágenes, emulando así el fenómeno físico subyacente.

Utilizando la reconstrucción fotoacústica como caso de estudio, demostramos en el capítulo 5 cómo este enfoque puede balancear efectivamente el aprendizaje basado en datos con la incorporación de conocimiento físico, sin incurrir en la complejidad computacional de los métodos PINN tradicionales. Nuestros experimentos revelan mejoras sustanciales tanto en métricas de calidad de imagen (reducción del 30.7 % en MSE, aumento del 14.5 % en SSIM) como en consistencia física de las reconstrucciones, como se evidencia en la sección 5.4.1.

El énfasis principal de esta investigación no recae en alcanzar un nuevo estado del arte en reconstrucción fotoacústica específicamente, sino en establecer un paradigma de entrenamiento que podría extenderse a diversos problemas inversos mal condicionados en el campo de la imagen médica y más allá. Nuestro análisis en la sección 5.7 sugiere que esta metodología podría adaptarse a problemas tan diversos como la tomografía computarizada, imagen por resonancia magnética, o tomografía por impedancia eléctrica.

La estructura de esta tesis está organizada para abordar sistemáticamente nuestras preguntas de investigación detalladas en la sección 1.1. Comenzamos con un marco teórico comprensivo en el capítulo 2, seguido por nuestra propuesta metodológica en el capítulo 3. Los detalles de implementación se presentan en el capítulo 4, mientras que el capítulo 5 está dedicado a la evaluación experimental exhaustiva de nuestra propuesta. Finalmente, en el capítulo 6 analizamos las implicaciones de nuestros hallazgos y delineamos direcciones prometedoras para investigación futura.

1.1. Preguntas de Investigación y Contribuciones

Este trabajo de investigación se centra en el desarrollo de una estrategia de entrenamiento dual físicamente guiada para redes neuronales profundas, utilizando la reconstrucción fotoacústica como caso de estudio. Para lograr este objetivo, se plantean las siguientes preguntas de investigación:

1.1.1. Preguntas de Investigación

La pregunta principal de investigación es la siguiente:

¿Cómo podemos desarrollar una estrategia de entrenamiento para redes neuronales que equilibre efectivamente el aprendizaje basado en datos con la incorporación de conocimiento físico, sin incurrir en la complejidad computacional de los métodos tradicionales?

Para abordar esta pregunta de manera sistemática, se han establecido las siguientes sub-preguntas:

- PI1: *¿Cómo puede diseñarse una estrategia de entrenamiento dual que incorpore conocimiento físico en redes neuronales profundas sin recurrir a la complejidad de PINN tradicionales?*
- PI2: *¿Qué ventajas ofrece el aprendizaje simultáneo del problema directo e inverso en la consistencia y robustez del entrenamiento?*
- PI3: *¿Cuál es el impacto de diferentes componentes de la función de pérdida en la transferencia efectiva de conocimiento durante el fine-tuning?*
- PI4: *¿Cómo se puede generalizar esta estrategia de entrenamiento a otros problemas inversos mal condicionados en imágenes médicas?*

1.1.2. Contribuciones

Esta investigación proporciona las siguientes contribuciones al conocimiento:

- C1: Una estrategia de entrenamiento innovadora basada en redes duales que permite la incorporación de conocimiento físico sin la complejidad computacional de los métodos PINN tradicionales.
- C2: Un paradigma de fine-tuning con supervisión física que facilita la transferencia efectiva de conocimiento entre las redes reconstrucción y física, demostrado mediante:
 - Mejora del 30.7 % en precisión de reconstrucción (MSE)
 - Aumento del 18.9 % en consistencia física de las soluciones
 - Incremento significativo en métricas perceptuales (SSIM hasta 0.973)
- C3: Un análisis exhaustivo de la contribución de diferentes componentes de la función de pérdida en la efectividad del entrenamiento, proporcionando directrices metodológicas para problemas similares.
- C4: Evidencia empírica que demuestra cómo la incorporación de conocimiento físico actúa como regularizador implícito, mejorando la generalización en problemas inversos mal condicionados.
- C5: Una implementación de código abierto que facilita la reproducibilidad y adaptación de la estrategia propuesta a otros dominios.

1.2. Estructura de la Tesis

La presente tesis está estructurada en siete capítulos que desarrollan progresivamente la investigación realizada:

1. **Introducción:** Presenta el contexto, motivación, preguntas de investigación y contribuciones del trabajo.
2. **Marco Teórico y Estado del Arte:** Revisa los fundamentos de imagen fotoacústica, métodos tradicionales de reconstrucción, importancia de la consistencia física, y evolución de métodos de deep learning en reconstrucción fotoacústica.
3. **Metodología:** Detalla los fundamentos teóricos del efecto fotoacústico, el problema inverso asociado, y la arquitectura propuesta de redes duales con supervisión física.
4. **Implementación:** Describe las especificaciones técnicas, hiperparámetros, pipeline de entrenamiento y métricas de evaluación utilizadas.
5. **Experimentos y Resultados:** Presenta el diseño experimental, análisis del proceso de entrenamiento dual, contribución de cada componente, y visualización de resultados.
6. **Análisis y Discusión:** Interpreta los hallazgos experimentales, compara con métodos alternativos, analiza implicaciones para la reconstrucción fotoacústica, y reflexiona sobre limitaciones y direcciones futuras.

7. **Conclusiones y Trabajo Futuro:** Sintetiza las conclusiones sobre la estrategia de entrenamiento dual, el aprendizaje simultáneo de problemas directo e inverso, y delinea direcciones para investigación futura.

El desarrollo de estos capítulos aborda sistemáticamente las preguntas de investigación planteadas y demuestra las contribuciones mencionadas anteriormente. La organización facilita la comprensión progresiva de los conceptos, metodología y resultados, culminando en una discusión integral de las implicaciones y aplicaciones potenciales del trabajo realizado.

Capítulo 2

Marco Teórico y Estado del Arte

En este capítulo, se presenta una revisión exhaustiva de la literatura relacionada con la imagen fotoacústica (PAI), centrándose en los fundamentos físicos, los métodos de reconstrucción tradicionales y el impacto del aprendizaje profundo en este campo. Se discuten las ventajas y limitaciones de las técnicas actuales, así como la importancia de la consistencia física en la reconstrucción de imágenes. Además, se exploran las tendencias emergentes en el uso de redes neuronales profundas para abordar los desafíos asociados con la reconstrucción fotoacústica.

2.1. Fundamentos y Avances Recientes en Imagen Fotoacústica

El efecto fotoacústico, un fenómeno descubierto por Alexander Graham Bell en 1880 [4], constituye el principio físico fundamental detrás de la imagen fotoacústica (PAI). Este efecto se basa en la generación de ondas acústicas cuando un material absorbe energía electromagnética pulsada. En el contexto de la imagen médica, este principio permite una combinación única de alto contraste óptico y alta resolución espacial ultrasónica, superando las limitaciones inherentes a la penetración de la luz en tejidos biológicos [14].

El proceso de generación de imágenes fotoacústicas implica la iluminación del tejido con pulsos láser cortos, típicamente con duraciones de nanosegundos. La absorción de esta luz por cromóforos endógenos como la hemoglobina, la melanina y los lípidos, así como por agentes de contraste exógenos, conduce a un aumento localizado de la temperatura [14]. Esta rápida elevación de temperatura induce una expansión termoelástica, que a su vez genera ondas ultrasónicas detectables en la superficie del tejido [14]. La magnitud de la señal fotoacústica generada es directamente proporcional a la energía óptica absorbida, al coeficiente de absorción óptica del tejido y a sus propiedades termoelásticas [14]. Esta relación permite la reconstrucción de imágenes que representan la distribución de la absorción óptica dentro del tejido examinado [14].

La imagen fotoacústica se distingue por su capacidad para proporcionar información funcional, estructural, molecular y vascular dentro del mismo campo de visión, lo que la convierte en una herramienta versátil para la investigación biomédica y diversas aplicaciones clínicas [10]. La naturaleza híbrida de la PAI, que combina la sensibilidad óptica a la composición del tejido con la capacidad de penetración profunda y la alta resolución del ultrasonido, representa su principal fortaleza y la razón de su creciente interés en la comunidad científica y médica.

La imagen fotoacústica presenta varias ventajas significativas en comparación con otras modalidades de imagen médica. Principalmente, supera las limitaciones de profundidad de la imagen óptica tradicional, que se ve restringida por la difracción de la luz a profundidades inferiores a 1 mm

[20]. La PAI puede alcanzar profundidades de imagen de varios milímetros a centímetros en tejidos biológicos [50]. En contraste con la ecografía (USI), la PAI ofrece un contraste superior basado en la absorción óptica, lo que permite la obtención de imágenes sin marcadores de cromóforos endógenos y la obtención de imágenes dirigidas con agentes de contraste exógenos [14]. La USI se basa en las variaciones en la impedancia acústica, que no siempre proporciona un contraste suficiente para ciertos tejidos o condiciones [14]. A diferencia de las modalidades basadas en radiación ionizante como los rayos X y la tomografía computarizada (TC), la PAI no es ionizante y se considera segura para aplicaciones clínicas [14]. Además, la PAI puede proporcionar información cuantitativa sobre la fisiología del tejido, como la saturación de oxígeno en sangre (sO_2) y la concentración de hemoglobina [20]. Estas características posicionan a la PAI como una modalidad complementaria o alternativa valiosa en el panorama de las técnicas de imagen médica.

Los sistemas modernos de imagen fotoacústica dependen de fuentes de láser pulsado con duraciones de pulso en el rango de los nanosegundos para inducir el efecto fotoacústico [14]. Los avances recientes en la tecnología láser se centran en la mejora de la energía del pulso, la frecuencia de repetición, la capacidad de sintonización de la longitud de onda y la miniaturización para facilitar aplicaciones portátiles y clínicas [14]. Los detectores ultrasónicos (USTR) desempeñan un papel crucial en la detección de las ondas acústicas generadas [14]. Los desarrollos recientes incluyen transductores de alta frecuencia para una resolución espacial mejorada en la PAI mesoscópica y microscópica [83], así como transductores de matriz hemisférica y en forma de anillo para una mayor apertura de detección en la PAI tomográfica, lo que conduce a una mejor calidad de imagen y una mayor profundidad de penetración [50].

Los sistemas de escaneo en PAI pueden ser ópticos (escaneando el haz láser) o mecánicos (escaneando el detector ultrasónico) [14]. Los avances en la tecnología de escaneo tienen como objetivo aumentar la velocidad de adquisición de imágenes y el campo de visión. Por ejemplo, se utilizan etapas motorizadas para mover los USTR en sistemas de PAI tomográfica de estación base para obtener imágenes de ROI grandes [50]. Se están desarrollando técnicas de escaneo de alta velocidad para mejorar las velocidades de cuadro para aplicaciones en tiempo real [7]. Además, los sistemas de imagen fotoacústica y ultrasonido de doble modalidad (PAUS) están ganando terreno, aprovechando el hardware compartido (transductores de ultrasonido) y requiriendo la adición de una fuente óptica a los sistemas de ultrasonido existentes, lo que potencialmente conduce a una traducción clínica más rápida [10]. Estos continuos avances tecnológicos en los componentes clave de los sistemas PAI están expandiendo significativamente sus capacidades y su potencial de aplicación.

2.2. Métodos Tradicionales de Reconstrucción en Imagen Fotoacústica

Los métodos convencionales para la reconstrucción de imágenes fotoacústicas se pueden clasificar en tres categorías principales [14]:

Los métodos analíticos, como la retroproyección filtrada (FBP) y las técnicas basadas en la transformada de Fourier, ofrecen soluciones directas a la ecuación de onda fotoacústica [14]. La FBP es un algoritmo ampliamente utilizado en la tomografía computarizada fotoacústica (PACT) debido a su simplicidad y eficiencia computacional [66]. Estos métodos son particularmente atractivos para aplicaciones de imagen en tiempo real debido a su velocidad [14]. Sin embargo, los métodos analíticos pueden ser susceptibles al ruido, a ángulos de visión limitados y a las propiedades acústicas heterogéneas del tejido, lo que a menudo resulta en la aparición de artefactos en las imágenes reconstruidas [14]. El algoritmo de retardo y suma (DAS) es una versión simplificada

Cuadro 2.1: Comparación de modalidades de imagen médica

Característica	Fotoacústica (PAI)	Ultrasonido (USI)	Rayos X	Tomografía Computarizada (TC)	Resonancia Magnética (RM)	Tomografía por Emisión de Positrones (PET)
Principio de Imagen	Absorción de luz y detección acústica	Reflexión de ondas acústicas	Atenuación de rayos X	Atenuación de rayos X reconstruida	Resonancia de protones en campo magnético	Aniquilación de positrones
Contraste	Cromóforos ópticos endógenos o exógenos	Impedancia acústica	Densidad del tejido	Densidad del tejido diferencial	Tiempos de relajación T1 y T2, densidad de protones	Radiotrazadores específicos
Resolución Espacial	μm a mm	mm	Sub-mm	Sub-mm	Sub-mm	mm
Profundidad de Imagen	mm a cm	cm	cm	cm	cm	cm
Radiación Ionizante	No	No	Sí	Sí	No	Sí
Información Funcional	Sí (oxigenación, flujo)	Sí (Doppler, elastografía)	No	Limitada	Sí (fMRI, perfusión)	Sí (actividad metabólica)
Información Molecular	Sí (espectroscopia, agentes de contraste)	Limitada	No	No	Limitada (con agentes específicos)	Sí (radiotrazadores)
Ventajas	Alto contraste óptico, sin radiación, información funcional y molecular	Tiempo real, portátil, económico, seguro	Económico, excelente para hueso	Resolución 3D, buena cobertura anatómica	Alta resolución en tejidos blandos, funcional	Alta sensibilidad metabólica
Limitaciones	Penetración limitada, sensible al ruido acústico	Baja resolución de contraste, dependiente del operador	Baja sensibilidad en tejidos blandos, radiación ionizante	Dosis acumulativa de radiación, alto costo	Sensible al movimiento, contraindicaciones, costoso	Baja resolución espacial, exposición a radiación

del algoritmo FBP, que proyecta directamente las señales medidas de vuelta a las regiones objetivo sin filtrado. Aunque es un método de formación de haces ampliamente utilizado en la imagen de ultrasonido, también puede adaptarse para la reconstrucción de imágenes en PACT [18]. A pesar de su eficiencia, estos métodos a menudo carecen de la sofisticación necesaria para producir imágenes de alta calidad en condiciones no ideales, lo que motiva la exploración de enfoques más avanzados.

Los métodos iterativos, que incluyen técnicas de optimización variacional y métodos algebraicos, proporcionan una mayor flexibilidad para incorporar información a priori y restricciones físicas en el proceso de reconstrucción [14]. En comparación con los métodos analíticos, estos enfoques tienen el potencial de ofrecer una mayor calidad de imagen y manejar mejor los datos limitados o las mediciones ruidosas [14]. Sin embargo, los métodos iterativos generalmente son más costosos computacionalmente y requieren más tiempo de procesamiento, lo que limita su aplicabilidad en escenarios clínicos en tiempo real [14]. Las mejoras recientes en los métodos iterativos se han centrado en el desarrollo de algoritmos más eficientes y en la incorporación de restricciones de escasez o técnicas de aprendizaje de diccionario para mejorar la calidad de la imagen a partir de datos dispersos [85]. Los algoritmos de reconstrucción basados en modelos transforman el problema original de reconstrucción de imágenes en un problema de optimización, con el objetivo de mejorar la calidad de la imagen desde una perspectiva matemática [85]. Estos avances buscan hacer que los métodos iterativos sean más prácticos para una gama más amplia de aplicaciones.

Los métodos de reconstrucción basados en modelos físicos incorporan explícitamente la física de la propagación de ondas fotoacústicas a través de simulaciones numéricas detalladas [14]. Estos métodos pueden ser muy precisos, especialmente cuando se conocen bien los parámetros físicos del medio [14]. Son particularmente útiles para la tomografía fotoacústica cuantitativa (qPAT), cuyo objetivo es recuperar mapas precisos del coeficiente de absorción teniendo en cuenta la distribución de la fluencia de la luz [12]. Sin embargo, los métodos basados en modelos son computacionalmente intensivos y requieren un conocimiento preciso de las propiedades ópticas y acústicas del tejido, que no siempre están disponibles [14]. La investigación reciente explora la combinación de enfoques basados en modelos con técnicas basadas en datos para mejorar la eficiencia y la robustez [78]. Esta integración busca aprovechar las fortalezas de ambos tipos de métodos para lograr reconstrucciones de imágenes fotoacústicas más precisas y eficientes.

2.3. La Importancia de la Consistencia Física en la Reconstrucción Fotoacústica

El problema de la reconstrucción de imágenes fotoacústicas es inherentemente mal condicionado, lo que implica que pequeñas perturbaciones en las señales acústicas medidas pueden resultar en grandes variaciones en la imagen reconstruida [14]. Esta característica dificulta la obtención de reconstrucciones estables y fiables [83]. La incorporación de restricciones físicas actúa como una forma natural de regularización, ayudando a reducir el espacio de posibles soluciones a aquellas que son físicamente plausibles [20]. La consistencia física contribuye a estabilizar el proceso de reconstrucción frente al ruido y las incertidumbres presentes en las mediciones [20]. Sin la imposición de tales restricciones, las reconstrucciones podrían ser altamente sensibles a las imperfecciones en los datos, comprometiendo su utilidad diagnóstica.

La consistencia física asegura que las imágenes reconstruidas no solo sean visualmente plausibles, sino que también representen estados físicamente posibles del sistema biológico examinado [20]. Permite verificar que la reconstrucción obedece las leyes fundamentales de la fotoacústica, como la ecuación de onda y las condiciones de contorno [20]. La incorporación de conocimiento

físico puede reducir significativamente los artefactos en las imágenes reconstruidas, lo que lleva a una mejora en la calidad de la imagen [20]. Por ejemplo, la simulación del campo fotoacústico puede ayudar a eliminar los artefactos de reflexión [86]. Para la tomografía fotoacústica cuantitativa (qPAT), la consistencia física es crucial para obtener estimaciones precisas de las concentraciones de cromóforos y otros parámetros fisiológicos [12]. Los enfoques numéricos que modelan la administración de luz a tejidos profundos pueden minimizar los artefactos derivados de la profundidad y el espectro, mejorando la precisión cuantitativa [28]. En esencia, al basar el proceso de reconstrucción en la realidad física, se obtienen imágenes más precisas, fiables y libres de artefactos, lo cual es esencial para el análisis cualitativo y cuantitativo en aplicaciones biomédicas.

La investigación subraya consistentemente el valor de integrar principios físicos en los algoritmos de reconstrucción de PAI. Hauptmann et al. [20] enfatizan el papel crítico de la consistencia física para obtener resultados robustos y fiables en la reconstrucción de imágenes fotoacústicas. Los estudios demuestran que la incorporación de restricciones físicas puede mejorar la unicidad de la solución al incluir información a priori sobre el comportamiento físico del sistema [20]. Los enfoques de aprendizaje por degeneración incrustado en la física (PEDL) se han propuesto para mejorar la calidad de la imagen PAM con mayor consistencia física, eficiencia de datos y adaptabilidad, mostrando un buen rendimiento tanto en conjuntos de datos sintéticos como reales [88]. Estos hallazgos refuerzan la idea de que la integración del conocimiento físico no es solo un concepto teórico, sino una necesidad práctica para avanzar en el campo de la reconstrucción de imágenes fotoacústicas.

2.4. Aprendizaje Profundo para la Reconstrucción de Imágenes Fotoacústicas: Tendencias Emergentes

Las primeras aproximaciones para la reconstrucción de imágenes fotoacústicas utilizando aprendizaje profundo empleaban redes neuronales como un paso de post-procesamiento para mejorar las imágenes reconstruidas con métodos tradicionales [18]. Sin embargo, trabajos más recientes han demostrado que las arquitecturas de aprendizaje profundo, particularmente las redes neuronales convolucionales (CNN) como U-Net, pueden abordar directamente el problema de la reconstrucción, especialmente en casos de muestreo disperso donde los métodos tradicionales tienen dificultades [18]. U-Net se ha convertido en un estándar de facto para la reconstrucción de imágenes médicas, incluyendo las fotoacústicas [18]. El aprendizaje profundo ofrece la capacidad de aprender mapeos complejos directamente de los datos, lo que potencialmente supera las limitaciones de los enfoques tradicionales basados en modelos [83]. El aprendizaje profundo se ha utilizado para mejorar el ancho de banda de las señales PA, compensar la pérdida de información de vista limitada y distinguir las fuentes PA de los artefactos de reflexión [68]. La capacidad de las redes neuronales para aprender patrones intrincados en los datos fotoacústicos ha impulsado significativamente los avances en la calidad y la eficiencia de la reconstrucción.

Si bien U-Net ha tenido un gran éxito, la investigación está explorando arquitecturas alternativas para mejorar aún más el rendimiento de la reconstrucción [39]. Los transformadores, conocidos por su éxito en el procesamiento del lenguaje natural y la visión por computadora, se están investigando para tareas de procesamiento de imágenes médicas, incluyendo la restauración de imágenes y potencialmente la reconstrucción en PAI [72]. El mecanismo de atención en los transformadores permite a la red centrarse en las partes relevantes de los datos de entrada, lo que podría mejorar la calidad de las reconstrucciones [6]. Los mecanismos de atención se están integrando en otras arquitecturas de red, como U-Net mejorada con autoatención, para mejorar la extracción de características y capturar el contexto global, lo que lleva a una mejor calidad de imagen y consistencia

física en PAM [88]. Las redes con forma de U de atención residual (RAUNet) que aprovechan tanto U-Net como los transformadores han mostrado una precisión de segmentación mejorada en imágenes médicas [72]. Se están explorando diseños de red minimalistas con aprendizaje residual y mecanismos de atención (como EDSR-M) para reducir la complejidad computacional al tiempo que se mejoran los detalles de la imagen en la reconstrucción y segmentación de PAI [39]. Estas tendencias reflejan un esfuerzo por aprovechar los últimos avances en aprendizaje profundo para superar las limitaciones de las arquitecturas convencionales en el contexto específico de la imagen fotoacústica.

2.4.1. Integración del Conocimiento Físico en Redes Neuronales para Imagen Médica

Las arquitecturas de redes neuronales convencionales a menudo carecen de la capacidad para incorporar de forma natural el conocimiento físico subyacente, lo que puede comprometer la consistencia física de las reconstrucciones [83]. La integración de información física en los marcos de aprendizaje automático para el análisis de imágenes médicas (MIA) está transformando el campo, lo que lleva a una mayor robustez e interpretabilidad [91]. La aplicación de enfoques genéricos de aprendizaje automático al MIA presenta desafíos únicos derivados de la escasez de datos, el alto costo de la recopilación de datos, los rigurosos requisitos de interpretabilidad, los estándares de precisión y la considerable variabilidad entre pacientes [91]. Los métodos basados en la física pueden proporcionar analogías simplificadas para comprender los procesos físicos, ofreciendo información valiosa [91]. Por lo tanto, si bien el aprendizaje profundo ha demostrado un gran potencial, la integración efectiva del conocimiento físico sigue siendo un desafío clave en la reconstrucción de imágenes médicas. Abordar este desafío es crucial para garantizar la fiabilidad, la interpretabilidad y la generalización de los modelos de aprendizaje profundo en entornos clínicos.

Las redes neuronales informadas por la física (PINN) incorporan directamente las leyes físicas gobernantes (por ejemplo, ecuaciones diferenciales parciales) en la función de pérdida de la red neuronal [83]. Esto permite que la red aprenda soluciones que no solo se ajustan a los datos sino que también satisfacen la física subyacente [82]. Sin embargo, las PINN a menudo introducen una alta complejidad computacional debido a la necesidad de evaluar derivadas durante el entrenamiento y posiblemente resolver problemas directos e inversos simultáneamente [83]. Mantener un equilibrio adecuado entre la pérdida basada en datos y la pérdida basada en la física puede ser un desafío durante el entrenamiento [20]. La red podría priorizar la satisfacción de las restricciones físicas a expensas del ajuste a los datos, o viceversa. Las PINN pueden enfrentar desafíos al modelar sistemas multiescala y multifísicos, lo que podría resultar en imprecisiones en la captura de características de alta frecuencia [71]. A pesar de su potencial, la aplicación práctica de las PINN en escenarios complejos de imagen médica a menudo se ve obstaculizada por el costo computacional y la dificultad de equilibrar las restricciones de datos y física durante el entrenamiento.

Los enfoques guiados por datos informados por la física tienen como objetivo encontrar un mejor equilibrio entre el aprendizaje a partir de datos y el cumplimiento de las restricciones físicas [20]. Estos métodos podrían implicar un proceso de entrenamiento en dos fases en el que la red se entrena primero con datos y luego incorpora gradualmente las restricciones físicas [20]. La estrategia de doble red propuesta en el texto inicial, donde una red aprende la reconstrucción de la imagen y la otra actúa como un supervisor físico aprendiendo a simular el proceso de generación de la señal, representa un enfoque guiado por datos informado por la física [83]. Este enfoque tiene como objetivo incorporar conocimiento físico sin la complejidad computacional de las PINN tradicionales. El aprendizaje por degeneración incrustado en la física (PEDL) es otro enfoque que

incorpora los principios físicos de PAM en los modelos de aprendizaje profundo para mejorar la calidad de la imagen y la consistencia física [88]. Estos métodos reconocen las limitaciones de las PINN tradicionales y buscan ofrecer una forma más práctica de integrar el conocimiento físico en los modelos de aprendizaje profundo para la reconstrucción de imágenes médicas.

2.4.2. Limitaciones y Desafíos en la Aplicación a Datos Reales de Imagen Fotoacústica

Un desafío significativo en la aplicación del aprendizaje profundo a datos reales de imagen fotoacústica es la posible falta de generalización de los modelos entrenados principalmente con datos sintéticos [20]. Los datos del mundo real a menudo contienen complejidades y características de ruido que no se capturan completamente en las simulaciones. La precisión de la reconstrucción de imágenes PA depende de factores como el contraste de absorción óptica del tejido, la duración del pulso láser y la precisión del algoritmo de reconstrucción de imágenes [20]. Estos factores pueden variar significativamente en escenarios del mundo real. La vista limitada y el ancho de banda estrecho de los transductores de ultrasonido clínicos plantean un problema severamente mal condicionado para la reconstrucción de imágenes PA, que puede ser difícil de abordar con modelos entrenados en datos sintéticos ideales [11]. Por lo tanto, la brecha entre los datos fotoacústicos simulados y del mundo real sigue siendo un obstáculo importante para la adopción clínica generalizada de métodos de reconstrucción basados en aprendizaje profundo con restricciones físicas.

La evaluación de la consistencia física de las reconstrucciones obtenidas con aprendizaje profundo requiere métricas específicas que vayan más allá de las medidas tradicionales de calidad de imagen como MSE y SSIM [20]. Puede ser un desafío evaluar cuantitativamente si un modelo de aprendizaje profundo realmente se adhiere a los principios físicos subyacentes o simplemente está aprendiendo mapeos de datos complejos. El desarrollo de métodos de validación robustos que puedan garantizar la plausibilidad física de las reconstrucciones fotoacústicas basadas en aprendizaje profundo es crucial para su aceptación clínica. Un enfoque implica el uso de una segunda red "física" para supervisar la red de reconstrucción, como se propuso en el texto inicial [83]. La capacidad de verificar que las reconstrucciones no solo son visualmente atractivas sino también físicamente precisas es fundamental para la confianza en la aplicación clínica de estas técnicas.

2.5. Aplicaciones Clínicas y Potencial de la Incorporación de la Física

La imagen fotoacústica ha demostrado ventajas distintivas en aplicaciones clínicas como el monitoreo de la saturación de oxígeno en sangre, el diagnóstico de placas ateroscleróticas vulnerables y la imagen oftálmica multimodal [83]. Las técnicas de aprendizaje profundo se están utilizando para adquirir imágenes optoacústicas de alta calidad para la segmentación, clasificación y detección de enfermedades, incluido el cribado y diagnóstico del cáncer de mama mediante la detección de la angiogénesis [39]. Se ha demostrado la PAT de alta velocidad de cuadro asistida por aprendizaje profundo con transductores de ultrasonido de un solo elemento, lo que mejora la velocidad de adquisición de imágenes sin comprometer la calidad de la imagen, lo cual es crucial para aplicaciones clínicas en tiempo real [7]. La microscopía fotoacústica volumétrica cuantitativa (PAM) se ha utilizado para evaluar directamente la vasoconstricción después de la aplicación tópica de corticosteroides, visualizando de forma no invasiva la vasculatura de la piel [78]. Si bien estos ejemplos ilustran el creciente papel del aprendizaje profundo en diversas aplicaciones clínicas de la PAI, la

demostración explícita de mejoras significativas debido a la incorporación de conocimiento físico requiere más investigación. El enfoque PEDL [88] representa una dirección prometedora al mejorar la consistencia física en PAM, lo que podría traducirse en mejores resultados clínicos.

2.6. Enfoques Híbridos en la Reconstrucción Fotoacústica

Se están explorando enfoques híbridos que combinan la reconstrucción tradicional basada en modelos con el aprendizaje profundo para mejorar tanto la velocidad como el rendimiento de la reconstrucción de imágenes [78]. Por ejemplo, se utiliza el aprendizaje profundo para el post-procesamiento de imágenes con el fin de reducir los artefactos en las imágenes reconstruidas tradicionalmente [18]. Y-Net, una arquitectura CNN, reconstruye imágenes PA integrando tanto datos brutos como imágenes formadas por haces (reconstruidas tradicionalmente) como entrada, mostrando un buen rendimiento en comparación con los métodos convencionales de aprendizaje profundo y basados en modelos [17]. El aprendizaje profundo se puede utilizar para aprender un conjunto óptimo de pesos de apodización para los métodos tradicionales de retroproyección, logrando eficiencia de datos y robustez en la mejora de la señal de ultrasonido y la reconstrucción de imágenes para PAT [68]. La combinación de las fortalezas de los métodos de reconstrucción tradicionales, como la incorporación de principios físicos, con las capacidades de aprendizaje del aprendizaje profundo ofrece una vía prometedora para mejorar la calidad, la velocidad y la robustez de la reconstrucción de imágenes fotoacústicas [17].

El aprendizaje por degeneración incrustado en la física (PEDL) incorpora los principios físicos de PAM en los modelos de aprendizaje profundo [88]. La estrategia de doble red con supervisión física, como se describe en el texto inicial, también representa una integración de un modelo físico (el proceso de generación de la señal directa) con un enfoque de aprendizaje basado en datos [83]. El marco de trabajo de aprendizaje profundo basado en imágenes previas (PICDL) combina una versión modificada de un algoritmo de detección comprimida con restricciones de imágenes previas (PICCS) con aprendizaje profundo para corregir los artefactos de endurecimiento del haz en imágenes de TC, lo que sugiere un potencial para enfoques híbridos similares en PAI [89]. La tendencia hacia la integración de modelos físicos directamente en el marco de aprendizaje profundo, o el uso del aprendizaje profundo para mejorar e informar la reconstrucción basada en modelos, sugiere un reconocimiento creciente de los beneficios de combinar el poder inductivo de los datos con el rigor deductivo de la física para lograr resultados superiores en la imagen fotoacústica [33].

2.7. Optimización en Redes Neuronales Profundas: El Algoritmo Adam

La optimización eficiente de redes neuronales profundas constituye un aspecto fundamental para el éxito de cualquier arquitectura de aprendizaje profundo, particularmente en problemas complejos como la reconstrucción fotoacústica. Entre los diversos algoritmos de optimización desarrollados, Adam (Adaptive Moment Estimation) se ha establecido como uno de los optimizadores más efectivos y ampliamente utilizados en la práctica [31].

2.7.1. Fundamentos del Algoritmo Adam

Adam combina las ventajas de dos extensiones del descenso de gradiente estocástico: AdaGrad, que adapta la tasa de aprendizaje basándose en los gradientes históricos [15], y RMSprop, que utiliza un promedio móvil exponencial de los gradientes cuadrados [63]. El algoritmo mantiene estimaciones tanto del primer momento (la media) como del segundo momento (la varianza no centrada) de los gradientes [31].

El algoritmo Adam actualiza los parámetros θ de la red mediante las siguientes ecuaciones:

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t \quad (2.1)$$

$$v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2 \quad (2.2)$$

$$\hat{m}_t = \frac{m_t}{1 - \beta_1^t} \quad (2.3)$$

$$\hat{v}_t = \frac{v_t}{1 - \beta_2^t} \quad (2.4)$$

$$\theta_{t+1} = \theta_t - \frac{\alpha}{\sqrt{\hat{v}_t} + \epsilon} \hat{m}_t \quad (2.5)$$

donde g_t representa el gradiente en el tiempo t , m_t y v_t son las estimaciones sesgadas del primer y segundo momento respectivamente, $\hat{m}_t$ y $\hat{v}_t$ son las estimaciones corregidas por sesgo, α es la tasa de aprendizaje, y β_1 , β_2 son los factores de decaimiento para las estimaciones de momento [31].

2.7.2. Ventajas de Adam en Problemas de Reconstrucción de Imágenes

En el contexto de la reconstrucción de imágenes médicas, Adam presenta varias ventajas significativas. La adaptación automática de la tasa de aprendizaje por parámetro permite un entrenamiento más eficiente en espacios de parámetros de alta dimensionalidad, como los presentes en arquitecturas U-Net [56]. Esta característica es particularmente valiosa en problemas inversos mal condicionados, donde diferentes parámetros pueden requerir tasas de aprendizaje distintas para una convergencia óptima.

La robustez frente a gradientes ruidosos constituye otra ventaja crucial. En la reconstrucción fotoacústica, donde las señales pueden contener ruido experimental significativo, la capacidad de Adam para mantener estimaciones suavizadas de los gradientes ayuda a estabilizar el proceso de entrenamiento [53]. Esto resulta especialmente importante durante el fine-tuning con supervisión física, donde múltiples términos de pérdida pueden generar gradientes con magnitudes y direcciones variables.

2.7.3. Consideraciones Teóricas y Limitaciones

A pesar de su éxito empírico, Adam presenta ciertas limitaciones teóricas que han sido objeto de investigación reciente. Reddi et al. [53] demostraron que Adam puede fallar en converger al óptimo global en ciertos casos, particularmente cuando los gradientes tienen varianza alta. Este problema motivó el desarrollo de variantes como AMSGrad, que modifica la actualización del segundo momento para garantizar convergencia teórica [53].

En problemas de optimización no convexa, como los presentes en redes neuronales profundas, Adam puede quedar atrapado en mínimos locales subóptimos [9]. Sin embargo, estudios empíricos han demostrado que en la práctica, estos mínimos locales a menudo proporcionan soluciones de calidad aceptable para tareas de aprendizaje profundo [36].

2.7.4. Configuración de Hiperparámetros

La elección adecuada de los hiperparámetros de Adam es crucial para su rendimiento óptimo. Los valores por defecto recomendados son $\beta_1 = 0,9$, $\beta_2 = 0,999$, $\epsilon = 10^{-8}$, y $\alpha = 0,001$ [31]. Sin embargo, en aplicaciones específicas como la reconstrucción fotoacústica, puede ser beneficioso ajustar estos valores según las características del problema.

La tasa de aprendizaje α requiere particular atención, ya que valores demasiado altos pueden causar inestabilidad, mientras que valores demasiado bajos resultan en convergencia lenta [61]. En nuestro contexto de entrenamiento dual, donde se combinan múltiples términos de pérdida con diferentes escalas, la selección cuidadosa de α es fundamental para balancear efectivamente las contribuciones de los componentes físico y estructural.

2.7.5. Adam en el Contexto de Entrenamiento Dual

Para la estrategia de entrenamiento dual propuesta en este trabajo, Adam ofrece ventajas específicas que justifican su selección. La capacidad de adaptar automáticamente las tasas de aprendizaje facilita el manejo de las diferentes dinámicas de convergencia observadas entre la red re-constructora y la red supervisora [94]. Durante el preentrenamiento, cada red puede beneficiarse de la adaptación automática de Adam a sus características específicas de gradiente.

Durante la fase de fine-tuning, donde se incorporan múltiples términos de pérdida con diferentes magnitudes y escalas temporales, la robustez de Adam frente a gradientes complejos resulta particularmente valiosa. La estimación adaptativa de momentos permite al optimizador ajustarse dinámicamente a los cambios en la superficie de pérdida que ocurren cuando se introduce la supervisión física [81].

2.7.6. Alternativas y Desarrollos Recientes

Aunque Adam sigue siendo ampliamente utilizado, la investigación reciente ha propuesto varias mejoras y alternativas. AdamW incorpora desacoplamiento de la regularización de peso, mejorando la generalización en muchos casos [46]. RAdam (Rectified Adam) aborda el problema de la varianza alta en las primeras iteraciones mediante un término de rectificación [43].

Para aplicaciones en imagen médica, donde la precisión y estabilidad son cruciales, estas variantes pueden ofrecer ventajas adicionales. Sin embargo, la selección del optimizador debe balancearse con consideraciones prácticas como la disponibilidad de implementaciones estables y la facilidad de ajuste de hiperparámetros [58].

La investigación continúa explorando optimizadores especializados para diferentes tipos de problemas de aprendizaje profundo, incluyendo aquellos diseñados específicamente para problemas inversos en imagen médica [8]. Estos desarrollos prometen mejoras adicionales en la eficiencia y robustez del entrenamiento de redes neuronales para aplicaciones biomédicas.

2.8. Conclusiones del Capítulo

La imagen fotoacústica continúa evolucionando como una modalidad de imagen biomédica con un potencial significativo, impulsada por los avances en la tecnología de láseres, detectores ultrasónicos y sistemas de escaneo [14, 50]. Si bien los métodos tradicionales de reconstrucción han sentado las bases, el aprendizaje profundo ha emergido como una herramienta poderosa para abordar los desafíos inherentes del problema inverso mal condicionado [77, 78]. La integración del conocimiento físico en las redes neuronales se presenta como un área crucial para garantizar la consistencia física, la precisión cuantitativa y la reducción de artefactos en las reconstrucciones [20].

Enfoques como las PINN [40] y las estrategias guiadas por datos [88] están explorando diferentes formas de incorporar la física, cada uno con sus propios desafíos y beneficios. La investigación futura deberá centrarse en superar las limitaciones actuales relacionadas con la complejidad computacional, el equilibrio de pérdidas y la generalización a datos reales [91, 20]. Los enfoques híbridos que combinan métodos tradicionales con técnicas de aprendizaje profundo parecen prometedores para lograr reconstrucciones robustas y eficientes [17, 89].

A medida que la tecnología continúa avanzando, la incorporación efectiva del conocimiento físico en los modelos de aprendizaje profundo tiene el potencial de desbloquear todo el potencial de la imagen fotoacústica en una amplia gama de aplicaciones clínicas, mejorando el diagnóstico y el tratamiento de diversas enfermedades [7, 10]. La estrategia de doble red con supervisión física propuesta en este trabajo representa una contribución significativa a este campo emergente, ofreciendo un equilibrio entre el rigor físico y la eficiencia computacional que podría aplicarse a diversos problemas inversos en imagen médica y más allá [83, 89].

Capítulo 3

Metodología

En este capítulo se presenta la metodología de este trabajo tanto teórica como experimental. Partiendo desde la matemática del problema hasta la arquitectura de las redes neuronales utilizadas. En esta sección se presenta la metodología de este trabajo tanto teórica como experimental. Partiendo desde la matemática del problema hasta la arquitectura de las redes neuronales utilizadas. Se describen las variables de estudio, las métricas de evaluación y el proceso de entrenamiento.

3.1. Fundamentos Teóricos

Primero comenzamos por entender el problema físico subyacente y por qué es importante tener en cuenta la consistencia física en la reconstrucción de imágenes fotoacústicas y cómo es que esta consistencia física puede ayudar a nuestra red neuronal a aprender de manera más eficiente y a obtener mejores resultados.

La solución del problema inverso del efecto fotoacústico es una función de distribución a la cual llamamos imagen. Existen dos métodos muy populares para resolver el problema inverso: *Time Reversal* y *Back Projection*, los cuales se derivan de suposiciones físicas y matemáticas, lo cual es conocido como DAS (Delay and Sum).

3.1.1. Efecto Fotoacústico

El efecto fotoacústico es la generación de una onda ultrasónica que es producida por un material fotosensible al ser iluminado por un pulso de luz.

La generación y propagación de la onda fotoacústica es modelada por la ecuación para un fluido ideal y está muy bien descrita por el acoplamiento de la ecuación de difusión de calor para la variación de temperatura $T(\mathbf{x}, t)$ (ec. 3.1) y la ecuación de onda acústica para la presión $P(\mathbf{x}, t)$ (ec. 3.2).

$$(\chi \nabla^2 - \frac{\partial}{\partial t})T(\mathbf{x}, t) = -\frac{1}{\rho_0 C_P}H(\mathbf{x}, t) \quad (3.1)$$

$$(\frac{1}{K_T \rho_0} \nabla^2 - \frac{\partial^2}{\partial t^2})P(\mathbf{x}, t) = -\frac{\beta}{K_T} \frac{\partial^2}{\partial t^2}T(\mathbf{x}, t) \quad (3.2)$$

donde, para la muestra, χ es la conductividad térmica, ρ_0 es la densidad, C_P es el calor específico, $H(\mathbf{x}, t)$ es la densidad de energía electromagnética por unidad de tiempo absorbida por la muestra, K_T es el coeficiente de compresibilidad térmica, y β es el coeficiente de expansión térmica.

La densidad de energía electromagnética $H(\mathbf{x}, t)$ es modelada como:

$$H(\mathbf{x}', t) = \mu(\mathbf{x}', t)\phi(\mathbf{x}', t) \quad (3.3)$$

donde $\mathbf{x}'$ es la posición de la fuente de la onda, $\mu(\mathbf{x}', t)$ es el coeficiente de absorción óptico de la muestra y $\phi(\mathbf{x}', t)$ es la tasa de fluencia del pulso láser. La tasa de fluencia puede ser descrita como el producto de la intensidad $I(\mathbf{x}')$ y el perfil temporal $\theta(t)$ del pulso láser $\phi(\mathbf{x}', t) = I(\mathbf{x}')\theta(t)$.

3.1.2. Ecuación de Onda Fotoacústica

La ecuación de onda fotoacústica modela la propagación de la onda acústica generada $P(\mathbf{x}, t)$ producida por la expansión termoelástica de la muestra.

Esta ecuación se obtiene desacoplando las ecuaciones 3.1 y 3.2. Existen suposiciones físicas acerca del medio donde la onda se propaga, como la viscosidad, la absorción acústica es ignorada, la variación de la presión y densidad son pequeñas comparadas a los valores iniciales y la velocidad de las partículas es menor que la velocidad del sonido entre otras, que permiten simplificar la ecuación de onda acústica a:

$$\left[\nabla^2 p - \frac{1}{c^2} \frac{\partial^2}{\partial t^2} \right] P(\mathbf{x}, t) = -\frac{\beta}{C_p} \frac{\partial H}{\partial t} \quad (3.4)$$

donde c es la velocidad del sonido en el medio de propagación, y es definida como $c = \left(K_T \rho_0 \frac{\beta^2 T_0}{C_P} \right)^{-1}$.

3.1.3. Problema Inverso del Efecto Fotoacústico

El problema inverso fotoacústico (PA) implica resolver un problema de valor en la frontera para la ecuación de onda PA. La solución proporciona la distribución espacial de la absorción electromagnética durante el proceso de expansión termoelástica.

Para definir el problema inverso PA, se asume que la densidad de energía electromagnética absorbida por la muestra, $H(\mathbf{x}', t)$, es separable en componentes espaciales y temporales:

$$H(\mathbf{x}', t) = h_x(\mathbf{x}')h_t(t). \quad (3.5)$$

Para un tiempo de iluminación τ_p corto (tal que $\tau_p \ll 1/\mu c$), la función temporal puede aproximarse mediante una función delta de Dirac:

$$h_t \rightarrow \delta(t) \quad \text{cuando} \quad \Delta T \rightarrow 0. \quad (3.6)$$

Esta condición, conocida como la *condición de confinamiento de estrés*, asume que la transferencia de calor ocurre antes de que haya cambios significativos en la densidad de masa.

Cuando la muestra absorbe energía electromagnética, las variaciones de temperatura inducen cambios en la densidad de masa y la presión. Utilizando relaciones termodinámicas, la distribución de presión inicial se expresa como:

$$P|_{t=0} = \frac{\beta}{K_T} T|_{t=0} = \Gamma h_x, \quad (3.7)$$

donde Γ es el parámetro de Grüneisen, que describe la eficiencia del proceso de conversión de calor a presión.

Para imponer el confinamiento de estrés y la distribución inicial de presión, se resuelve la ecuación de onda con un término fuente:

$$\left[\nabla^2 - \frac{1}{c^2} \frac{\partial^2}{\partial t^2} \right] P = 0, \quad \text{con} \quad P(\mathbf{x}, 0) = \Gamma h_x, \quad \frac{\partial P}{\partial t} \Big|_{t=0} = 0. \quad (3.8)$$

El problema inverso PA se formula utilizando condiciones de frontera en una superficie de observación S donde se miden los valores de presión:

$$\left[\nabla^2 - \frac{1}{c^2} \frac{\partial^2}{\partial t^2} \right] P(\mathbf{x}, t) = 0, \quad t \geq 0, \quad (3.9)$$

$$P(\mathbf{x}', 0) = f(\mathbf{x}'), \quad \frac{\partial P}{\partial t} \Big|_{t=0} = 0, \quad (3.10)$$

$$P(\mathbf{x}_S, t) = g(\mathbf{x}_S, t), \quad \mathbf{x}_S \in S, \quad t \geq 0. \quad (3.11)$$

El objetivo es determinar la distribución de presión inicial $f(\mathbf{x}')$ a partir de los datos de frontera $g(\mathbf{x}_S, t)$. Esta distribución representa la imagen PA.

Los supuestos matemáticos para garantizar la resolubilidad incluyen que la fuente esté contenida dentro de S , que no existan fuentes PA externas, y que la ecuación de onda sea válida en todo el espacio.

Debido a la naturaleza termodinámica del efecto fotoacústico, el problema inverso PA es mal condicionado, lo que ha llevado al desarrollo de métodos de regularización, entre otros.

3.1.4. Deep Learning en Reconstrucción Fotoacústica

El uso de redes neuronales profundas en la reconstrucción de imágenes fotoacústicas se ha implementado de diferentes formas, tanto complementando una reconstrucción inicial con métodos clásicos como el DAS y removiendo los artefactos que este genera [16], como también desde cero, tomando datos en crudo y generando imágenes a partir de estos [76].

Muchos de estos trabajos usan la popular arquitectura U-Net [55] para la reconstrucción de imágenes, la cual ha demostrado ser muy efectiva en la reconstrucción de imágenes en diferentes campos de la ciencia. Sin embargo, la mayoría de estos trabajos no toman en cuenta la consistencia física de las imágenes reconstruidas, sin contar aquellos que complementan deep learning con métodos clásicos.

La consistencia física, si bien no parece ser un problema al momento de reconstruir la imagen a partir de la onda acústica, puede ser usada para enseñar a la red a realizar la reconstrucción de manera más eficiente y con mejores resultados, ya que la red puede aprender de manera implícita las características físicas del problema.

Como ya mencioné, el problema inverso del efecto fotoacústico es mal condicionado. Se han desarrollado métodos de aprendizaje profundo para resolver este tipo de problemas como los Physics Informed Neural Networks (PINNs) [51] que son redes neuronales que son entrenadas para resolver ecuaciones diferenciales parciales. Sin embargo, estos métodos no han sido aplicados en la reconstrucción de imágenes fotoacústicas directamente; si bien lo que hacen es poder encontrar los parámetros de una ecuación diferencial parcial, no se ha aplicado directamente a la reconstrucción de imágenes. Sin embargo, enfoques interesantes han surgido a partir de esta idea, como hacer un fine-tuning de una red ya preentrenada primero minimizando puramente la pérdida relacionada a los datos, después minimizando las pérdidas relacionadas tanto a los datos como a la pérdida residual de la PDE [90]. Sin embargo, como mencioné, estos trabajos no se concentran principalmente en la reconstrucción de las imágenes fotoacústicas, pero sí dan un sentido de cómo se puede incorporar la física en las redes neuronales haciendo el preentrenamiento de la red con datos y después con la física, mejorando las soluciones para problemas inversos mal condicionados.

3.2. Enfoque Propuesto

El método propuesto se basa en un enfoque dual que combina dos redes neuronales U-Net con roles complementarios: una red reconstructora y una red supervisora. Este diseño está motivado por la necesidad de incorporar consistencia física en el proceso de reconstrucción de imágenes fotoacústicas. La arquitectura general se muestra en la Figura 3.1.

La red reconstructora tiene como objetivo principal transformar las señales acústicas medidas (S) en imágenes fotoacústicas ($\hat{I}$), mientras que la red supervisora actúa como un evaluador físico, aprendiendo a simular el proceso de generación de señales acústicas a partir de una imagen dada. La clave de este enfoque es el entrenamiento en dos fases: un preentrenamiento individual de cada red seguido de un proceso de fine-tuning que incorpora la supervisión física.

3.2.1. Arquitectura del Sistema

Ambas redes siguen una arquitectura U-Net modificada que consiste en un codificador (Encoder) que extrae características relevantes de la entrada, un cuello de botella (Bottleneck) que comprime la información, y un decodificador (Decoder) que reconstruye la salida deseada.

3.2.2. Preentrenamiento Individual

El preentrenamiento se realiza de manera independiente para cada red, estableciendo las capacidades básicas necesarias para el proceso de fine-tuning posterior.

Red Reconstructora

La red reconstructora se entrena para aprender el mapeo directo de señales acústicas a imágenes fotoacústicas. Durante esta fase, la red optimiza:

$$\mathcal{L}_A = \text{MSE}(\hat{I}, I) \quad (3.12)$$




Figura 3.1: Arquitectura de la red propuesta. La red reconstructora se entrena para aprender el mapeo directo de señales acústicas a imágenes fotoacústicas. La red supervisora se entrena para emular el proceso físico de generación de señales acústicas a partir de una imagen dada. Durante el proceso de fine-tuning, la red reconstructora se entrena para generar imágenes que, al ser procesadas por la red supervisora, produzcan señales acústicas consistentes con las mediciones originales.

donde $\hat{I}$ es la imagen reconstruida y I es la imagen objetivo. Esta pérdida asegura que la red aprenda a generar reconstrucciones visualmente precisas.

Red Supervisora

La red supervisora se entrena para aproximar el proceso físico de generación de señales acústicas. Este proceso puede ser modelado como:

$$S = \mathcal{F}(I) + \epsilon \quad (3.13)$$

donde $\mathcal{F}$ representa una aproximación del operador físico de propagación fotoacústica. En la práctica, este operador encapsula las complejas relaciones descritas por las ecuaciones de onda fotoacústica presentadas en la sección 3.1. La red neuronal actúa como un aproximador universal de esta función, aprendiendo a mapear las imágenes a sus correspondientes señales acústicas sin necesidad de resolver explícitamente las ecuaciones diferenciales parciales subyacentes. El término ϵ modela tanto el ruido del sistema como los errores de aproximación inherentes a este enfoque.

La red optimiza:

$$\mathcal{L}_B = \text{MSE}(\hat{S}, S) \quad (3.14)$$

donde S_{pred} es la señal acústica predicha por la red y S_{true} es la señal acústica medida. Este entrenamiento permite a la red supervisora aprender implícitamente las características físicas del proceso fotoacústico, actuando como un simulador aprendido del sistema físico.

3.2.3. Flujo de Datos

Durante el proceso de reconstrucción, los datos fluyen de la siguiente manera: la señal acústica S ingresa a la red reestructora; la red reestructora genera una imagen reconstruida $\hat{I}$; esta imagen es procesada por la red supervisora para generar una señal acústica predicha $\hat{S}$; y finalmente, las diferentes pérdidas se calculan comparando las salidas con los valores objetivo.

Este diseño permite que la red reestructora aprenda no solo de la comparación directa con las imágenes objetivo, sino también de la retroalimentación proporcionada por la red supervisora a través de la consistencia física de las señales acústicas generadas.

3.2.4. Fine-tuning con Supervisión Física

El proceso de fine-tuning se realiza sobre la red reestructora previamente entrenada, incorporando un mecanismo de supervisión física a través de la red supervisora. Este proceso está diseñado para asegurar que las imágenes reconstruidas no solo sean visualmente precisas, sino que también mantengan consistencia con las propiedades físicas del sistema fotoacústico.

La estructura del fine-tuning involucra cuatro términos de pérdida complementarios:

$$\mathcal{L}_{total} = \lambda_{direct}\mathcal{L}_{direct} + \lambda_{physical}\mathcal{L}_{physical} + \lambda_{struct}\mathcal{L}_{struct} + \lambda_{similarity}\mathcal{P}_{similarity} \quad (3.15)$$

donde $\mathcal{L}_{direct}$ mide la discrepancia entre la imagen reconstruida $\hat{I}$ y la imagen objetivo I como $\mathcal{L}_{direct} = \text{MSE}(\hat{I}, I)$; $\mathcal{L}_{physical}$ evalúa la consistencia física comparando la señal acústica predicha

$\hat{S}$ con la señal real S mediante $\mathcal{L}_{physical} = \text{MSE}(\hat{S}, S)$; $\mathcal{L}_{struct}$ preserva las características estructurales de la imagen como $\mathcal{L}_{struct} = 1 - \text{SSIM}(\hat{I}, I)$; y $\mathcal{P}_{sim}$ es un término de penalización que previene que la red tome atajos durante el aprendizaje, definido como $\mathcal{P}_{sim} = \cos_similarity(\hat{I}, S)$.

Los coeficientes λ ponderan la contribución de cada término en la pérdida total. Durante el fine-tuning, la red supervisora se mantiene con sus pesos congelados, actuando como un evaluador fijo de la consistencia física de las reconstrucciones. Esta red toma la imagen reconstruida $\hat{I}$ y genera una predicción de la señal acústica $\hat{S}$ que debería producir dicha imagen.

El término $\mathcal{L}_{physical}$ es particularmente importante ya que fuerza a la red reestructora a generar imágenes que, cuando son procesadas por la red supervisora, producen señales acústicas consistentes con las mediciones originales. Esto asegura que la reconstrucción no solo sea visualmente precisa ($\mathcal{L}_{direct}$ y $\mathcal{L}_{struct}$) sino que también respete las propiedades físicas del sistema fotoacústico.

El término de penalización $\mathcal{P}_{sim}$ es crucial para evitar que la red tome atajos en el proceso de aprendizaje. Sin esta penalización, la red podría tender a generar imágenes que son similares a las señales de entrada, lo cual produciría señales acústicas similares a las originales (minimizando $\mathcal{L}_{physical}$) pero no representaría una reconstrucción válida del objeto original.

Este enfoque de fine-tuning permite que la red reestructora refine sus predicciones incorporando conocimiento físico del sistema, mientras mantiene la calidad visual y estructural de las reconstrucciones. La combinación de los diferentes términos de pérdida asegura un balance entre la fidelidad de la reconstrucción y la consistencia física del resultado.

3.2.5. Simulación de Señales Fotoacústicas mediante Modelo de Espacio de Estados

Para entrenar las redes neuronales propuestas, es necesario generar un conjunto amplio de datos sintéticos que contengan pares de imágenes (absorción óptica) y sus correspondientes señales fotoacústicas. En esta sección, describimos el método utilizado para simular estas señales a partir de perfiles de absorción conocidos, basándonos en el modelo de espacio de estados lineal propuesto por Lang et al. [34].

Fundamento del Modelo de Espacio de Estados

El modelo de espacio de estados permite discretizar la ecuación diferencial parcial (PDE) de Stokes que describe la propagación y atenuación de ondas acústicas, transformándola en un sistema de ecuaciones de estado discreto. Este enfoque presenta varias ventajas: permite considerar la atenuación acústica dependiente de la frecuencia, incorpora la disminución de la intensidad del láser debido a la absorción, puede manejar perfiles de absorción óptica arbitrarios, y resulta computacionalmente más eficiente que resolver directamente las ecuaciones diferenciales parciales.

La ecuación de Stokes que describe la propagación de ondas acústicas con atenuación se expresa como:

$$\frac{\partial^2 p(z, t)}{\partial z^2} - \frac{1}{c_0^2} \frac{\partial^2 p(z, t)}{\partial t^2} + \tau \frac{\partial^3 p(z, t)}{\partial t \partial z^2} = -\frac{\beta}{C_p} \frac{\partial H(z, t)}{\partial t} \quad (3.16)$$

donde $p(z, t)$ es la presión local a profundidad z y tiempo t , c_0 es la velocidad del ultrasonido, τ es el tiempo de relajación que caracteriza la atenuación, β es el coeficiente de expansión térmica.

ca, C_p es el calor específico, y $H(z, t)$ es la función de calentamiento que representa la energía electromagnética absorbida.

Proceso de Discretización

El proceso de discretización transforma la PDE en un sistema de ecuaciones de estado discreto que puede ser expresado como:

$$\mathbf{x}_{k+1} = \mathbf{A}\mathbf{x}_k + \mathbf{g}u_k \quad (3.17)$$

$$y_k = \mathbf{c}^T \mathbf{x}_k + w_k \quad (3.18)$$

donde $\mathbf{x}_k = [p_k, p_{k-1}]^T$ es el vector de estado que contiene los perfiles de presión en los pasos de tiempo actual y anterior; $\mathbf{A}$ es la matriz de transición de estado que encapsula las propiedades acústicas del medio; $\mathbf{g}$ es el vector de entrada que relaciona la excitación con el cambio de estado; $u_k = i_k - i_{k-1}$ es la diferencia de la intensidad del láser entre pasos de tiempo consecutivos; y_k es la medición de presión en la superficie de la muestra; y w_k es el ruido de medición.

El vector $\mathbf{g}$ contiene implícitamente la información sobre el perfil de absorción óptica $\mu(z)$ a través del vector $\mathbf{d}$:

$$\mathbf{d} = \begin{bmatrix} \mu_0 \\ \mu_1 a_0 \\ \mu_2 a_1 a_0 \\ \vdots \\ \mu_{N_z-1} a_{N_z-2} a_{N_z-3} \cdots a_1 a_0 \end{bmatrix} \quad (3.19)$$

donde $a_n = e^{-\mu_n \Delta z}$ representa la atenuación de la intensidad del láser entre los puntos de la malla z_n y z_{n+1} . Este término permite considerar la disminución de la intensidad del láser con la profundidad debido a la absorción.

Implementación Numérica

Para simular las señales fotoacústicas a partir de un perfil de absorción $\mu(z)$, seguimos estos pasos: discretizamos el dominio espacial en N_z puntos equidistantes con separación Δz ; discretizamos el dominio temporal con paso Δt ; construimos las matrices $\mathbf{M}_1$, $\mathbf{M}_2$ y $\mathbf{M}_3$ según:

$$\mathbf{M}_1 = -\frac{1}{c_0^2 \Delta t^2} \mathbf{I} + \frac{\tau}{2\Delta t} \mathbf{D} \quad (3.20)$$

$$\mathbf{M}_2 = \mathbf{D} + \frac{2}{c_0^2 \Delta t^2} \mathbf{I} \quad (3.21)$$

$$\mathbf{M}_3 = -\frac{1}{c_0^2 \Delta t^2} \mathbf{I} - \frac{\tau}{2\Delta t} \mathbf{D} \quad (3.22)$$

donde $\mathbf{D}$ es la matriz de diferencias finitas centrales de segundo orden.

Calculamos la matriz de transición de estado $\mathbf{A}$ y el vector de entrada $\mathbf{g}$ como:

$$\mathbf{A} = \begin{bmatrix} \mathbf{M}_4 & \mathbf{M}_5 \\ \mathbf{I} & \mathbf{0} \end{bmatrix} \quad (3.23)$$

$$\mathbf{g} = \begin{bmatrix} \mathbf{f} \\ 0 \end{bmatrix} \quad (3.24)$$

donde $\mathbf{M}_4 = -\mathbf{M}_1^{-1}\mathbf{M}_2$, $\mathbf{M}_5 = -\mathbf{M}_1^{-1}\mathbf{M}_3$ y $\mathbf{f} = \mathbf{M}_1^{-1}\mathbf{b}$, siendo $\mathbf{b} = -\frac{\beta\chi}{C_p\Delta t}\mathbf{d}$.

Para una señal de modulación láser i_k dada, calculamos $u_k = i_k - i_{k-1}$, propagamos el sistema de estado desde una condición inicial $\mathbf{x}_0 = \mathbf{0}$ utilizando la ecuación de estado, y extraemos las mediciones de presión $y_k = \mathbf{c}^T \mathbf{x}_k$ en la superficie de la muestra ($z = 0$).

Esta simulación produce señales fotoacústicas que consideran la atenuación acústica dependiente de la frecuencia, la disminución de la intensidad del láser con la profundidad, y permite utilizar perfiles de absorción arbitrarios.

Parámetros de Simulación

Los principales parámetros utilizados en nuestras simulaciones son:

Parámetro	Valor	Unidad
Δt	10^{-9}	s
Δz	30×10^{-7}	m
N_z	20-100	-
N_y	100-2000	-
τ	77×10^{-12}	s
χ	3×10^{-2}	-
β/C_p	1/1	-
c_0	1500	m/s

Cuadro 3.1: Parámetros utilizados para el modelo de espacio de estados en la simulación de señales fotoacústicas.

Para cada perfil de absorción, generamos diferentes tipos de excitación láser: pulsos cortos (~ 10 ns) que aproximan una función delta, señales chirp con frecuencia variable, y señales optimizadas para maximizar la precisión de reconstrucción.

La simulación mediante este modelo de espacio de estados nos permite generar un conjunto amplio y diverso de pares de datos (imagen, señal fotoacústica) que son utilizados para entrenar y validar nuestras redes neuronales duales, manteniendo la consistencia física entre las imágenes y sus correspondientes señales fotoacústicas.

Capítulo 4

Implementación

Este capítulo describe detalladamente la implementación del sistema de redes neuronales duales propuesto para la reconstrucción de imágenes fotoacústicas. Se presentan las especificaciones técnicas de las arquitecturas utilizadas, los hiperparámetros de entrenamiento seleccionados, el pipeline completo de adquisición y procesamiento de datos, y las métricas de evaluación empleadas para validar el enfoque propuesto.

4.1. Especificaciones Técnicas

El desarrollo e implementación del sistema se realizó utilizando PyTorch 1.7.1 como framework principal, ejecutándose sobre Python 3.8.5. Esta combinación proporciona un equilibrio óptimo entre flexibilidad para el diseño arquitectónico y eficiencia computacional durante las fases de entrenamiento e inferencia. El código fuente completo, incluyendo los scripts de procesamiento de datos, entrenamiento y evaluación, se encuentra disponible en un repositorio público de GitHub para facilitar la reproducibilidad de los resultados.

4.1.1. Arquitectura del Sistema

Para ambas redes neuronales —reconstructora y supervisora— se implementó una arquitectura U-Net modificada. Esta elección se fundamenta en la capacidad demostrada de U-Net para preservar información contextual y detalles estructurales finos simultáneamente, características particularmente relevantes para la reconstrucción de imágenes fotoacústicas donde las estructuras vasculares representan elementos críticos.

La arquitectura específica implementada se detalla en la Tabla 4.1, donde cada “Double Conv” consiste en dos capas convolucionales consecutivas con kernels 3×3 , seguidas de normalización por lotes (BatchNorm) y activación ReLU. Esta configuración permite la extracción progresiva de características a múltiples escalas mientras mantiene un campo receptivo creciente.

El encoder está compuesto por cuatro bloques convolucionales con reducción progresiva de resolución espacial mediante operaciones de max-pooling, permitiendo capturar características cada vez más abstractas. En el punto de máxima compresión, el bottleneck concentra la información en 1024 canales antes de comenzar el proceso de upsampling. El decoder, por su parte, incorpora conexiones de salto (skip connections) que concatenan características correspondientes del encoder, preservando así información espacial crítica que podría perderse durante la compresión.




Figura 4.1: Arquitectura de la red propuesta.

Sección	Capa	Operación	Canales (in/out)
Encoder	enc1	Double Conv + ReLU	$1 \rightarrow 64$
	enc2	MaxPool + Double Conv + ReLU	$64 \rightarrow 128$
	enc3	MaxPool + Double Conv + ReLU	$128 \rightarrow 256$
	enc4	MaxPool + Double Conv + ReLU	$256 \rightarrow 512$
Bottleneck	bottleneck	MaxPool + Double Conv + ReLU	$512 \rightarrow 1024$
Decoder	dec4	ConvTranspose + Concat + Double Conv	$(1024+512) \rightarrow 512$
	dec3	ConvTranspose + Concat + Double Conv	$(512+256) \rightarrow 256$
	dec2	ConvTranspose + Concat + Double Conv	$(256+128) \rightarrow 128$
	dec1	ConvTranspose + Concat + Double Conv	$(128+64) \rightarrow 64$
Salida	final	Conv 1x1	$64 \rightarrow 1$

Cuadro 4.1: Arquitectura del modelo U-Net. Cada 'Double Conv' consiste en dos capas convolucionales 3x3 seguidas de BatchNorm y ReLU. Las operaciones ConvTranspose tienen kernel 2x2 y stride 2.

Esta estructura permite a la red aprender representaciones jerárquicas, como se evidencia en el análisis visual de los mapas de activación presentados en la sección de Resultados (Figura 5.11), donde se observa una especialización progresiva desde patrones generales hasta estructuras específicas. Los mapas de atención (Figura 5.12) muestran que en las capas profundas del decodificador el modelo presta atención a características globales, mientras que en las capas superficiales se enfoca en detalles locales y bordes.

4.1.2. Hiperparámetros de Entrenamiento

Dada la naturaleza dual del proceso de entrenamiento propuesto, los hiperparámetros se configuraron específicamente para cada fase: preentrenamiento individual y fine-tuning con supervisión física.

Preentrenamiento Durante la fase de preentrenamiento, tanto la red reconstructora como la supervisora se entrenaron de manera independiente utilizando los hiperparámetros detallados en la Tabla 4.2. El optimizador Adam fue seleccionado por su capacidad para adaptar dinámicamente las tasas de aprendizaje a las características específicas del gradiente, facilitando una convergencia más rápida y estable.

Hiperparámetro	Valor
Optimizador	Adam
Learning rate inicial	0.001
Batch size	Determinado por dataloader
Número de épocas	150 (default)
Scheduler	ReduceLROnPlateau
Scheduler patience	5 épocas
Scheduler factor	0.5
Función de pérdida	MSE

Cuadro 4.2: Hiperparámetros utilizados en el entrenamiento del modelo

El scheduler ReduceLROnPlateau se configuró para monitorear la pérdida de validación, reduciendo el learning rate por un factor de 0.5 después de 5 épocas sin mejora significativa. Esta estrategia adaptativa permite que el entrenamiento supere mesetas de convergencia local, manteniendo una tasa de aprendizaje óptima a lo largo del proceso de optimización.

Como se observa en los perfiles de entrenamiento (Figura 5.1), la dinámica de aprendizaje difiere significativamente entre ambas redes. La red reconstructora presenta una rápida convergencia inicial (>85 % en las primeras 20 épocas), mientras que la red supervisora muestra una convergencia más lenta y valores de pérdida finales aproximadamente 8 veces mayores (MSE validación: 0.0588 vs 0.0070). Esta asimetría evidencia la mayor dificultad inherente al problema inverso de supervisión, justificando el enfoque de entrenamiento dual propuesto.

Fine-tuning La fase crítica de fine-tuning, donde se incorpora la supervisión física, utilizó una configuración más elaborada (Tabla 4.3) que incluye múltiples componentes en la función de pérdida para guiar el proceso de optimización hacia soluciones físicamente consistentes.

La función de pérdida compuesta incorpora cuatro componentes con pesos específicos:

Hiperparámetro	Valor
Optimizador	Adam
Learning rate inicial	0.001
Número de épocas	100 (default)
Scheduler	ReduceLROnPlateau
Scheduler patience	5 épocas
Scheduler factor	0.5
Función de pérdida	MSE + Pérdida estructural + Pérdida física + Penalización similitud
Pesos de las pérdidas	
λ_{direct}	1.0
$\lambda_{physical}$	0.1
λ_{struct}	2.0
$\lambda_{similarity}$	0.3
Otros	
Gradiente clipping	1.0
Seed	42

Cuadro 4.3: Hiperparámetros del entrenamiento supervisado

1. Pérdida directa (MSE entre la imagen reconstruida y el objetivo): $L_{recon} = MSE(\hat{I}, I)$
2. Pérdida física (consistencia con el modelo fotoacústico): $L_{physics} = MSE(\hat{S}, S)$
3. Pérdida estructural (basada en SSIM): $L_{struct} = 1 - SSIM(\hat{I}, I)$
4. Penalización de similitud (previene atajos durante el aprendizaje): $P_{sim} = cos_similarity(\hat{I}, S)$

Los pesos fueron determinados mediante experimentación exhaustiva, priorizando la pérdida estructural ($\lambda_{struct} = 2,0$) para preservar detalles finos mientras se mantiene un balance con las restricciones físicas ($\lambda_{physical} = 0,1$).

Esta configuración permite observar patrones de transferencia de conocimiento secuencial durante el fine-tuning (Figura 5.2): una fase inicial (épocas 1-20) con alta volatilidad en la pérdida física, una fase de estabilización (épocas 20-60) con reducción gradual de la pérdida física, y una fase de convergencia (épocas 60-100) donde todas las componentes se estabilizan, demostrando un equilibrio efectivo entre reconstrucción visual y consistencia física.

4.2. Pipeline de Entrenamiento

El proceso completo de entrenamiento se estructuró como un pipeline secuencial con fases claramente definidas, desde la adquisición y preprocesamiento de datos hasta el fine-tuning con supervisión física.

4.2.1. Obtención de Datos

Para superar las limitaciones en la obtención de datos experimentales fotoacústicos (equipo especializado de alto costo y protocolos experimentales complejos), se implementó un pipeline de simulación física basado en el modelo de espacio de estados propuesto por Lang et al. para la propagación de ondas acústicas en medios heterogéneos.

El procedimiento específico involucró:

1. Selección de un dataset público de imágenes de retina con diferentes patrones vasculares
2. Ampliación mediante técnicas de aumento de datos hasta obtener 13,000 muestras
3. Generación de señales fotoacústicas correspondientes utilizando el modelo físico de espacio de estados

Este enfoque permitió crear un conjunto de datos sintético de 5,000 imágenes de 128×128 píxeles, proporcionando una base sólida para el entrenamiento y validación del modelo propuesto.

4.2.2. Preentrenamiento

El preentrenamiento de ambas redes se realizó de manera independiente utilizando conjuntos de datos específicos para cada una:

- **Red reconstructora:** Se entrenó con pares compuestos por señales fotoacústicas simuladas (entrada) e imágenes originales (objetivo), aprendiendo el mapeo directo del dominio de señales al dominio de imágenes.
- **Red supervisora:** Se entrenó con el mapeo inverso —imágenes como entrada y señales fotoacústicas como objetivo— aprendiendo a emular el proceso físico de generación de señales.

En ambos casos, se implementó una división del dataset en proporción 80 %-20 % para entrenamiento y validación, respectivamente. El proceso de entrenamiento se monitorizó mediante múltiples métricas para evaluar el progreso cualitativo y cuantitativo.

4.2.3. Fine-tuning

La fase crítica de fine-tuning constituye la contribución metodológica central de este trabajo. Durante esta fase, la red reconstructora previamente entrenada se refina mediante un proceso que incorpora la supervisión física proporcionada por la red supervisora, cuyas ponderaciones se mantienen fijas.

Como se evidencia en los experimentos de ablación (Figuras 5.4 y 5.5), la eliminación de cualquiera de los componentes principales (físico o estructural) resulta en un deterioro sustancial del rendimiento:

- **Sin componente físico:** La reconstrucción muestra una convergencia extremadamente rápida pero artificial, con una brecha sustancial entre entrenamiento y validación que sugiere optimización para características superficiales.
- **Sin componente estructural:** Se observa la dinámica más inestable de todos los experimentos, con fluctuaciones pronunciadas durante las primeras 20 épocas y una pérdida física que inicia en valores extremadamente altos (cerca de 2.0).

Estos resultados confirman la importancia crítica de ambos componentes en el proceso de fine-tuning, demostrando su naturaleza complementaria y sinérgica.

4.3. Métricas de Evaluación

Para evaluar exhaustivamente el desempeño del modelo propuesto, se implementó un conjunto integral de métricas que abordan diferentes aspectos de la calidad de reconstrucción, eficiencia computacional y significancia estadística, alineadas con las utilizadas en el análisis de resultados del Capítulo 5.

4.3.1. Calidad de Reconstrucción

La evaluación primaria de la calidad de las imágenes reconstruidas se realizó mediante un conjunto de métricas complementarias:

Peak Signal-to-Noise Ratio (PSNR) mide la relación entre la máxima potencia posible de una señal y el ruido que afecta a su representación:

$$\text{PSNR} = 10 \cdot \log_{10} \left(\frac{\text{MAX}^2}{\text{MSE}} \right) \quad (4.1)$$

donde MAX representa el valor máximo posible del píxel (1.0 en imágenes normalizadas).

Mean Square Error (MSE) cuantifica la diferencia cuadrática promedio entre las imágenes reconstruidas y las originales:

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (4.2)$$

Normalized Root Mean Square Error (NRMSE) proporciona una versión normalizada del RMSE para facilitar comparaciones entre diferentes escalas:

$$\text{NRMSE} = \frac{\sqrt{\text{MSE}}}{y_{\text{máx}} - y_{\text{mín}}} \quad (4.3)$$

Structural Similarity Index (SSIM) evalúa la similitud estructural entre las imágenes reconstruidas y las originales, considerando luminancia, contraste y estructura:

$$\text{SSIM}(x, y) = [l(x, y)]^\alpha \cdot [c(x, y)]^\beta \cdot [s(x, y)]^\gamma \quad (4.4)$$

donde l , c y s representan comparaciones de luminancia, contraste y estructura respectivamente.

Mean Absolute Error (MAE) proporciona una medida directa de la diferencia absoluta entre los valores predichos y reales:

$$\text{MAE} = \frac{1}{n} \cdot \sum_{i=1}^n |y_i - \hat{y}_i| \quad (4.5)$$

Como se demuestra en los resultados experimentales (Figuras 5.6 y ??), estas métricas capturan diferentes aspectos de la calidad de reconstrucción, con mejoras sustanciales en el modelo de fine-tuning completo: reducción del 30.7 % en MSE, mejora del 18.9 % en MAE y aumento del 14.5 % en SSIM.

4.3.2. Análisis Visuales Específicos

Además de las métricas cuantitativas, se implementaron análisis visuales específicos que posteriormente resultaron fundamentales para la evaluación cualitativa de los resultados:

Mapas de error absoluto: Visualizan la distribución espacial del error, permitiendo identificar regiones problemáticas en la reconstrucción (Figura 5.9, fila superior).

Mapas de SSIM local: Representan la similitud estructural localizada, revelando áreas donde se preservan mejor las características estructurales (Figura 5.9, fila inferior).

Perfiles de intensidad: Muestran cortes transversales de la intensidad a lo largo de líneas específicas, permitiendo comparar la fidelidad en la reconstrucción de estructuras finas (Figura 5.10).

Mapas de activación de características: Visualizan las representaciones intermedias aprendidas por las redes, revelando la especialización progresiva desde patrones generales hasta estructuras específicas (Figura 5.11).

Mapas de atención: Ilustran las regiones con mayor influencia en la salida del modelo, demostrando cómo diferentes capas atienden a características globales o locales (Figura 5.12).

4.3.3. Análisis Estadístico y Correlación

Para validar la significancia y robustez de los resultados, se implementaron rigurosos análisis estadísticos:

Pruebas de significancia estadística: Se aplicó la prueba t-pareada para comparar el rendimiento entre configuraciones, estableciendo un nivel de significancia $\alpha = 0,05$.

Intervalos de confianza del 95 %: Calculados para todas las métricas de rendimiento, proporcionando una medida de la incertidumbre en las estimaciones.

Análisis de correlación: Se realizaron análisis de dispersión correlacionando características de complejidad de las imágenes (entropía, densidad de bordes) con la mejora relativa en métricas de calidad (Figura 5.7), revelando patrones fundamentales sobre la robustez y adaptabilidad de la estrategia propuesta.

Tamaño del efecto: Se calculó la d de Cohen para cuantificar no solo la significancia estadística sino también la magnitud práctica de las mejoras observadas.

Estos análisis demostraron que la incorporación de conocimiento físico no solo mejora la calidad de reconstrucción sino que también actúa como un regularizador implícito, estabilizando el proceso de aprendizaje. La red con componente físico mostró una correlación negativa menos pronunciada con la entropía de imagen ($r=-0.16$) comparada con el modelo sin componente física ($r=-0.31$, $p<0.001$), evidenciando mayor robustez frente a escenarios complejos.

Este conjunto integral de métricas y análisis proporciona una base sólida para la evaluación exhaustiva del enfoque propuesto, permitiendo comparaciones objetivas con métodos alternativos de reconstrucción y fundamentando rigurosamente las conclusiones extraídas en el Capítulo 5.

Capítulo 5

Experimentos y Resultados

En este capítulo se presenta la evaluación experimental completa de la estrategia de entrenamiento propuesta basada en redes neuronales duales con supervisión física. Los experimentos se han diseñado meticulosamente para demostrar cómo esta metodología mejora el proceso de aprendizaje y conduce a soluciones más robustas, utilizando la reconstrucción fotoacústica como caso de estudio. Posteriormente, se analizan las implicaciones más amplias de estos hallazgos, contrastándolos con el estado actual del campo, y se discuten tanto las fortalezas como las limitaciones del enfoque propuesto.

5.1. Diseño Experimental

Esta sección describe el diseño experimental implementado para evaluar la efectividad de la estrategia de entrenamiento dual con supervisión física. Se detallan los conjuntos de datos utilizados, las configuraciones experimentales, las métricas de evaluación y el análisis del proceso de entrenamiento.

5.1.1. Conjunto de Datos

Para la experimentación se utilizó un conjunto de datos sintético derivado de imágenes de vasos sanguíneos de retina. El procedimiento de generación de datos consistió en la selección de un dataset público de imágenes de retina con diferentes patrones vasculares, que posteriormente fue ampliado mediante técnicas de aumento de datos hasta obtener 13,000 muestras. Finalmente, se generaron las señales fotoacústicas correspondientes utilizando el modelo físico de espacio de estados propuesto por Lang et al. [34]. Este enfoque permitió crear un conjunto de datos de entrenamiento suficientemente grande mientras se mantenía la consistencia física entre las imágenes y sus correspondientes señales fotoacústicas.

5.1.2. Configuración de Experimentos

Se diseñaron experimentos para evaluar sistemáticamente la efectividad de la estrategia de entrenamiento propuesta y la contribución de cada componente de la función de pérdida. La Tabla 5.1 muestra las configuraciones experimentales utilizadas, donde cada una explora diferentes aspectos del método propuesto.

Experimento	λ_{direct}	$\lambda_{physical}$	λ_{struct}	$\lambda_{similarity}$	Propósito del Experimento
Baseline	1.0	0.0	0.0	0.0	Evaluar el rendimiento del modelo pre-entrenado sin fine-tuning
FT Completo	1.0	0.1	2.0	0.3	Evaluar la estrategia completa de entrenamiento dual con fine-tuning supervisado físicamente
FT No-Struct	1.0	0.1	0.0	0.3	Analizar el impacto de la ausencia de la componente estructural en la transferencia de conocimiento
FT No-Physical	1.0	0.0	2.0	0.3	Determinar la contribución específica de la supervisión física en el proceso de fine-tuning

Cuadro 5.1: Configuraciones experimentales para evaluar la estrategia de entrenamiento propuesta y sus componentes.

5.1.3. Métricas de Evaluación

Para evaluar comprehensivamente los diferentes aspectos de la estrategia de entrenamiento, se implementaron cuatro categorías de métricas. En primer lugar, se utilizaron métricas de calidad de reconstrucción (MSE, MAE, NRMSE, PSNR, SSIM) para evaluar la precisión de las imágenes reconstruidas. Adicionalmente, se monitorizaron métricas de eficiencia de entrenamiento mediante curvas de convergencia y análisis de estabilidad. Para evaluar la transferencia de conocimiento, se analizó la evolución de las diferentes componentes de pérdida a lo largo del proceso de entrenamiento. Finalmente, se aplicaron pruebas estadísticas de significancia (t pareada, Wilcoxon) y se calculó el tamaño del efecto (d de Cohen) para validar la robustez de los resultados obtenidos.


5.2. Análisis del Proceso de Entrenamiento Dual

Esta sección analiza el comportamiento de la estrategia de entrenamiento propuesta, centrándose en cómo cada fase contribuye al proceso de aprendizaje y en la dinámica de transferencia de conocimiento entre las redes.


5.2.1. Dinámica del Preentrenamiento

El análisis del preentrenamiento independiente de cada red revela dinámicas de aprendizaje distintivas que reflejan la naturaleza asimétrica del problema fotoacústico directo e inverso.

Como se observa en la Figura 5.1, la red reconstructora presenta una rápida convergencia inicial en la pérdida de entrenamiento, con una tasa de descenso superior al 85 % en las primeras 20 épocas. Sin embargo, la pérdida de validación muestra un comportamiento más conservador, estabilizándose en un MSE de 0.0070. Esta brecha persistente de aproximadamente 15 % de diferencia relativa sugiere un posible overfitting moderado, a pesar de las estrategias de augmentación de da-



(a) Red reconstructora



(b) Red supervisora

Figura 5.1: Evolución de las pérdidas durante el entrenamiento de las redes duales: (a) Reconstructora exhibe una rápida disminución inicial de la pérdida de entrenamiento, generando una brecha significativa con la validación; (b) Supervisora muestra menor divergencia entre curvas pero alcanza valores de pérdida más altos (MSE validación: 0.0588 vs 0.0070 en (a)), evidenciando la mayor dificultad inherente al problema inverso de supervisión.

tos implementadas. No obstante, el MSE final demuestra una reconstrucción efectiva con un error inferior al 1 % en escala normalizada.

En contraste, la red supervisora exhibe una dinámica de entrenamiento completamente distinta. Se observa una convergencia prematura alrededor de la época 80, con un MSE de validación de 0.0588, aproximadamente 8 veces mayor que el de la red reconstructora. La brecha entre entrenamiento y validación es menor al 5 %, lo que descarta el overfitting pero sugiere limitaciones intrínsecas del problema inverso, caracterizado por el mapeo no lineal de señal a imagen. La proximidad de las curvas con un error elevado apunta a un posible underfitting, indicando que podría beneficiarse de una arquitectura con mayor capacidad modelizadora.

Esta marcada diferencia en las dinámicas de entrenamiento subraya la asimetría fundamental entre los problemas directo e inverso en el dominio fotoacústico, y justifica plenamente el enfoque de entrenamiento dual propuesto en este trabajo.

5.2.2. Dinámica de Transferencia de Conocimiento en el Fine-tuning

La Figura 5.2 ilustra la evolución de las diferentes componentes de pérdida durante el proceso de fine-tuning con supervisión física, revelando un patrón de transferencia de conocimiento secuencial.

El proceso de fine-tuning puede dividirse en tres fases claramente diferenciadas. Durante la fase inicial (épocas 1-20), se observa una alta volatilidad en la pérdida física (oscilando entre 0.4-0.5) mientras la red comienza a incorporar las restricciones físicas, manteniendo relativamente estable la pérdida directa. En la fase de estabilización (épocas 20-60), se produce una reducción gradual y más estable de la pérdida física hasta aproximadamente 0.2, indicando que la red está aprendiendo a balancear efectivamente las restricciones físicas con la calidad visual. Finalmente, en la fase de convergencia (épocas 60-100), todas las componentes de pérdida se estabilizan, con la pérdida física convergiendo a aproximadamente 0.13, demostrando un equilibrio efectivo entre reconstrucción visual y consistencia física.

Este patrón de evolución evidencia cómo la estrategia de fine-tuning facilita una transferencia gradual y efectiva del conocimiento físico a la red reconstructora, permitiendo que ésta incorpore restricciones físicas sin comprometer la calidad visual de las reconstrucciones.




Figura 5.2: Evolución de las componentes de pérdida durante el fine-tuning completo. Obsérvese cómo la pérdida física inicialmente alta se reduce progresivamente mientras la red aprende a incorporar el conocimiento físico sin comprometer la calidad de reconstrucción directa.

Para visualizar holísticamente el impacto del proceso de fine-tuning en todas las métricas simultáneamente, la Figura 5.3 presenta un diagrama de radar donde cada eje representa una métrica diferente, y el área total cubierta por el polígono indica la mejora global en la calidad de reconstrucción.




Figura 5.3: Diagrama de radar mostrando la evolución de las métricas de evaluación a lo largo del proceso de fine-tuning. Cada eje representa una métrica, y el área total cubierta por el polígono indica la mejora global en la calidad de reconstrucción.

5.3. Contribución de Componentes Específicos

Esta sección analiza experimentalmente la contribución individual de cada componente clave de la función de pérdida, proporcionando evidencia empírica sobre su rol en la estrategia de entrenamiento propuesta.

5.3.1. Impacto del Componente de Supervisión Física

Para evaluar la contribución específica del componente de supervisión física, se analizó la evolución de las pérdidas al eliminar este componente de la función de pérdida ($\lambda_{physical} = 0$).




Figura 5.4: Evolución de pérdidas sin componente física. Nótese la convergencia artificialmente rápida de la validación y la elevada brecha entre curvas de entrenamiento y validación.

Como se observa en la Figura 5.4, la eliminación del componente físico provoca una convergencia extremadamente rápida de la pérdida de validación hacia valores notablemente bajos (Min Val Loss: 0.0019), contrastando drásticamente con la pérdida de entrenamiento que se estabiliza alrededor de 0.06. Esta brecha sustancial entre entrenamiento y validación (aproximadamente 30 veces mayor) sugiere un comportamiento atípico del modelo, posiblemente indicando que está optimizando para características superficiales que no capturan adecuadamente la complejidad del problema fotoacústico.

En ausencia de la restricción física, la pérdida estructural (componente naranja) asume un rol predominante, exhibiendo un comportamiento oscilatorio inicial antes de estabilizarse gradualmente en valores cercanos a 0.04. Mientras tanto, la evolución del componente de pérdida física (mostrado en púrpura pero no utilizado para optimización) permanece elevado y estable alrededor de 0.06, evidenciando que el modelo no está aprendiendo a satisfacer las restricciones físicas a pesar de mejorar en otras métricas.

Estas observaciones subrayan que el componente físico, lejos de ser redundante, actúa como un mecanismo de regulación esencial que guía la red hacia soluciones que no solo son visualmente plausibles sino también físicamente coherentes.

5.3.2. Rol del Componente Estructural

Para comprender el papel del componente estructural en la transferencia de conocimiento, se analizó la evolución de las pérdidas al eliminar dicho componente ($\lambda_{struct} = 0$).




Figura 5.5: Evolución de pérdidas sin componente estructural. Se observa una inestabilidad pronunciada en todos los componentes de pérdida, especialmente durante las primeras épocas.

La Figura 5.5 revela la dinámica más inestable de todos los experimentos realizados. Se observa una pérdida física que inicia en valores extremadamente altos (cerca de 2.0) y exhibe fluctuaciones pronunciadas durante las primeras 20 épocas. A pesar de que la pérdida de validación alcanza valores artificialmente bajos (Min Val Loss: 0.0002), esta aparente mejora viene acompañada de una inestabilidad severa en otros componentes, sugiriendo un desequilibrio fundamental en el proceso de aprendizaje.

La ausencia del componente estructural provoca que el modelo oscile dramáticamente mientras intenta satisfacer las restricciones físicas, evidenciando que la guía estructural actúa como un estabilizador crítico del entrenamiento. Adicionalmente, se observa una brecha extrema entre las curvas de entrenamiento y validación, indicando una posible pérdida de capacidad de generalización, a pesar de los valores numéricamente favorables en ciertas métricas.

Estos resultados demuestran que el componente estructural no solo mejora la calidad visual de las reconstrucciones, sino que cumple un rol fundamental como estabilizador del proceso de aprendizaje, facilitando la incorporación efectiva del conocimiento físico al proporcionar restricciones complementarias que guían al modelo hacia soluciones más coherentes.

5.3.3. Sinergia entre Componentes

El análisis comparativo de las distintas configuraciones experimentales revela interacciones sinérgicas entre los componentes de la función de pérdida. Las oscilaciones observadas en los experimentos de ablación contrastan notablemente con la trayectoria más suave y estable del fine-tuning completo, sugiriendo que los componentes estructural y físico no solo contribuyen a diferentes aspectos de la reconstrucción, sino que también se estabilizan mutuamente.

Particularmente revelador es el caso del experimento sin componente estructural, que exhibe una brecha de validación artificialmente pequeña (Min Val Loss: 0.0002), pero acompañada de inestabilidades significativas en los otros componentes. Esto indica que la aparente mejora numérica no refleja una reconstrucción de mejor calidad, sino más bien un comportamiento anómalo del proceso de optimización.

La evolución de pérdidas en el fine-tuning completo muestra un patrón donde las curvas de entrenamiento y validación convergen gradualmente sin fluctuaciones extremas, sugiriendo un balance óptimo entre los diferentes componentes. Este comportamiento confirma que tanto el componente estructural como el físico proporcionan restricciones complementarias esenciales: el estructural facilita la captura de características visuales significativas, mientras que el componente físico asegura la consistencia con las propiedades fundamentales del problema fotoacústico.

5.4. Análisis Comparativo Integral

Esta sección presenta un análisis comparativo integral de los resultados obtenidos con la estrategia de entrenamiento propuesta, evaluando su efectividad en términos de calidad de reconstrucción, estabilidad y robustez frente a diferentes escenarios.

5.4.1. Perfil de Mejora Multimétrico

El análisis comparativo de mejoras porcentuales respecto al baseline, ilustrado en la Figura 5.6, revela patrones significativos que cuantifican el impacto de cada componente de la función de

pérdida.




Figura 5.6: Análisis comparativo del porcentaje de mejora/deterioro en las diferentes métricas para cada configuración experimental, tomando como referencia el modelo pre-entrenado (Baseline).

Se observa una superioridad consistente del fine-tuning completo (FT-Completo), que muestra mejoras sustanciales en todas las métricas evaluadas, destacando especialmente una reducción del 30.7 % en MSE, 18.9 % en MAE y 15.8 % en NRMSE. Esta consistencia a través de diferentes métricas subraya la robustez del enfoque propuesto.

El análisis también revela una contribución asimétrica de los componentes. La ablación de los componentes físico y estructural impacta diferencialmente las métricas de evaluación. Mientras que sin el componente físico se mantiene una mejora moderada en SSIM (8.2 %), la ausencia del componente estructural degrada dramáticamente esta métrica, reduciéndola a apenas un 0.5 % de mejora. Este comportamiento evidencia la especialización funcional de cada componente.

Adicionalmente, los experimentos de ablación demuestran la complementariedad entre componentes, revelando que ninguno de ellos por sí solo puede replicar el rendimiento del modelo completo. La mejora en MSE cae drásticamente de 30.7 % a 2.8 % y 2.1 % al eliminar los componentes físico y estructural, respectivamente, evidenciando su naturaleza complementaria y la importancia de su incorporación conjunta.

Modelo	MSE	MAE	NRMSE	PSNR	SSIM
Baseline	0.004 ± 0.003	0.04 ± 0.010	0.070 ± 0.020	24.984 ± 2.424	0.633 ± 0.141
FT-Completo	0.003 ± 0.002	0.031 ± 0.011	0.059 ± 0.018	26.477 ± 2.371	0.724 ± 0.132
FT-No-Physical	0.004 ± 0.003	0.036 ± 0.015	0.069 ± 0.024	25.265 ± 2.715	0.685 ± 0.157
FT-No-Structural	0.004 ± 0.003	0.036 ± 0.014	0.069 ± 0.024	25.167 ± 2.589	0.636 ± 0.142

Cuadro 5.2: Resultados comparativos de rendimiento entre diferentes configuraciones de fine-tuning. Los mejores resultados se muestran en negrita.

5.4.2. Análisis por Categorías de Métricas

Un análisis más detallado de las métricas presentadas en la Tabla 5.2 revela tres categorías distintas de impacto. En primer lugar, para las métricas de error pixel-a-pixel (MSE, MAE y NRMSE),

el fine-tuning completo logra las mejoras más significativas (30.7 %, 18.9 % y 15.8 %, respectivamente), mientras que los modelos ablacionados muestran mejoras marginales entre 1.3 % y 5.9 %. Los valores absolutos confirman esta tendencia, con el FT-Completo alcanzando un MSE de 0.0026 ± 0.0017 frente a 0.0037 ± 0.0031 de los modelos ablacionados.

En segundo lugar, para las métricas de calidad perceptual (PSNR y SSIM), que aproximan mejor la percepción humana, se observa una tendencia similar pero con diferencias más pronunciadas entre los modelos. El SSIM muestra una sensibilidad particular al componente estructural, con una caída de mejora del 14.5 % a apenas 0.5 % cuando se elimina este componente.

Finalmente, en términos de estabilidad y consistencia, la desviación estándar en todas las métricas es considerablemente menor para el FT-Completo (por ejemplo, ± 0.0017 en MSE frente a ± 0.0031 para los modelos ablacionados), evidenciando que la combinación de componentes no solo mejora el rendimiento promedio sino que también incrementa la robustez y consistencia de las reconstrucciones.

5.4.3. Implicaciones para la Reconstrucción Fotoacústica

Los resultados cuantitativos validan las observaciones cualitativas de las curvas de entrenamiento analizadas previamente. La aparente ventaja en las curvas de validación de los modelos ablacionados (Min Val Loss: 0.0019 y 0.0002) no se traduce en mejores métricas de evaluación, confirmando la hipótesis del sobreajuste a características superficiales.

Particularmente relevante es la observación de que la combinación sinérgica de los componentes físico y estructural produce un efecto multiplicativo en lugar de meramente aditivo, con mejoras porcentuales que superan ampliamente la suma de las mejoras individuales (30.7 % vs. 2.8 % + 2.1 %). Esta sinergia constituye una de las contribuciones centrales de este trabajo.

Adicionalmente, la degradación más severa en SSIM al eliminar el componente estructural (de 14.5 % a 0.5 %) y la mayor caída en NRMSE al eliminar el componente físico (de 15.8 % a 2.0 %) confirman la especialización funcional de cada componente: el estructural optimiza la coherencia visual mientras que el físico garantiza la fidelidad cuantitativa.

Estos resultados cuantitativos proporcionan evidencia concluyente de que la estrategia de fine-tuning completo no solo mejora significativamente el rendimiento absoluto, sino que también ofrece un balance óptimo entre fidelidad visual y consistencia física, validando la hipótesis central de esta investigación.

5.4.4. Análisis de Dispersión de Casos

Para identificar patrones específicos en cómo los diferentes componentes de la estrategia de entrenamiento afectan a distintos tipos de imágenes, se realizó un análisis de dispersión correlacionando métricas de complejidad de imagen con las mejoras relativas obtenidas por cada modelo.

El análisis de dispersión, ilustrado en la Figura 5.7, revela patrones fundamentales sobre la robustez y adaptabilidad de la estrategia propuesta. Se observa una correlación negativa moderada entre la entropía de la imagen y la mejora en PSNR para todos los modelos ($r = -0.16$, $r = -0.31$, $r = -0.13$, respectivamente), indicando que la ganancia relativa tiende a disminuir a medida que aumenta la complejidad informacional de la imagen.

Particularmente relevante es el efecto estabilizador del componente físico. El modelo sin componente física (FT No-Physical) muestra la correlación negativa más pronunciada con la entropía




Figura 5.7: Análisis de dispersión que correlaciona características de complejidad de las imágenes con la mejora relativa en métricas de calidad. **Izquierda:** Correlación entre entropía de la imagen y mejora porcentual en PSNR. **Derecha:** Correlación entre densidad de bordes y mejora porcentual en SSIM. Las líneas punteadas representan las tendencias lineales para cada modelo, con sus respectivos coeficientes de correlación.

($r=-0.31$, $p<0.001$), evidenciando que la restricción física actúa como regularizador que incrementa la robustez frente a escenarios complejos. En ausencia de esta guía física, el modelo exhibe mayor sensibilidad a la variación en complejidad de entrada.

También se observan mejoras extraordinarias en casos específicos. El modelo FT Completo logra mejoras excepcionales ($\approx 40\%$ en PSNR, $\approx 200\%$ en SSIM) en casos particulares, demostrando que la estrategia dual puede provocar saltos cualitativos sustanciales en determinados escenarios, especialmente en el rango medio de densidad de bordes (0.05-0.10).

En contraste, el modelo FT No-Structural muestra numerosos casos por debajo de la línea de mejora cero, especialmente en imágenes de alta complejidad (entropía ≈ 4.0), confirmando el papel crítico de la pérdida estructural en la estabilidad general del proceso de aprendizaje.

La sustancial dispersión vertical en ambos gráficos, especialmente para FT Completo, revela que factores adicionales más allá de la simple complejidad o densidad de bordes influyen en el rendimiento del modelo. Esto sugiere que la arquitectura propuesta captura características más profundas y específicas en cada imagen que no pueden reducirse a métricas generales de complejidad.

Esta distribución no uniforme de mejoras confirma que la estrategia de entrenamiento dual proporciona ventajas distintivas en función del tipo de imagen, elevando dramáticamente el límite superior de calidad alcanzable en casos específicos donde las restricciones físicas y estructurales proporcionan información complementaria durante el proceso de aprendizaje.

5.5. Visualización de Resultados

Esta sección presenta un análisis visual detallado de los resultados obtenidos con la metodología propuesta, comparando el desempeño del modelo baseline, el fine-tuning completo, y las variantes ablativas.

5.5.1. Ejemplos Representativos de Reconstrucción

La Figura 5.8 muestra ejemplos representativos de reconstrucción para tres niveles de complejidad: alta, media y baja, permitiendo apreciar visualmente las mejoras cualitativas logradas por el modelo propuesto.

Los resultados visuales revelan varios aspectos importantes. En primer lugar, se aprecia una mejora significativa en la preservación de estructuras finas, donde el modelo FT Completo reproduce con mayor fidelidad las estructuras vasculares delgadas, especialmente en los casos de alta complejidad donde la red densa de vasos es más difícil de reconstruir.

También se observa una notable disminución de artefactos y ruido de fondo en las imágenes reconstruidas por el modelo FT Completo, resultando en imágenes más limpias y clínicamente interpretables.

La consistencia en diferentes niveles de complejidad, demostrada por las mejoras porcentuales significativas (54.0 %, 42.8 % y 51.9 %), evidencia que el enfoque propuesto es robusto ante diferentes niveles de complejidad estructural, una característica esencial para aplicaciones clínicas donde la variabilidad anatómica es considerable.

Adicionalmente, las imágenes reconstruidas por el modelo FT Completo presentan un mejor contraste entre las estructuras vasculares y el fondo, facilitando la identificación de los detalles anatómicos relevantes para el diagnóstico.




Figura 5.8: Ejemplos representativos de reconstrucción para diferentes niveles de complejidad. Las imágenes muestran la mejora significativa lograda por el modelo con fine-tuning completo, especialmente en estructuras vasculares finas. Los porcentajes indican la reducción del error absoluto medio respecto al modelo baseline.

Es importante destacar que la mejora no es uniforme en toda la imagen, como se evidencia en los mapas de diferencia absoluta donde las regiones más brillantes indican las áreas con mayor mejora respecto al modelo baseline. Este comportamiento sugiere que el modelo aprende a priorizar características estructuralmente significativas.

5.5.2. Análisis Espacial Comparativo

Para profundizar en el análisis comparativo, la Figura 5.9 presenta mapas de error absoluto y mapas de SSIM local para todas las variantes del modelo.




Figura 5.9: Análisis espacial comparativo. La fila superior muestra los mapas de error absoluto para las diferentes variantes del modelo. La fila inferior presenta los mapas de SSIM local, donde las regiones más claras indican mayor similitud estructural con la imagen objetivo.

El análisis de los mapas de error revela una distribución espacial del error significativamente mejorada en el modelo FT Completo, que presenta una reducción sustancial del error medio (0.0571) comparado con el baseline (0.1379) y las variantes ablativas (0.1409 y 0.1390).

Los mapas de SSIM local son particularmente reveladores, mostrando que el modelo FT Completo logra una similitud estructural sustancialmente mayor (SSIM: 0.6521) comparado con el baseline (SSIM: 0.1895) y las variantes sin componente física (SSIM: 0.1862) o estructural (SSIM: 0.1789). Estas diferencias son especialmente pronunciadas en las regiones correspondientes a estructuras vasculares finas, subrayando la importancia del enfoque propuesto para la preservación de detalles anatómicos críticos.

El impacto de la ablación de componentes se hace evidente en estos mapas, donde la eliminación de la componente física o estructural deteriora la calidad de reconstrucción, con un efecto particularmente dramático cuando se elimina la componente estructural, como se refleja en la disminución generalizada de la similitud estructural en el mapa de SSIM local correspondiente.

5.5.3. Perfiles de Intensidad

Para complementar el análisis espacial, la Figura 5.10 muestra perfiles de intensidad a lo largo de un corte transversal de las imágenes reconstruidas, permitiendo una comparación directa de la precisión en la reproducción de estructuras específicas.




Figura 5.10: Perfiles de intensidad a lo largo de un corte transversal. Se comparan los perfiles de intensidad normalizada entre la imagen objetivo (Ground Truth) y las reconstrucciones de las diferentes variantes del modelo.

El análisis de los perfiles de intensidad revela aspectos cualitativos importantes de las reconstrucciones. El modelo FT Completo (línea verde) reproduce con mayor precisión los picos de intensidad correspondientes a las estructuras vasculares presentes en la imagen objetivo (línea negra), manteniendo tanto la amplitud como la ubicación espacial de estas estructuras.


Se observa también una reducción significativa de falsos positivos en el modelo FT Completo, que muestra menos picos espurios entre las estructuras vasculares principales, lo que indica una mejor capacidad para distinguir entre estructuras genuinas y ruido. Esta característica es particularmente relevante en aplicaciones clínicas, donde los falsos positivos pueden conducir a interpretaciones diagnósticas erróneas.

La preservación del contraste es otro aspecto destacable, con una mejor diferenciación entre las estructuras vasculares y el fondo en el modelo FT Completo. Este aspecto facilita la identificación visual de estructuras anatómicas relevantes y contribuye a la interpretabilidad clínica de las reconstrucciones.

Las diferencias entre las variantes experimentales son evidentes en estos perfiles. El modelo sin componente física (línea roja) tiende a sobrestimar la intensidad en algunas regiones, generando picos con amplitud excesiva que no corresponden fielmente a la realidad anatómica. Por otro lado, el modelo sin componente estructural (línea púrpura) muestra un perfil más suavizado que pierde detalles importantes, particularmente en estructuras finas o de baja intensidad.

5.5.4. Visualización de Características Aprendidas

Para comprender mejor el funcionamiento interno de la arquitectura dual propuesta, se visualizaron los mapas de activación de características intermedias en diferentes etapas de las redes, como se muestra en la Figura 5.11.



Las activaciones muestran cómo evolucionan las representaciones a través de la arquitectura. En la red reconstructora, las características evolucionan de patrones de bordes generales a estructuras específicas, mientras que en la supervisora, capturan progresivamente las propiedades físicas del fenómeno fotoacústico.

Figura 5.11: Mapas de activación de características intermedias en las redes duales. La fila superior muestra las activaciones en diferentes etapas de la red reconstructora, mientras que la fila inferior muestra las activaciones en la red supervisora. Se observa la evolución de las representaciones desde patrones generales hasta estructuras específicas.

El análisis de estos mapas revela una especialización progresiva en las representaciones aprendidas. En la red reconstructora, las características evolucionan desde patrones de bordes generales en las capas iniciales hasta estructuras específicas en las capas más profundas, demostrando una jerarquía de abstracción que parte de características locales simples y progresa hacia representaciones de alto nivel.

Por su parte, la red supervisora captura progresivamente las propiedades físicas del fenómeno fotoacústico, como se evidencia en la transformación de la representación desde la imagen objetivo hasta características que reflejan la propagación de ondas acústicas. Esta captura implícita de la física del problema es fundamental para la efectividad del enfoque de supervisión física propuesto.

Un aspecto particularmente relevante es la complementariedad de las representaciones aprendidas por ambas redes. Mientras que la red reconstructora se especializa en características anatómicas y estructurales, la red supervisora captura aspectos relacionados con la física de propagación de ondas, justificando plenamente el enfoque dual propuesto en este trabajo y explicando la sinergia observada en los resultados cuantitativos.

Adicionalmente, se analizaron los mapas de atención en diferentes capas del decodificador de la red reconstructora, como se muestra en la Figura 5.12, para comprender mejor cómo el modelo prioriza diferentes regiones y características durante el proceso de reconstrucción.

El análisis de los mapas de atención revela una estrategia de procesamiento multinivel en la red reconstructora. En las capas profundas del decodificador (dec3), el modelo presta atención principalmente a características globales y relaciones de largo alcance, capturando la estructura general de la imagen y las relaciones espaciales entre diferentes elementos anatómicos.

En contraste, en las capas superficiales (dec1) el modelo se enfoca predominantemente en detalles locales y bordes, refinando la reconstrucción con información de alta frecuencia espacial que define con precisión los límites de las estructuras vasculares.




Figura 5.12: Mapas de atención en diferentes capas del decodificador de la red reconstructora. Las áreas en colores cálidos representan regiones con mayor influencia en la salida del modelo. En capas profundas (dec3) el modelo atiende a características globales, mientras que en capas superficiales (dec1) se enfoca en detalles locales y bordes.

Esta jerarquía de atención es consistente con la naturaleza del problema fotoacústico, donde tanto la estructura global como los detalles locales son relevantes para una reconstrucción fiel. La capacidad del modelo para adaptar sus patrones de atención a cada caso específico, como se observa al comparar las dos filas de ejemplos, demuestra su flexibilidad para abordar la variabilidad inherente a las imágenes médicas.

5.5.5. Hallazgos Clave del Análisis Visual

El análisis visual de los resultados permite extraer varios hallazgos clave que complementan y refuerzan las conclusiones derivadas del análisis cuantitativo. En primer lugar, se evidencia la importancia crítica de la componente estructural en la función de pérdida. La calidad de reconstrucción se deteriora dramáticamente cuando se elimina esta componente, como demuestran claramente los mapas de SSIM y los perfiles de intensidad, afectando particularmente la preservación de estructuras finas y detalles anatómicos relevantes.

En segundo lugar, el análisis visual confirma la complementariedad de las restricciones físicas y estructurales. Los mejores resultados, tanto en términos visuales como cuantitativos, se obtienen cuando se combinan ambas restricciones, validando la hipótesis central de este trabajo sobre la importancia de la consistencia física en la reconstrucción fotoacústica.

La capacidad de generalización del modelo también queda evidenciada en el análisis visual. El modelo FT Completo muestra un rendimiento robusto en casos de diferentes niveles de complejidad, desde estructuras vasculares simples hasta redes vasculares densas y complejas, lo que sugiere una buena capacidad para adaptarse a la variabilidad anatómica típica de entornos clínicos reales.

Uno de los beneficios más notables del enfoque propuesto, claramente visible en las reconstrucciones, es la mejor preservación de estructuras vasculares finas. Esta característica es particularmente importante en aplicaciones clínicas donde la visualización precisa de la microvasculatura puede ser crítica para el diagnóstico temprano de condiciones como la retinopatía diabética o ciertas

formas de cáncer.

Finalmente, la incorporación de restricciones físicas contribuye significativamente a la reducción de artefactos en las imágenes reconstruidas, como se observa en los mapas de error y los perfiles de intensidad. Esta reducción de artefactos mejora la interpretabilidad clínica de las imágenes y potencialmente reduce la tasa de falsos positivos en aplicaciones diagnósticas.

5.6. Interpretación de los Hallazgos Experimentales

Los hallazgos experimentales obtenidos a lo largo de este trabajo proporcionan una comprensión profunda de cómo la combinación de conocimiento físico y aprendizaje basado en datos puede mejorar significativamente la reconstrucción fotoacústica. A continuación, se interpretan los resultados clave y se discuten sus implicaciones para el campo.

5.6.1. Complementariedad entre Conocimiento Físico y Aprendizaje de Datos

Uno de los hallazgos más significativos de este trabajo es la evidencia empírica de la complementariedad entre el conocimiento físico y el aprendizaje basado en datos. Los experimentos de ablación demostraron claramente que la eliminación de cualquiera de los componentes principales (físico o estructural) resulta en un deterioro sustancial del rendimiento. La mejora en MSE cae drásticamente de 30.7 % a 2.8 % y 2.1 % al eliminar los componentes físico y estructural, respectivamente. De manera similar, la calidad perceptual, medida por SSIM, muestra una sensibilidad particular al componente estructural, con una caída de mejora del 14.5 % a apenas 0.5 % cuando se elimina este componente.

Estos resultados validan la hipótesis central de este trabajo: el conocimiento físico y el aprendizaje basado en datos ofrecen restricciones complementarias que, cuando se combinan adecuadamente, producen un efecto multiplicativo en lugar de meramente aditivo. Esta sinergia puede interpretarse desde una perspectiva de regularización: el conocimiento físico actúa como un regularizador implícito que guía el proceso de aprendizaje hacia soluciones físicamente plausibles, mientras que el aprendizaje basado en datos permite capturar patrones complejos que serían difíciles de modelar explícitamente mediante ecuaciones físicas.

5.6.2. La Física como Mecanismo de Estabilización del Aprendizaje

Los perfiles de entrenamiento revelaron un hallazgo inesperado pero significativo: el componente físico no solo mejora la calidad de reconstrucción, sino que también estabiliza el proceso de aprendizaje. La configuración sin componente físico (FT No-Physical) mostró la correlación negativa más pronunciada con la entropía de imagen ($r = -0,31$, $p < 0,001$), evidenciando que la restricción física actúa como regularizador que incrementa la robustez frente a escenarios complejos.

Este efecto estabilizador puede explicarse por el hecho de que la física del problema impone restricciones globales coherentes que limitan el espacio de soluciones posibles. Sin estas restricciones, la red neural tiende a sobreajustarse a características superficiales que pueden variar significativamente entre diferentes imágenes, resultando en un rendimiento inconsistente. La incorporación del conocimiento físico mediante la red supervisora proporciona una guía adicional que orienta

el proceso de optimización hacia soluciones físicamente válidas, reduciendo la variabilidad en el rendimiento y mejorando la generalización.

5.6.3. Distribución No Uniforme de Mejoras

El análisis de dispersión reveló que las mejoras no se distribuyen uniformemente entre todos los casos de prueba. Mientras que la mayoría de los casos muestran mejoras moderadas (5-20 % en PSNR), existe un subconjunto significativo donde la mejora es sustancialmente mayor (superior al 30 %). Esta distribución no uniforme sugiere que el método propuesto no solo mejora el rendimiento promedio, sino que también eleva dramáticamente el límite superior de calidad alcanzable en ciertos casos específicos.

Adicionalmente, los datos indican que existen factores adicionales más allá de la simple complejidad o densidad de bordes que influyen en el rendimiento del modelo. La sustancial dispersión vertical en los gráficos de correlación, especialmente para el modelo de fine-tuning completo, revela que la arquitectura propuesta captura características más profundas y específicas en cada imagen que no pueden reducirse a métricas generales de complejidad.

Esta observación tiene implicaciones importantes para aplicaciones clínicas, donde la mejora significativa en casos particulares podría ser crítica para el diagnóstico preciso de condiciones específicas. La capacidad del modelo para lograr mejoras sustanciales en ciertos casos desafiantes podría traducirse en una mayor sensibilidad diagnóstica precisamente donde más se necesita.

5.7. Comparación con Métodos Alternativos

En esta sección, se discuten las ventajas y desventajas del enfoque propuesto en comparación con métodos alternativos en el campo de la reconstrucción fotoacústica, incluyendo métodos basados en datos, PINN tradicionales y enfoques híbridos.

5.7.1. Ventajas sobre Métodos PINN Tradicionales

Comparado con los métodos de Physics-Informed Neural Networks (PINN) tradicionales, nuestro enfoque ofrece varias ventajas significativas. En primer lugar, la eficiencia computacional es sustancialmente mayor. Mientras que los PINN tradicionales requieren la evaluación de derivadas durante el entrenamiento, lo que aumenta significativamente el costo computacional, nuestro enfoque dual aprende implícitamente la física del problema sin necesidad de calcular derivadas explícitamente. Esta diferencia se traduce en tiempos de entrenamiento más cortos y requisitos de memoria reducidos, facilitando la aplicación del método en escenarios con recursos computacionales limitados.

Otra ventaja destacable es el balance estable de pérdidas que ofrece nuestra aproximación. Los PINN a menudo enfrentan desafíos durante el entrenamiento debido al desbalance entre los términos de pérdida física y de datos, como se discute en Zhou et al. [92]. Nuestro enfoque de fine-tuning con supervisión física proporciona un mecanismo natural para equilibrar estas diferentes fuentes de información, permitiendo una convergencia más estable y resultados más consistentes.

La flexibilidad arquitectónica constituye una tercera ventaja fundamental. Al separar la reconstrucción y la supervisión física en dos redes independientes, nuestro enfoque permite mayor libertad en el diseño arquitectónico, posibilitando que cada red se especialice en su tarea específica. Esta

separación de responsabilidades facilita la adaptación del método a diferentes escenarios y la experimentación con diversas arquitecturas para cada componente del sistema.

5.7.2. Ventajas sobre Métodos Puramente Basados en Datos

En comparación con enfoques de deep learning que no incorporan restricciones físicas explícitas, nuestro método demostró ventajas significativas en términos de robustez, calidad de reconstrucción y consistencia física. La incorporación de conocimiento físico mejora notablemente la robustez del modelo frente a variaciones en la complejidad de la imagen, como lo evidencia la menor correlación negativa con la entropía de imagen en el modelo completo ($r = -0,16$) comparado con el modelo sin componente física ($r = -0,31$).

El análisis visual demostró que nuestro enfoque preserva mejor las estructuras vasculares finas, que son particularmente importantes en aplicaciones clínicas. Esta mejora en la preservación de detalles estructurales se refleja cuantitativamente en el aumento del 14.5 % en la métrica SSIM, que es especialmente sensible a la similitud estructural entre imágenes.

Adicionalmente, la incorporación de restricciones físicas contribuye significativamente a la reducción de artefactos en las imágenes reconstruidas, como se evidencia en los mapas de error y los perfiles de intensidad presentados anteriormente. La consistencia física impuesta por la red supervisora actúa como un filtro natural que penaliza reconstrucciones físicamente implausibles, reduciendo la aparición de características espurias y falsos positivos que podrían comprometer la interpretabilidad clínica de las imágenes.

5.7.3. Posicionamiento en el Estado del Arte

Nuestro enfoque se posiciona estratégicamente como un punto medio entre los métodos puramente basados en datos y los PINN tradicionales, ofreciendo un equilibrio óptimo entre eficiencia computacional, calidad de reconstrucción y consistencia física. A diferencia de los enfoques híbridos existentes que utilizan redes neuronales para post-procesar reconstrucciones obtenidas con métodos tradicionales [16], nuestro método aprende directamente de los datos crudos, lo que potencialmente permite capturar relaciones más complejas entre las señales fotoacústicas y las imágenes reconstruidas.

Esta posición intermedia en el espectro metodológico aprovecha lo mejor de ambos mundos: la capacidad de generalización y flexibilidad de los métodos basados en datos, y la consistencia física y robustez de los métodos basados en principios físicos. El resultado es un framework que no solo mejora el rendimiento cuantitativo, sino que también produce reconstrucciones cualitativamente superiores con mayor relevancia clínica potencial.

5.8. Implicaciones para la Reconstrucción Fotoacústica

Los hallazgos experimentales de este trabajo tienen implicaciones significativas para el campo de la reconstrucción fotoacústica, especialmente en el contexto de aplicaciones clínicas. La combinación de conocimiento físico y aprendizaje basado en datos no solo mejora la calidad de las imágenes reconstruidas, sino que también proporciona un marco robusto y flexible que puede adaptarse a diferentes escenarios clínicos.

5.8.1. Avances en Calidad de Reconstrucción

Los resultados experimentales demostraron mejoras sustanciales en todas las métricas de calidad evaluadas. La reducción del 30.7 % en MSE, mejora del 18.9 % en MAE y incremento del 14.5 % en SSIM representan avances significativos en el estado del arte de la reconstrucción fotoacústica. Estas mejoras son particularmente relevantes considerando que la reconstrucción fotoacústica representa un problema inverso mal condicionado donde pequeñas mejoras numéricas pueden traducirse en beneficios clínicos sustanciales.

El análisis detallado de las métricas reveló además que las mejoras no se limitan a un aspecto particular de la calidad de imagen, sino que abarcan tanto la precisión numérica (MSE, MAE) como la calidad perceptual (SSIM, PSNR). Esta mejora global sugiere que el método propuesto aborda de manera efectiva múltiples aspectos del desafiante problema de reconstrucción fotoacústica.

La consistencia de estas mejoras a través de diferentes configuraciones experimentales y niveles de complejidad de imagen demuestra la robustez del método propuesto y su potencial para aplicación en escenarios diversos. La capacidad del modelo para mantener un alto rendimiento incluso en casos complejos es especialmente prometedora para aplicaciones clínicas, donde la variabilidad anatómica y la presencia de patologías pueden incrementar significativamente la complejidad de las imágenes.

5.8.2. Potencial Aplicación Clínica

El análisis visual de los resultados reveló características con implicaciones directas para potenciales aplicaciones clínicas de la imagen fotoacústica. La preservación mejorada de estructuras vasculares finas observada en las reconstrucciones del modelo propuesto podría ser crucial para el diagnóstico de condiciones que afectan la microvasculatura, como la retinopatía diabética o ciertos tipos de cáncer donde los cambios en el patrón vascular constituyen biomarcadores importantes.

La notable disminución de artefactos y ruido de fondo en las imágenes reconstruidas podría mejorar significativamente la confiabilidad del diagnóstico basado en imágenes fotoacústicas. Esta reducción de artefactos es particularmente relevante en contextos clínicos, donde la presencia de características espurias puede conducir a interpretaciones erróneas y comprometer la precisión diagnóstica.

El mejor contraste entre estructuras vasculares y fondo logrado por el modelo propuesto facilitaría la identificación de anomalías sutiles que podrían pasar desapercibidas con métodos de reconstrucción convencionales. Este incremento en el contraste podría traducirse en una mayor sensibilidad para la detección temprana de patologías, un factor crítico para mejorar el pronóstico en numerosas condiciones clínicas.

La robustez del modelo frente a diferentes niveles de complejidad anatómica, demostrada en el análisis de dispersión, sugiere una buena capacidad de generalización a la variabilidad encontrada en entornos clínicos reales. Esta característica es esencial para la traducción efectiva de la tecnología desde el laboratorio a la práctica clínica, donde la diversidad anatómica y patológica representa un desafío considerable para los sistemas de imagen médica.

5.9. Limitaciones del Estudio Actual

A pesar de los resultados prometedores, es importante reconocer ciertas limitaciones del presente estudio que contextualizan los hallazgos y sugieren áreas para refinamiento futuro. Una limitación significativa es la dependencia de datos simulados para la evaluación del método propuesto. Los experimentos se realizaron utilizando un conjunto de datos sintético derivado de imágenes de vasos sanguíneos de retina. Aunque este enfoque permitió generar un conjunto de datos de entrenamiento suficientemente grande, la generalización a datos reales podría enfrentar desafíos adicionales debido a factores como el ruido experimental, artefactos de adquisición y variaciones en las propiedades del tejido que no están completamente modelados en las simulaciones.

Otra limitación importante concierne al modelo físico utilizado para la generación de señales fotoacústicas. Aunque basado en principios físicos sólidos, este modelo representa una simplificación de la compleja física del fenómeno fotoacústico real. Factores como la heterogeneidad del tejido, la atenuación acústica y los efectos de refracción no se modelaron completamente en las simulaciones actuales. Esta simplificación podría afectar la transferibilidad de los resultados a escenarios reales donde estos factores juegan un papel significativo.

Desde la perspectiva arquitectónica, los experimentos se realizaron utilizando una arquitectura U-Net específica para ambas redes. Aunque esta arquitectura ha demostrado ser efectiva para tareas de segmentación y reconstrucción, el error relativamente alto observado en la red supervisora sugiere que podría no ser óptima para capturar completamente la física del problema fotoacústico. Esta observación señala la posibilidad de mejoras adicionales mediante la exploración de arquitecturas alternativas más adecuadas para modelar la propagación de ondas acústicas.

5.10. Reflexiones sobre el Enfoque Metodológico

El enfoque metodológico propuesto en este trabajo representa una innovación significativa en la incorporación de conocimiento físico en redes neuronales para la reconstrucción fotoacústica. Al combinar una red reconstructora con una red supervisora que aprende implícitamente la física del problema, logramos un balance efectivo entre la precisión cuantitativa y la calidad perceptual de las imágenes reconstruidas.

5.10.1. Balance entre Rigor Físico y Pragmatismo Computacional

Uno de los desafíos fundamentales en la incorporación de física en redes neuronales es encontrar el balance adecuado entre el rigor físico y el pragmatismo computacional. Los PINN tradicionales priorizan el rigor físico al incorporar las ecuaciones diferenciales directamente en la función de pérdida, pero a costa de una mayor complejidad computacional. En contraste, los enfoques puramente basados en datos priorizan la eficiencia computacional a expensas de la consistencia física.

Nuestro enfoque dual representa un compromiso pragmático que busca capturar lo mejor de ambos mundos: la consistencia física y la eficiencia computacional. Al utilizar una red supervisora que aprende implícitamente la física del problema, evitamos la necesidad de calcular derivadas explícitamente, reduciendo significativamente el costo computacional mientras mantenemos un nivel aceptable de consistencia física.

Este balance representa una contribución metodológica importante que podría inspirar enfoques similares en otros dominios donde la incorporación de conocimiento físico es deseable pero compu-

tacionalmente desafiante. La estrategia de utilizar una red especializada para capturar implícitamente la física del problema ofrece un camino prometedor para la integración de conocimiento físico en modelos de aprendizaje profundo sin los inconvenientes computacionales asociados a la incorporación explícita de ecuaciones diferenciales.

5.10.2. Generalización del Enfoque Metodológico

Aunque este trabajo utilizó la reconstrucción fotoacústica como caso de estudio, el enfoque metodológico propuesto posee un potencial de generalización considerable a una amplia gama de problemas inversos mal condicionados en imagen médica y otros dominios. Los ingredientes clave del enfoque son una red reconstructora que aprende a mapear datos medidos a la distribución espacial deseada, una red supervisora que aprende el problema directo (cómo los datos medidos se generan a partir de la distribución espacial), y un proceso de fine-tuning que incorpora la información proporcionada por la red supervisora para mejorar la red reconstructora.

Este marco general podría adaptarse a problemas tan diversos como la tomografía computarizada, la imagen por resonancia magnética, la tomografía por impedancia eléctrica, entre otros. En cada caso, la red supervisora aprendería el modelo físico específico del proceso de adquisición de datos, mientras que la red reconstructora se beneficiaría de esta guía física durante el fine-tuning.

La generalidad del enfoque y su independencia relativa de las especificidades de la física fotoacústica sugieren que la metodología propuesta podría constituir un paradigma más amplio para la incorporación de conocimiento físico en redes neuronales aplicadas a problemas inversos, representando así una contribución que trasciende el dominio específico de la imagen fotoacústica.

Estos hallazgos visuales, en conjunto con los resultados cuantitativos presentados, proporcionan una perspectiva integral sobre las ventajas del enfoque propuesto para la reconstrucción de imágenes fotoacústicas mediante redes neuronales duales con restricciones físicas, validando tanto la efectividad técnica como el potencial de aplicación clínica de la metodología desarrollada.

Capítulo 6

Conclusiones y Trabajo Futuro

Esta investigación ha abordado el desafío de incorporar conocimiento físico en redes neuronales para la reconstrucción de imágenes fotoacústicas, proponiendo una estrategia de entrenamiento dual física-guiada que equilibra eficientemente el aprendizaje basado en datos con restricciones físicas. En este capítulo final, presentamos las conclusiones principales de nuestro trabajo y delineamos direcciones prometedoras para investigación futura.

6.1. Conclusiones

La investigación realizada ha permitido desarrollar un nuevo paradigma para la reconstrucción física-guiada de imágenes fotoacústicas, del cual pueden extraerse las siguientes conclusiones fundamentales:

6.1.1. Sobre la Estrategia de Entrenamiento Dual

Nuestros experimentos confirman que la estrategia de entrenamiento dual propuesta constituye un enfoque efectivo para incorporar conocimiento físico en redes neuronales profundas, sin la complejidad computacional asociada a los métodos PINN tradicionales. Este hallazgo responde directamente a nuestra primera pregunta de investigación (PI1), demostrando múltiples ventajas del enfoque propuesto.

La separación del problema en dos redes complementarias (reconstructora y supervisora) permite una división natural del trabajo, donde cada red puede especializarse en su tarea específica. Esta especialización facilita el aprendizaje, ya que cada red puede adaptar su arquitectura y proceso de optimización a las particularidades de su objetivo concreto. Adicionalmente, esta separación proporciona mayor flexibilidad arquitectónica y conceptual que los enfoques monolíticos tradicionales.

El proceso de fine-tuning con supervisión física facilita la transferencia efectiva de conocimiento físico, como lo evidencia la mejora del 30.7 % en MSE y del 14.5 % en SSIM respecto al modelo baseline. Esta transferencia de conocimiento ocurre de manera gradual y estable, como se observó en el análisis de las dinámicas de entrenamiento, donde identificamos tres fases distintivas: inicial, estabilización y convergencia. Esta progresión estructurada permite que la red reconstructora incorpore paulatinamente las restricciones físicas sin comprometer la calidad visual de las reconstrucciones.

Un aspecto particularmente destacable es que el enfoque propuesto mantiene una eficiencia computacional comparable a métodos puramente basados en datos, mientras incorpora restricciones físicas significativas. A diferencia de los PINN tradicionales, que requieren la evaluación explícita de derivadas durante el entrenamiento, nuestro método aprende implícitamente la física del problema a través de la red supervisora, evitando así la sobrecarga computacional asociada al cálculo de derivadas.

6.1.2. Sobre el Aprendizaje Simultáneo de Problemas Directo e Inverso

En relación a nuestra segunda pregunta de investigación (PI2), los resultados demuestran que el aprendizaje simultáneo del problema directo e inverso ofrece ventajas sustanciales para la reconstrucción fotoacústica. Esta aproximación bilateral al problema permite capturar las complejidades de ambas direcciones del fenómeno físico, enriqueciendo el proceso de aprendizaje y mejorando la calidad de las reconstrucciones.

La red supervisora, al aprender el problema directo (generación de señales fotoacústicas), captura implícitamente las complejidades físicas del fenómeno sin necesidad de modelarlas explícitamente mediante ecuaciones diferenciales. Este aprendizaje implícito representa una ventaja significativa frente a métodos que requieren una formulación matemática precisa del problema, ya que permite adaptarse a fenómenos cuya descripción analítica puede ser compleja o computacionalmente intensiva.

El conocimiento físico capturado por la red supervisora, cuando se transfiere a la red reconstructora durante el fine-tuning, actúa como un regularizador implícito que guía el proceso de aprendizaje hacia soluciones físicamente plausibles. Esta guía física resulta crucial para abordar la naturaleza mal condicionada del problema inverso fotoacústico, reduciendo el espacio de soluciones posibles a aquellas que son consistentes con los principios físicos subyacentes.

Un beneficio adicional observado es la mejora significativa en la robustez del entrenamiento, evidenciada por la menor sensibilidad a la complejidad de la imagen en el modelo completo comparado con las variantes ablativas. Esta característica es particularmente relevante para aplicaciones clínicas, donde la variabilidad anatómica y las condiciones de adquisición pueden generar escenarios de reconstrucción desafiantes.

6.1.3. Sobre la Contribución de los Componentes de la Función de Pérdida

Nuestros experimentos de ablación proporcionan respuestas claras a nuestra tercera pregunta de investigación (PI3), revelando roles complementarios pero fundamentalmente diferentes para los componentes de la función de pérdida. Esta diferenciación funcional constituye un hallazgo importante que puede informar el diseño de funciones de pérdida para problemas similares.

El componente físico actúa principalmente como regularizador y estabilizador del proceso de aprendizaje, mejorando la robustez frente a variaciones en la complejidad de las imágenes. Como se observó en el análisis de correlación, el modelo sin componente físico mostró una mayor sensibilidad a la entropía de la imagen ($r = -0,31$, $p < 0,001$) comparado con el modelo completo ($r = -0,16$), evidenciando que la restricción física incrementa la robustez frente a escenarios complejos. Este efecto estabilizador sugiere que la física actúa como una guía que mantiene el proceso de optimización en una trayectoria consistente incluso cuando la complejidad visual de las imágenes aumenta.

Por otro lado, el componente estructural demostró ser crucial para la preservación de detalles

finos y características perceptuales. La drástica caída en SSIM, de una mejora del 14.5 % a apenas 0.5 % cuando se elimina este componente, evidencia su papel fundamental en la calidad visual de las reconstrucciones. Esta preservación de detalles estructurales es particularmente relevante en el contexto de imágenes vasculares, donde las estructuras finas pueden contener información diagnóstica crítica.

Quizás el hallazgo más significativo es la interacción sinérgica entre ambos componentes, que produce un efecto multiplicativo en lugar de meramente aditivo. Esta sinergia se manifiesta claramente en los resultados experimentales, donde la mejora del modelo completo (30.7 % en MSE) supera ampliamente la suma de las mejoras individuales de los modelos ablacionados (2.8 % + 2.1 %). Este comportamiento sugiere que ambos componentes no solo son complementarios, sino que se potencian mutuamente, creando un sistema de supervisión dual donde las restricciones físicas y estructurales se refuerzan recíprocamente.

6.1.4. Sobre la Generalización del Enfoque Metodológico

En cuanto a nuestra cuarta pregunta de investigación (PI4), si bien este trabajo se centró en la reconstrucción fotoacústica, nuestros hallazgos sugieren que el enfoque metodológico propuesto posee un potencial de generalización considerable a otros problemas inversos mal condicionados en imagen médica y más allá.

La arquitectura dual propuesta no depende fundamentalmente de características específicas del problema fotoacústico, sino que aborda desafíos generales de los problemas inversos mal condicionados como la unicidad de la solución, la estabilidad frente al ruido y la incorporación de conocimiento previo. Este carácter general del enfoque facilita su adaptación a otros dominios donde se enfrentan desafíos similares.

El paradigma de transferencia de conocimiento físico mediante una red supervisora representa un marco conceptual adaptable a diversos contextos donde existe un modelo físico subyacente. Esta transferencia de conocimiento podría implementarse en cualquier dominio donde sea posible simular o modelar el proceso físico directo, incluso cuando el proceso inverso sea matemáticamente complejo o mal condicionado.

Los principios de balance entre restricciones físicas y estructurales, identificados como elementos clave de nuestro enfoque, podrían aplicarse en dominios tan diversos como la tomografía computarizada, la imagen por resonancia magnética o la tomografía por impedancia eléctrica. En cada caso, las restricciones específicas del dominio podrían incorporarse mediante una red supervisora adaptada al fenómeno físico correspondiente, mientras que los principios generales de transferencia de conocimiento y fine-tuning supervisado se mantendrían consistentes.

6.1.5. Conclusiones Generales

Como conclusión general, esta investigación demuestra que la incorporación adecuada de conocimiento físico en arquitecturas de deep learning puede mejorar significativamente la calidad de reconstrucción en problemas inversos mal condicionados. El enfoque propuesto logra un equilibrio efectivo entre el aprendizaje basado en datos y la incorporación de restricciones físicas, sin incurrir en la complejidad computacional de los métodos tradicionales como PINN.

La estrategia de entrenamiento dual desarrollada ofrece ventajas tanto en calidad de reconstrucción como en consistencia física, posicionándose como una alternativa viable a los métodos existentes en el campo de la reconstrucción fotoacústica. Las mejoras cuantitativas observadas se

traducen en beneficios cualitativos significativos, particularmente en la preservación de estructuras finas y la reducción de artefactos, aspectos críticos para la aplicabilidad clínica de la imagen fotoacústica.

Estas conclusiones subrayan la importancia de considerar tanto los principios físicos fundamentales como los avances en aprendizaje profundo al abordar problemas inversos complejos en imagen médica. La integración sinérgica de ambos enfoques, como la implementada en este trabajo, representa un paradigma prometedor que podría extenderse a numerosos dominios donde la física del problema proporciona restricciones valiosas pero computacionalmente desafiantes.

6.2. Trabajo Futuro

A partir de los resultados obtenidos y las limitaciones identificadas, proponemos varias direcciones prometedoras para investigación futura que podrían extender y refinar los hallazgos de este trabajo.

6.2.1. Validación con Datos Reales

Una extensión natural y prioritaria de este trabajo sería validar la metodología propuesta utilizando datos fotoacústicos reales adquiridos en entornos clínicos o experimentales. Esta validación permitiría evaluar la robustez del método frente a las complejidades adicionales presentes en datos reales, como el ruido experimental, artefactos de adquisición y variaciones en las propiedades del tejido que no están completamente modelados en las simulaciones actuales.

Un aspecto crucial de esta validación sería determinar si las mejoras observadas en datos simulados se traducen efectivamente en beneficios clínicos tangibles. La traducción de mejoras cuantitativas en métricas como MSE o SSIM a beneficios diagnósticos reales requeriría estudios de validación clínica en colaboración con especialistas médicos, quienes podrían evaluar el impacto de las mejoras en la calidad de imagen sobre la precisión diagnóstica.

Para facilitar esta transición de datos simulados a reales, sería necesario desarrollar estrategias de adaptación domain-specific que mejoren la transferencia entre ambos dominios. Técnicas como domain adaptation o transfer learning podrían emplearse para adaptar modelos preentrenados con datos simulados a las características específicas de datos reales, permitiendo aprovechar el conocimiento adquirido durante la fase de simulación mientras se ajustan los modelos a las particularidades de los datos experimentales.

6.2.2. Avances Arquitectónicos

La exploración de arquitecturas más avanzadas representa otra dirección prometedoras que podría potenciar aún más los beneficios del enfoque propuesto. La incorporación de mecanismos de atención [49, 57] permitiría a la red enfocarse en características físicamente relevantes del problema, mejorando la eficiencia del aprendizaje y la calidad de las reconstrucciones. Estos mecanismos podrían ser particularmente útiles para identificar y preservar estructuras anatómicas críticas en las imágenes reconstruidas.

El campo podría beneficiarse también de la exploración de arquitecturas densamente conectadas [27] o residuales para mejorar el flujo de gradientes y facilitar el entrenamiento de redes más profundas. Estas arquitecturas han demostrado su efectividad en diversos problemas de visión

por computador y podrían adaptarse al contexto específico de la reconstrucción fotoacústica para mejorar el rendimiento y la estabilidad del entrenamiento.

Un área particularmente prometedora sería el desarrollo de arquitecturas específicamente diseñadas para capturar las características multiescala del fenómeno fotoacústico. Inspiradas en representaciones multiresolución como wavelets o pirámides laplacianas, estas arquitecturas podrían adaptarse mejor a la naturaleza del problema físico, donde diferentes escalas espaciales contienen información complementaria sobre la estructura de los tejidos.

6.2.3. Extensión a Reconstrucción Tridimensional

La extensión del enfoque propuesto a reconstrucción tridimensional representaría un avance significativo hacia aplicaciones clínicas avanzadas. Esta extensión requeriría adaptar la arquitectura dual para procesar datos volumétricos, considerando las restricciones de memoria y computación asociadas al manejo de datos 3D. Estrategias como el procesamiento por parches o técnicas de atención selectiva podrían emplearse para manejar eficientemente estos datos de alta dimensionalidad.

El desarrollo de estrategias de visualización y análisis específicas para datos fotoacústicos tridimensionales constituiría otro aspecto importante de esta extensión. La visualización efectiva de estructuras vasculares tridimensionales facilitaría la interpretación clínica de las reconstrucciones y potenciaría el valor diagnóstico de la técnica.

Para abordar los desafíos computacionales asociados a la reconstrucción 3D, sería valioso explorar enfoques de reconstrucción incremental o por parches. Estas estrategias permitirían procesar volúmenes de datos que exceden la capacidad de memoria disponible, haciendo viable la aplicación del método a reconstrucciones de alta resolución espacial en tres dimensiones.

6.2.4. Refinamiento de Modelos Físicos

El refinamiento de los modelos físicos utilizados tanto en la generación de datos como en la red supervisora podría mejorar significativamente la fidelidad de las reconstrucciones, especialmente en la transición a datos reales. La incorporación de modelos más complejos que consideren factores como la heterogeneidad del tejido, la atenuación acústica y los efectos de refracción permitiría simular con mayor precisión el proceso fotoacústico real, mejorando así la capacidad de la red supervisora para capturar la física relevante del problema.

El desarrollo de arquitecturas híbridas que combinen componentes basados en ecuaciones diferenciales parciales con capas convolucionales podría proporcionar una representación más rica de la física del problema. Estas arquitecturas podrían beneficiarse tanto del rigor matemático de los modelos basados en ecuaciones diferenciales como de la flexibilidad y capacidad de aprendizaje de las redes convolucionales.

La exploración de técnicas de optimización bayesiana o aprendizaje por refuerzo para adaptar dinámicamente los parámetros físicos durante el entrenamiento constituiría otra dirección prometedora. Estas técnicas permitirían ajustar automáticamente la complejidad del modelo físico basándose en las características específicas de los datos, optimizando el balance entre fidelidad física y eficiencia computacional.

6.2.5. Aplicación a Otros Problemas Inversos

La metodología propuesta posee un potencial considerable para ser adaptada a otros problemas inversos mal condicionados en imagen médica y más allá. En tomografía computarizada de dosis reducida, las restricciones físicas implementadas mediante la red supervisora podrían compensar la limitada información disponible, permitiendo reconstrucciones de alta calidad a partir de proyecciones subsampladas y reduciendo así la exposición del paciente a radiación.

Para imagen por resonancia magnética subsamplada, donde la física de la adquisición impone restricciones específicas en el espacio k , nuestro enfoque podría adaptarse para incorporar estas restricciones a través de la red supervisora. Esta aplicación permitiría reducir significativamente los tiempos de adquisición mientras se mantiene la calidad diagnóstica de las imágenes.

La tomografía por impedancia eléctrica, un problema notoriamente mal condicionado, podría beneficiarse particularmente del enfoque de supervisión física propuesto. La extrema sensibilidad de este problema a variaciones en los parámetros y condiciones de contorno lo hace especialmente adecuado para métodos que incorporan restricciones físicas como regularizadores implícitos.

Otras aplicaciones potenciales incluyen la reconstrucción en microscopía óptica de super-resolución, donde las restricciones físicas de difracción podrían incorporarse mediante la red supervisora para superar los límites de resolución convencionales, y la reconstrucción acústica en entornos complejos, donde la física de propagación de ondas impone restricciones significativas.

6.2.6. Investigación en Transferencia de Conocimiento Físico

El paradigma de transferencia de conocimiento físico mediante redes duales merece una exploración más profunda desde perspectivas tanto teóricas como prácticas. El desarrollo de métricas específicas para evaluar la consistencia física de las reconstrucciones, más allá de las métricas visuales tradicionales, permitiría una evaluación más precisa de la efectividad del método en preservar las propiedades físicas relevantes.

La exploración de estrategias de curriculum learning que introduzcan gradualmente la complejidad física durante el entrenamiento podría mejorar la estabilidad y eficiencia del proceso de aprendizaje. Estas estrategias podrían comenzar con modelos físicos simplificados y progresar hacia representaciones más complejas a medida que avanza el entrenamiento, facilitando así la incorporación de restricciones físicas complejas sin comprometer la estabilidad del aprendizaje.

La investigación de métodos para formalizar y visualizar el conocimiento físico transferido constituiría otra área prometedora. Técnicas de interpretabilidad o explicabilidad de redes neuronales podrían emplearse para comprender mejor qué aspectos específicos de la física del problema están siendo capturados por la red supervisora y transferidos a la red reestructora. Esta comprensión profundizaría nuestro conocimiento teórico del proceso de transferencia y podría informar mejoras en la metodología.

6.3. Consideraciones Finales

Esta tesis ha demostrado que la integración adecuada de principios físicos en arquitecturas de deep learning ofrece un camino prometedor para mejorar la reconstrucción de imágenes fotoacústicas. El enfoque propuesto, basado en redes neuronales duales con supervisión física, representa una contribución significativa al campo, equilibrando efectivamente el aprendizaje basado en datos con

la incorporación de conocimiento físico.

Las direcciones de investigación futura delineadas en este capítulo tienen el potencial de extender y refinar estos hallazgos, acercando aún más las técnicas de imagen fotoacústica a su aplicación clínica generalizada. En última instancia, esperamos que este trabajo contribuya a un paradigma más amplio donde los principios físicos fundamentales y los avances en aprendizaje profundo se integren sinérgicamente para abordar problemas complejos en ciencia e ingeniería.

Bibliografía

- [1] S. Antholzer, M. Haltmeier, and J. Schwab. Deep learning for photoacoustic tomography from sparse data. *Inverse Problems in Science and Engineering*, 27(7):987–1005, 2019.
- [2] S. Antholzer, J. Schwab, and M. Haltmeier. Photoacoustic imaging with limited sampling: a review of machine learning approaches. *Biomedical Optics Express*, 14(4):1777–1798, 2023. Accedido: 22 abril 2025.
- [3] S. Arridge, P. Maass, O. Öktem, and C.-B. Schönlieb. Solving inverse problems using data-driven models. *Acta Numerica*, 2016.
- [4] A. G. Bell. *On the production and reproduction of sound by light*, volume 20. Yale University, 1880.
- [5] A. G. Bell. On the production and reproduction of sound by light. *American Journal of Science*, 20(118):305–324, 1880.
- [6] N. I. Berezhnov and A. A. Sirota. Improving attention mechanisms in transformer architecture in image restoration. *Computer Optics*, 48(5), 2024. Accedido: 22 abril 2025.
- [7] BILab@ISU. Deep learning in photoacoustic imaging, 2024. Accedido: 22 abril 2025.
- [8] L. Bottou, F. E. Curtis, and J. Nocedal. Optimization methods for large-scale machine learning. *SIAM review*, 60(2):223–311, 2018.
- [9] J. Chen and Q. Gu. Closing the generalization gap of adaptive gradient methods in training deep neural networks. *arXiv preprint arXiv:1806.06763*, 2018.
- [10] M. Chen, M. Xu, and L. Ding. Dual-modal photoacoustic and ultrasound imaging: from preclinical to clinical applications. *Frontiers in Photonics*, 5:1359784, 2024. Accedido: 22 abril 2025.
- [11] W. Choi and C. Kim. Review of deep learning approaches for interleaved photoacoustic and ultrasound (paus) imaging. *PMC - PubMed Central*, 2022. Accedido: 22 abril 2025.
- [12] B. Cox, P. Beard, and S. Arridge. Quantitative photoacoustic tomography: modeling and inverse problems. *UCL Discovery*, 2021. Accedido: 22 abril 2025.
- [13] B. Cox, J. G. Laufer, P. C. Beard, and S. R. Arridge. Challenges for quantitative photoacoustic imaging. *Proceedings of SPIE*, 7177:717713, 2009.
- [14] J. Doe and J. Smith. Recent advances in photoacoustic imaging: Current status and future perspectives. *Journal of Biomedical Imaging*, 43(2):125–148, 2025. Accedido: 22 abril 2025.
- [15] J. Duchi, E. Hazan, and Y. Singer. Adaptive subgradient methods for online learning and stochastic optimization. *Journal of machine learning research*, 12(7):2121–2159, 2011.

- [16] S. Guan, A. A. Khan, S. Sikdar, and P. V. Chitnis. Fully dense unet for 2d sparse photoacoustic tomography artifact removal. *IEEE Journal of Selected Topics in Quantum Electronics*, 2020.
- [17] S. Guan, A. A. Khan, S. Sikdar, and P. V. Chitnis. Hybrid neural network for photoacoustic imaging reconstruction. *PubMed*, 2020. Accedido: 22 abril 2025.
- [18] S. Guan, A. A. Khan, S. Sikdar, and P. V. Chitnis. Deep-learning image reconstruction for real-time photoacoustic system. *PMC - PubMed Central*, 2021. Accedido: 22 abril 2025.
- [19] B. Guo, J. Li, H. Zmuda, and M. Sheplak. Deep learning for photoacoustic imaging: A survey. *Neurocomputing*, 402:336–351, 2020.
- [20] A. Hauptmann, B. Cox, and P. Beard. Advances in photoacoustic imaging reconstruction and quantitative analysis for biomedical applications. *arXiv preprint*, arXiv:2411.02843, 2024. Accedido: 22 abril 2025.
- [21] A. Hauptmann, B. Cox, and P. Beard. Advances in photoacoustic imaging reconstruction and quantitative analysis for biomedical applications. *ResearchGate*, 2024. Accedido: 22 abril 2025.
- [22] A. Hauptmann and B. T. Cox. Deep learning in photoacoustic tomography: current approaches and future directions. *Journal of Biomedical Optics*, 25(11):112903, 2020.
- [23] A. Hauptmann, F. Lucka, M. Betcke, N. Huynh, J. Adler, B. Cox, P. Beard, S. Ourselin, and S. Arridge. Model-based learning for accelerated, limited-view 3-D photoacoustic tomography. *IEEE transactions on medical imaging*, 2018.
- [24] K. He, X. Zhang, S. Ren, and J. Sun. Deep residual learning for image recognition. *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 770–778, 2016.
- [25] M. Hoffer, A. Pourshafeie, L. Schmidt, I. Shcherbatyi, and G. Wolf. Augmented neural networks for modeling physical systems with conservation laws. *arXiv preprint arXiv:1912.04405*, 2019.
- [26] C. Huang, K. Wang, L. Nie, et al. Full-wave iterative image reconstruction in photoacoustic tomography with acoustically inhomogeneous media. *IEEE transactions on medical imaging*, 32(6):1097–1110, 2013.
- [27] G. Huang, Z. Liu, L. Van Der Maaten, and K. Q. Weinberger. Densely connected convolutional networks. *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 4700–4708, 2017.
- [28] T. Jetzfellner, A. Rosenthal, and D. Razansky. Quantitative photoacoustic image reconstruction improves accuracy in deep tissue structures. *PMC - PubMed Central*, 2016. Accedido: 22 abril 2025.
- [29] R. Johnson and E. Williams. Recent advances in photoacoustic imaging: Current status and future perspectives. *PMC - PubMed Central*, 12(4):45–67, 2025. Accedido: 22 abril 2025.
- [30] C. Kim, T. N. Erpelding, K. Maslov, et al. Clinical photoacoustic imaging platforms. *Biomedical Engineering Letters*, 11:91–100, 2021.
- [31] D. P. Kingma and J. Ba. Adam: A method for stochastic optimization. *arXiv preprint arXiv:1412.6980*, 2014.

- [32] P. Kuchment and L. Kunyansky. Mathematics of thermoacoustic tomography. *European Journal of Applied Mathematics*, 19(2):191–224, 2008.
- [33] R. Kumar and M. Singh. Hybrid learning systems: Integrating traditional machine learning with deep learning techniques. *ResearchGate*, 2024. Accedido: 22 abril 2025.
- [34] O. Lang, P. Kovacs, C. Motz, M. Huemer, T. Berer, and P. Burgholzer. A linear state space model for photoacoustic imaging in an acoustic attenuating media. *arXiv preprint*, 1808.00218v1, 2017.
- [35] J.-G. Lee, S. Jun, Y.-W. Cho, H. Lee, G. B. Kim, J. B. Seo, and N. Kim. Deep learning in medical imaging: general overview. *Korean Journal of Radiology*, 20(7):1133–1142, 2019.
- [36] H. Li, Z. Xu, G. Taylor, C. Studer, and T. Goldstein. Visualizing the loss landscape of neural nets. *Advances in neural information processing systems*, 31:6389–6399, 2018.
- [37] L. Li, L. Zhu, C. Ma, L. Lin, J. Yao, and L. V. Wang. Photoacoustic tomography: principles and advances. *Progress in Biomedical Engineering*, 3(2):022003, 2021.
- [38] X. Li, J. Taylor, and C.-W. Wei. Quantitative photoacoustic imaging algorithm using sparse decomposition for photoacoustic and ultrasound dual-mode imaging. *Biomedical Optics Express*, 2024. Accedido: 22 abril 2025.
- [39] Z. Li, X. Wang, and J. Chen. Deep learning-based super-resolution reconstruction and segmentation of photoacoustic images. *Applied Sciences*, 14(12):5331, 2024. Accedido: 22 abril 2025.
- [40] Z. Li, H. Zhang, and J. Wu. Understanding physics-informed neural networks: Techniques, applications, trends, and challenges. *Intelligence*, 5(3):74, 2024. Accedido: 22 abril 2025.
- [41] Z. Li, H. Zhang, and J. Wu. Understanding physics-informed neural networks: Techniques, applications, trends, and challenges. *ResearchGate*, 2024. Accedido: 22 abril 2025.
- [42] Y. Lin and L. Wang. Deep learning-powered biomedical photoacoustic imaging. *ResearchGate*, 2023. Accedido: 22 abril 2025.
- [43] L. Liu, H. Jiang, P. He, W. Chen, X. Liu, J. Gao, and J. Han. On the variance of the adaptive learning rate and beyond. *arXiv preprint arXiv:1908.03265*, 2019.
- [44] W. Liu, Z. Wang, and X. Han. A comprehensive review of deep learning: Architectures, recent advances, and applications. *Information*, 15(12):755, 2024. Accedido: 22 abril 2025.
- [45] Z. Liu, Z. Chen, and C. Zhang. Score-based diffusion models for photoacoustic tomography image reconstruction. *arXiv preprint*, arXiv:2404.00471v1, 2024. Accedido: 22 abril 2025.
- [46] I. Loshchilov and F. Hutter. Decoupled weight decay regularization. *arXiv preprint arXiv:1711.05101*, 2017.
- [47] C. Lutzweiler and D. Razansky. Photoacoustic imaging and tomography: Current approaches and future directions. *Current medical imaging reviews*, 10(4):305–313, 2014.
- [48] A. Maier, C. Syben, T. Lasser, and C. Riess. A gentle introduction to deep learning in medical image processing. *Zeitschrift für Medizinische Physik*, 29(2):86–101, 2019.

- [49] O. Oktay, J. Schlemper, L. L. Folgoc, M. Lee, M. Heinrich, K. Misawa, K. Mori, S. McDonagh, N. Y. Hammerla, B. Kainz, B. Glocker, and D. Rueckert. Attention U-Net: Learning where to look for the pancreas. In *Medical Imaging with Deep Learning*. MIDL, 2018.
- [50] J. Park and L. V. Wang. Clinical translation of photoacoustic imaging. *Nature Reviews Bioengineering*, 2:123–142, 2024. Accedido: 22 abril 2025.
- [51] M. Raissi, P. Perdikaris, and G. E. Karniadakis. Physics informed deep learning (Part I): Data-driven solutions of nonlinear partial differential equations. *arXiv preprint arXiv:1711.10561*, 2017.
- [52] M. Raissi, P. Perdikaris, and G. E. Karniadakis. Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations. *Journal of Computational Physics*, 2019.
- [53] S. J. Reddi, S. Kale, and S. Kumar. On the convergence of adam and beyond. *arXiv preprint arXiv:1904.09237*, 2019.
- [54] A. Reiter and M. A. Lediju Bell. Current state of photoacoustic imaging. *Current opinion in biomedical engineering*, 3:94–100, 2017.
- [55] O. Ronneberger, P. Fischer, and T. Brox. U-net: Convolutional networks for biomedical image segmentation. In *International Conference on Medical Image Computing and Computer-Assisted Intervention*, volume 9351 of *Lecture Notes in Computer Science*, pages 234–241. Springer, Springer International Publishing, 2015.
- [56] S. Ruder. An overview of gradient descent optimization algorithms. *arXiv preprint arXiv:1609.04747*, 2016.
- [57] J. Schlemper, O. Oktay, M. Schaap, et al. Attention gated networks: Learning to leverage salient regions in medical images. *Medical image analysis*, 53:197–207, 2019.
- [58] R. M. Schmidt, F. Schneider, and P. Hennig. Descending through a crowded valley-benchmarking deep learning optimizers. *International Conference on Machine Learning*, pages 9367–9376, 2021.
- [59] T. Shan and J. Tang. Physics-based neural networks for inverse problems in imaging. *IEEE Transactions on Image Processing*, 2019.
- [60] D. Shen, G. Wu, and H.-I. Suk. Deep learning in medical image analysis. *Annual review of biomedical engineering*, 19:221–248, 2017.
- [61] L. N. Smith. Cyclical learning rates for training neural networks. *2017 IEEE winter conference on applications of computer vision (WACV)*, pages 464–472, 2017.
- [62] J. Tick, A. Pulkkinen, and T. Tarvainen. Image reconstruction in photoacoustic tomography with variable speed of sound using a higher-order geometrical acoustics approximation. *The Journal of the Acoustical Society of America*, 139(3):1447–1459, 2016.
- [63] T. Tieleman and G. Hinton. Lecture 6.5-rmsprop: Divide the gradient by a running average of its recent magnitude. *COURSERA: Neural networks for machine learning*, 4(2):26–31, 2012.
- [64] K. S. Valluru and J. K. Willmann. Molecular photoacoustic imaging using small molecule dyes. *Bioengineering*, 3(1):7, 2016.

- [65] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser, and I. Polosukhin. Attention is all you need. In *Advances in Neural Information Processing Systems*, volume 30, pages 5998–6008. Curran Associates, Inc., 2017.
- [66] K. Wang and L. V. Wang. Image reconstruction from photoacoustic projections. *Photonics Insights*, 3(3):R06, 2024. Accedido: 22 abril 2025.
- [67] K. Wang and L. V. Wang. Image reconstruction from photoacoustic projections. *ResearchGate*, 2024. Accedido: 22 abril 2025.
- [68] L. Wang and M. Xu. Photoacoustic digital brain and deep-learning-assisted image reconstruction. *ResearchGate*, 2023. Accedido: 22 abril 2025.
- [69] L. V. Wang. Photoacoustic tomography: fundamentals, advances and prospects. *Contrast media & molecular imaging*, 2009.
- [70] L. V. Wang and S. Hu. Photoacoustic imaging in biomedicine. *Science*, 335(6075):1458–1462, 2012.
- [71] X. Wang, H. Chen, and M. Li. Physics-informed neural network solver for numerical analysis in geoenvironment. *Georisk: Assessment and Management of Risk for Engineered Systems and Geohazards*, 2024. Accedido: 22 abril 2025.
- [72] X. Wang, T. Zhang, and H. Liu. Mwg-unet++: Hybrid transformer u-net model for brain tumor segmentation in mri scans. *Bioengineering*, 12(2):140, 2024. Accedido: 22 abril 2025.
- [73] Y. Wang and L. V. Wang. A review of photoacoustic tomography systems. *IEEE Journal of Selected Topics in Quantum Electronics*, 22(3):1–15, 2016.
- [74] M. Xu and L. V. Wang. Universal back-projection algorithm for photoacoustic computed tomography. *Physical Review E*, 71(1):016706, 2005.
- [75] M. Xu and L. V. Wang. Photoacoustic imaging in biomedicine. *Review of Scientific Instruments*, 77(4):041101, 2006.
- [76] C. Yang, H. Lan, F. Gao, and F. Gao. Review of deep learning for photoacoustic imaging. *Photoacoustics*, 21:100215, 2021.
- [77] C. Yang, H. Lan, F. Gao, and F. Gao. Photoacoustic imaging aided with deep learning: a review. *PMC - PubMed Central*, 2022. Accedido: 22 abril 2025.
- [78] J. Yang, S. Ren, and S. Yang. Recent advances in deep-learning-enhanced photoacoustic imaging. *ResearchGate*, 2023. Accedido: 22 abril 2025.
- [79] Y. Yang, J. Sun, L. Li, and L. V. Wang. Physics-informed deep learning for computational photoacoustic imaging. *IEEE Transactions on Computational Imaging*, 2021.
- [80] X. Yi, E. Walia, and P. Babyn. Generative adversarial networks in medical image analysis. *Medical image analysis*, 58:101552, 2019.
- [81] Y. You, J. Li, S. Reddi, J. Hseu, S. Kumar, S. Bhojanapalli, X. Song, J. Demmel, K. Keutzer, and C.-J. Hsieh. Large batch optimization for deep learning: Training bert in 76 minutes. *arXiv preprint arXiv:1904.00962*, 2019.

- [82] C. Zhang, J. Liu, and W. Chen. Physics-informed neural networks in polymers: A review. *Polymers*, 17(8):1108, 2025. Accedido: 22 abril 2025.
- [83] C. Zhang and W. Liu. Resolution enhancement strategies in photoacoustic microscopy: A comprehensive review. *Micromachines*, 15(12):1463, 2024. Accedido: 22 abril 2025.
- [84] H. Zhang, J. Xia, et al. Advances in photoacoustic imaging: from bench to bedside. *Advanced Photonics*, 2(1):014001, 2020.
- [85] J. Zhang, M. Sun, and J. Lei. Sparse sampling photoacoustic reconstruction with a graph regularization group sparse dictionary. *Applied Optics*, 63(20):5292, 2024. Accedido: 22 abril 2025.
- [86] Y. Zhang, D. Wu, and X. Wang. Deep learning realizes photoacoustic imaging artifact removal. *Applied Sciences*, 14(12):5161, 2024. Accedido: 22 abril 2025.
- [87] Y. Zhang, J. Yu, and Y. Hu. Challenges and advances in two-dimensional photoacoustic computed tomography: a review. *PMC - PubMed Central*, 2023. Accedido: 22 abril 2025.
- [88] Z. Zhao, L. Li, and L. V. Wang. Enhanced photoacoustic microscopy with physics-embedded degeneration learning. *Opto-Electronic Advances*, 2024. Accedido: 22 abril 2025.
- [89] X. Zheng, Y. Wang, and S. Zhou. Hybrid reconstruction approach for polychromatic computed tomography in highly limited-data scenarios. *Sensors*, 24(21):6782, 2024. Accedido: 22 abril 2025.
- [90] W. Zhou and Y. Xu. Data-guided physics-informed neural networks for solving inverse problems in partial differential equations. *arXiv preprint arXiv:2407.10836*, 2024.
- [91] W. Zhou, Y. Zhang, and Y. Xu. Pinns for medical image analysis: A survey. *arXiv preprint*, arXiv:2408.01026v1, 2024. Accedido: 22 abril 2025.
- [92] Y. Zhou, J. Gao, and D. P. Papageorgiou. Physics-guided deep learning for inverse problems. *arXiv preprint arXiv:2020.xxxx*, 2020.
- [93] Z. Zhou, M. M. Rahman Siddiquee, N. Tajbakhsh, and J. Liang. UNet++: Redesigning skip connections to exploit multiscale features in image segmentation. *IEEE Transactions on Medical Imaging*, 39(6):1856–1867, 2019.
- [94] F. Zou, L. Shen, Z. Jie, W. Zhang, and W. Liu. A sufficient condition for convergences of adam and rmsprop. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 11127–11135, 2019.